ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG CÔNG NGHỆ VÀ THIẾT KẾ
KHOA CÔNG NGHỆ THÔNG TIN KINH DOANH

KHÓA LUẬN TỐT NGHIỆP

CHUYÊN NGÀNH: CÔNG NGHỆ THÔNG TIN

ĐỀ TÀI: XÂY DỰNG NỀN TẢNG TÍCH HỢP VÀ PHÂN TÍCH DỮ LIỆU VẬN HÀNH ĐA NGUỒN HỖ TRỢ TRUY VẾT NGUYÊN NHÂN BIẾN ĐỘNG DOANH THU CHO CHUỖI F&B

Giảng viên hướng dẫn: TS. Ngô Tấn Vũ Khanh

Sinh viên thực hiện: Lê Cao Phúc

MSSV:31231021033

TP. Hồ Chí Minh, tháng 10 năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan khóa luận "Xây dựng nền tảng tích hợp và phân tích dữ liệu vận hành đa nguồn hỗ trợ truy vết nguyên nhân biến động doanh thu cho chuỗi F&B" là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn của TS. Ngô Tấn Vũ Khanh.

Các số liệu và kết quả trình bày trong khóa luận là trung thực, được đo trực tiếp trên hệ thống do tôi xây dựng. Dữ liệu sử dụng là dữ liệu mô phỏng, cách xây dựng và kiểm chứng được trình bày ở Chương 3 và Chương 4. Các tài liệu tham khảo đều được trích dẫn đầy đủ.

Tôi xin hoàn toàn chịu trách nhiệm về nội dung của khóa luận.

TP. Hồ Chí Minh, ngày … tháng 10 năm 2026

Sinh viên thực hiện

Lê Cao Phúc

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn sâu sắc đến giảng viên hướng dẫn, TS. Ngô Tấn Vũ Khanh, Đại học Kinh tế TP. Hồ Chí Minh. Sự định hướng và những góp ý trong suốt quá trình thực hiện đã giúp em đi đúng mục tiêu và hoàn thành khóa luận này. Qua quá trình làm khóa luận, em đã học được rất nhiều điều.

Em xin cảm ơn quý thầy cô Khoa Công nghệ Thông tin Kinh doanh, Trường Công nghệ và Thiết kế, đã truyền đạt kiến thức cho em trong những năm học tại trường; những kiến thức đó là nền tảng để em thực hiện đề tài. Em cũng xin cảm ơn gia đình và bạn bè đã luôn tin tưởng, động viên và tạo điều kiện cho em trong thời gian làm khóa luận.

Nhiều kiến thức về kỹ thuật dữ liệu và về nghiệp vụ vận hành chuỗi F&B em phải tự tìm hiểu từ đầu, kinh nghiệm thực tế còn ít, nên khóa luận khó tránh khỏi thiếu sót. Em rất mong nhận được những góp ý quý báu của quý thầy cô để hoàn thiện hơn. Với em, khóa luận không chỉ là điều kiện tốt nghiệp mà còn là kết quả của sự cố gắng trong một khoảng thời gian ngắn.

Lê Cao Phúc

Tháng 10 năm 2026

TÓM TẮT

Các chuỗi đồ ăn nhanh bán hàng đồng thời tại quầy, qua ứng dụng riêng và qua các sàn giao đồ ăn, nên dữ liệu vận hành nằm rải rác ở máy bán hàng (POS), ứng dụng, báo cáo của sàn, sổ kho và máy chấm công, mỗi nơi một định dạng và một bộ mã riêng. Khi doanh thu hay lợi nhuận biến động, nhà quản lý thường chỉ thấy con số tổng hợp và khó phân biệt biến động bình thường với sự cố vận hành. Các nghiên cứu trước thường chỉ phân tích một nguồn dữ liệu cho một loại sự cố.

Theo phương pháp nghiên cứu khoa học thiết kế, khóa luận xây dựng một nền tảng tích hợp dữ liệu vận hành đa nguồn và truy vết nguyên nhân biến động doanh thu cho chuỗi đồ ăn nhanh. Do dữ liệu doanh nghiệp không được công khai, đề tài xây dựng bộ mô phỏng bảy hệ thống nguồn của một chuỗi 11 chi nhánh: dữ liệu nhất quán về nhân quả, có lỗi nhập liệu như thực tế, một số quy luật mua hàng được hiệu chỉnh từ dữ liệu giao dịch thật công khai, kèm hai tập kịch bản sự cố độc lập có đáp án. Dữ liệu được thu thập qua API, tệp xuất tự động và tệp tải lên, xử lý theo kiến trúc Medallion bằng DuckDB và dbt thành kho dữ liệu hình sao có kiểm thử. Năm bộ phát hiện dựa trên thống kê vững, kiểm định Poisson và luật đối soát, cùng một cây KPI, phát hiện và truy vết năm vấn đề vận hành; toàn bộ được điều phối bằng Airflow và phục vụ qua Metabase và Streamlit.

Đường ống đạt cả 158 kiểm thử dữ liệu, không thất lạc dòng nào giữa các tầng và xử lý một ngày dữ liệu mới trong khoảng 80 giây. Trên tập kiểm tra độc lập, chạy một lần với tham số đã chốt trước, hệ thống phát hiện 4 trên 6 sự cố với F1 0,52 và độ trễ trung vị 6 ngày, trong đó 3 sự cố được gán đúng nguyên nhân; trên tập phát triển là 5 trên 6 với F1 0,79. Chỉ theo dõi doanh thu phát hiện được nhiều nhất 1 sự cố. Biến động của ngày lễ, ngày mưa và điều chỉnh giá không bị nhầm thành sự cố; thất thoát kho với nhịp kiểm kê hai tuần là loại sự cố chưa phát hiện được.

Kết quả cho thấy việc đối chiếu chéo các nguồn dữ liệu vận hành phát hiện được những sự cố mà chỉ số doanh thu không thể hiện, và một chuỗi F&B quy mô vừa có thể xây dựng nền tảng như vậy bằng công cụ mã nguồn mở.

Từ khóa: kỹ thuật dữ liệu, kho dữ liệu, kiến trúc Medallion, chất lượng dữ liệu, phát hiện bất thường, truy vết nguyên nhân, F&B, dữ liệu mô phỏng.

ABSTRACT

Fast-food chains now sell over the counter, through their own ordering apps and on food delivery platforms, so their operational data is spread across point-of-sale (POS) systems, apps, platform reports, inventory records and time clocks, each with its own format and identifiers. When revenue or profit changes, managers usually see only aggregate figures and cannot tell a normal fluctuation from an operational problem. Previous studies typically analyse a single data source for a single type of incident.

Following a design science approach, this thesis builds a platform that integrates multi-source operational data and traces the causes of revenue changes in a fast-food chain. Because real operational data is not publicly available, a simulator of seven source systems was built for a chain of 11 branches. It produces causally consistent data with realistic entry errors, partly calibrated on public transaction data, and injects incidents with known ground truth into two independent scenario sets. Data collected through APIs, scheduled exports and uploads is processed in a Medallion architecture with DuckDB and dbt into a tested star-schema warehouse. Five detectors based on robust statistics, Poisson tests and reconciliation rules, together with a KPI tree, detect and explain five operational problems; the pipeline is orchestrated with Airflow and served through Metabase and Streamlit.

The pipeline passes all 158 data tests, loses no rows between layers and processes a new day of data in about 80 seconds. On the independent test set, evaluated once with parameters fixed in advance, the system detects four of six incidents with an F1 score of 0.52 and a median delay of six days, and assigns the correct cause to three of them; on the development set it detects five of six with an F1 score of 0.79. Monitoring revenue alone detects at most one incident. Holidays, rain and price changes are not mistaken for incidents; inventory theft remains undetected under a two-week stock-count cycle. Cross-checking operational sources thus reveals incidents that revenue figures hide, using only open-source tools.

Keywords: data engineering, data warehouse, Medallion architecture, data quality, anomaly detection, root cause analysis, food and beverage, synthetic data.

MỤC LỤC

LỜI CAM ĐOAN i
LỜI CẢM ƠN ii
TÓM TẮT iii
ABSTRACT iv
DANH MỤC TỪ VIẾT TẮT x
DANH MỤC BẢNG xi
DANH MỤC HÌNH xiii
CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI 1
1.1. Bối cảnh và lý do chọn đề tài 1
1.2. Phát biểu vấn đề 2
1.3. Câu hỏi nghiên cứu 3
1.4. Mục tiêu nghiên cứu 3
1.4.1. Mục tiêu tổng quát 3
1.4.2. Mục tiêu cụ thể 3
1.5. Đối tượng và phạm vi nghiên cứu 4
1.5.1. Đối tượng nghiên cứu 4
1.5.2. Phạm vi nghiên cứu 4
1.6. Phương pháp nghiên cứu 5
1.7. Đóng góp của đề tài 6
1.8. Bố cục khóa luận 6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN 7
2.1. Nghiệp vụ vận hành chuỗi đồ ăn nhanh và các chỉ số then chốt 7
2.1.1. Bán hàng đa kênh và đối soát với sàn giao đồ ăn 7
2.1.2. Giá vốn hàng bán và chênh lệch thực tế – lý thuyết 7
2.1.3. Chi phí và hiệu suất nhân công 8
2.1.4. Tồn kho, kiểm kê và thất thoát 9
2.1.5. Gian lận tại quầy thu ngân 9
2.1.6. Nguyên tắc phân tích dữ liệu vận hành F&B 9
2.2. Kiến trúc dữ liệu cho phân tích 10
2.2.1. Kho dữ liệu, hồ dữ liệu và lakehouse 10
2.2.2. ELT và kiến trúc Medallion 10
2.2.3. Thu thập dữ liệu, nạp tăng dần và tính lũy đẳng 11

2.3. Mô hình hóa dữ liệu chiều 11
2.3.1. Bảng sự kiện, bảng chiều và lược đồ hình sao 11
2.3.2. Chiều thay đổi chậm 11
2.4. Chất lượng dữ liệu 12
2.4.1. Các chiều chất lượng dữ liệu 12
2.4.2. Khám phá dữ liệu, kiểm thử, cách ly và phả hệ 13
2.4.3. Giải quyết định danh thực thể 13
2.5. Phát hiện bất thường và truy vết nguyên nhân 14
2.5.1. Phân loại bất thường và phương pháp thống kê vững 14
2.5.2. Luật nghiệp vụ và kiểm định trên số đếm 14
2.5.3. Phân rã chỉ số và cây KPI 15
2.5.4. Đánh giá bộ phát hiện 15
2.6. Dữ liệu mô phỏng trong nghiên cứu 16
2.7. Công nghệ sử dụng 16
2.8. Các nghiên cứu liên quan 17
2.9. Khoảng trống nghiên cứu và tiểu kết chương 19
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG 20
3.1. Phân tích yêu cầu 20
3.1.1. Từ câu hỏi nghiên cứu đến thiết kế 20
3.1.2. Yêu cầu chức năng và phi chức năng 21
3.1.3. Ca sử dụng 22
3.2. Kiến trúc tổng thể 23
3.3. Thiết kế bộ mô phỏng dữ liệu nguồn 25
3.3.1. Nguyên lý “một thế giới, nhiều góc nhìn” 25
3.3.2. Mô hình nhu cầu và chuỗi nhân quả vận hành 26
3.3.3. Mô hình lỗi của dữ liệu nguồn 29
3.3.4. Kịch bản sự cố và tập đánh giá 30
3.3.5. Hiệu chỉnh từ dữ liệu giao dịch thật công khai và giới hạn 31
3.4. Thiết kế đường ống dữ liệu 32
3.4.1. Tầng thu thập 33
3.4.2. Tầng Bronze 34
3.4.3. Tầng Silver và giải quyết định danh 35
3.5. Thiết kế kho dữ liệu 36
3.5.1. Bảng sự kiện và ma trận bus 36

3.5.2. Bảng chiều và chiều thay đổi chậm 37
3.5.3. Chiến lược cập nhật kho 38
3.6. Thiết kế kiểm soát chất lượng dữ liệu 39
3.7. Thiết kế lớp phân tích 40
3.7.1. Các chỉ số vận hành 40
3.7.2. Mức kỳ vọng và cây KPI truy vết nguyên nhân 41
3.7.3. Thiết kế các bộ phát hiện 43
3.8. Thiết kế ứng dụng, kho phục vụ và điều phối 44
3.8.1. Ứng dụng và truy vết về dữ liệu gốc 44
3.8.2. Kho phục vụ và công cụ BI 45
3.8.3. Điều phối 45
3.9. Tiểu kết chương 46
CHƯƠNG 4. HIỆN THỰC HỆ THỐNG 47
4.1. Môi trường và cấu trúc mã nguồn 47
4.2. Hiện thực bộ mô phỏng 47
4.2.1. Tổ chức chương trình và sinh dữ liệu tăng dần 47
4.2.2. Dữ liệu nguồn được tạo ra 48
4.2.3. Kiểm chứng bộ mô phỏng 49
4.3. Hiện thực tầng thu thập và Bronze 51
4.3.1. Kênh thu thập và hợp đồng dữ liệu 51
4.3.2. API nguồn và bộ kết nối 52
4.3.3. Nạp tầng Bronze 53
4.4. Khám phá dữ liệu thô 55
4.4.1. Hạt dữ liệu và hồ sơ từng nguồn 55
4.4.2. Phân phối làm căn cứ cho ngưỡng làm sạch 57
4.5. Hiện thực tầng Silver 58
4.5.1. Tổ chức dự án dbt 58
4.5.2. Xử lý lỗi dữ liệu và giải quyết định danh 58
4.5.3. Bảo toàn số dòng 59
4.6. Hiện thực tầng Gold 60
4.6.1. Bảng chiều, bảng sự kiện và bảng chỉ số 60
4.6.2. Kiểm thử 61
4.7. Khám phá dữ liệu đã làm sạch 62
4.8. Hiện thực các bộ phát hiện và đề xuất xử lý 65

4.9. Kho phục vụ và báo cáo kinh doanh 66
4.10. Ứng dụng 67
4.10.1. Tổ chức ứng dụng 67
4.10.2. Các trang phân tích vận hành 68
4.10.3. Các trang dữ liệu và kiểm chứng 70
4.11. Điều phối và vận hành tăng dần 72
4.11.1. Đóng gói và triển khai 72
4.11.2. Hai DAG và cơ chế kích hoạt theo dữ liệu 73
4.11.3. Một lượt chạy với dữ liệu ngày mới 74
4.12. Tiểu kết chương 74
CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ 75
5.1. Thiết lập thực nghiệm 75
5.1.1. Dữ liệu và quy trình đánh giá 75
5.1.2. Quy tắc đối chiếu và độ đo 75
5.2. Đánh giá đường ống và chất lượng dữ liệu (RQ1) 76
5.2.1. Phát hiện và xử lý lỗi dữ liệu 76
5.2.2. Đối soát giữa các tầng và hiệu năng 77
5.2.3. Độ bền trước dữ liệu bất thường và sự cố nguồn 78
5.3. Đánh giá các bộ phát hiện (RQ2) 79
5.3.1. Kết quả tổng hợp 79
5.3.2. Kết quả theo từng bộ phát hiện 81
5.3.3. Phân tích lỗi 82
5.4. Đánh giá khả năng truy vết nguyên nhân (RQ3) 84
5.4.1. Ví dụ truy vết: thiếu nhân sự ở CN2 84
5.4.2. Chỉ đúng nguyên nhân và phân biệt với biến động bình thường 85
5.5. Phân tích độ nhạy và so sánh với phương án cơ sở 86
5.5.1. Độ nhạy theo ngưỡng điểm cảnh báo 86
5.5.2. So sánh với phương án cơ sở 87
5.5.3. Độ nhạy theo cách tính mức kỳ vọng 88
5.6. Các phát hiện kinh doanh 90
5.6.1. Cơ cấu chi phí theo hạng chi nhánh 90
5.6.2. Hiệu quả theo kênh, ảnh hưởng của mưa và điều chỉnh giá 91
5.6.3. Ma trận thực đơn 92
5.6.4. Thiệt hại ước tính của các sự cố được phát hiện 92

5.7. Thảo luận 93
5.7.1. Trả lời các câu hỏi nghiên cứu 93
5.7.2. So sánh với các nghiên cứu liên quan 94
5.7.3. Các yếu tố ảnh hưởng đến tính hợp lệ 95
5.8. Tiểu kết chương 95
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 96
6.1. Kết quả đạt được 96
6.2. Hàm ý quản trị 97
6.3. Điều chỉnh so với đề cương 98
6.4. Hạn chế 98
6.5. Hướng phát triển 99
TÀI LIỆU THAM KHẢO 101
PHỤ LỤC 108
Phụ lục A. Mã nguồn và tài liệu của hệ thống 108

DANH MỤC TỪ VIẾT TẮT

1. API: Application Programming Interface – Giao diện lập trình ứng dụng
2. AOV: Average Order Value – Giá trị trung bình mỗi đơn hàng
3. AvT: Actual versus Theoretical – Chênh lệch giá vốn thực tế so với định mức
4. BI: Business Intelligence – Báo cáo, phân tích kinh doanh
5. COGS: Cost of Goods Sold – Giá vốn hàng bán
6. CSV: Comma-Separated Values – Tệp văn bản phân tách bằng dấu phẩy
7. DAG: Directed Acyclic Graph – Đồ thị có hướng không chu trình
8. ELT: Extract – Load – Transform – Trích xuất, nạp, biến đổi
9. ETL: Extract – Transform – Load – Trích xuất, biến đổi, nạp
10. F&B: Food and Beverage – Ngành ăn uống
11. FIFO: First In, First Out – Nhập trước, xuất trước
12. JSON: JavaScript Object Notation – Định dạng dữ liệu JSON
13. KPI: Key Performance Indicator – Chỉ số hiệu suất then chốt
14. MAD: Median Absolute Deviation – Độ lệch tuyệt đối trung vị
15. OPLH: Orders per Labor Hour – Số đơn trên mỗi giờ công
16. POS: Point of Sale – Hệ thống bán hàng tại quầy
17. RFM: Recency – Frequency – Monetary – Gần đây, tần suất, giá trị
18. RQ: Research Question – Câu hỏi nghiên cứu
19. SCD: Slowly Changing Dimension – Chiều thay đổi chậm
20. SPLH: Sales per Labor Hour – Doanh thu trên mỗi giờ công
21. SQL: Structured Query Language – Ngôn ngữ truy vấn có cấu trúc
22. UML: Unified Modeling Language – Ngôn ngữ mô hình hóa thống nhất
23. UTC: Coordinated Universal Time – Giờ phối hợp quốc tế

DANH MỤC BẢNG

Bảng 1.1. Năm vấn đề vận hành được nghiên cứu 2
Bảng 2.1. Các kiểu chiều thay đổi chậm phổ biến....12
Bảng 2.2. Các chiều chất lượng dữ liệu và ví dụ trong đề tài....12
Bảng 2.3. Lựa chọn công nghệ và lý do....17
Bảng 2.4. Tổng hợp các nghiên cứu liên quan....18
Bảng 3.1. Liên hệ giữa câu hỏi nghiên cứu, giả thuyết thiết kế và cách kiểm chứng ..20
Bảng 3.2. Yêu cầu chức năng 21
Bảng 3.3. Yêu cầu phi chức năng 22
Bảng 3.4. Các hệ thống nguồn và phần sự kiện mỗi hệ thống quan sát được 25
Bảng 3.5. Tham số chính của mô hình nhu cầu 26
Bảng 3.6. Các lỗi dữ liệu đặc trưng của từng hệ thống nguồn....29
Bảng 3.7. Hai tập kịch bản sự cố 30
Bảng 3.8. Kết quả hiệu chỉnh tham số từ dữ liệu giao dịch thật....32
Bảng 3.9. Quy tắc làm sạch và chuẩn hóa chính ở tầng Silver....35
Bảng 3.10. Các hệ thống định danh và cách giải quyết 36
Bảng 3.11. Các bảng sự kiện: hạt dữ liệu, chiều liên kết và đo lường....36
Bảng 3.12. Các nhóm kiểm thử chất lượng dữ liệu 39
Bảng 3.13. Định nghĩa các chỉ số vận hành trong kho dữ liệu 40
Bảng 3.14. Thiết kế năm bộ phát hiện 43
Bảng 4.1. Môi trường hiện thực....47
Bảng 4.2. Khối lượng dữ liệu nguồn của tập phát triển (182 ngày, 11 chi nhánh)....48
Bảng 4.3. Tác động đo được của các kịch bản sự cố trên hai tập 50
Bảng 4.4. Các biến động bình thường đo được (ngày không có sự cố)....50
Bảng 4.5. Kênh thu thập của từng nguồn....51
Bảng 4.6. Một lượt kéo bảy ngày kinh doanh 23–29/09/2024 qua API (môi trường vận hành, chạy trong Airflow) 53
Bảng 4.7. Hồ sơ dữ liệu thô của các nguồn chính (tập phát triển, 183 ngày)....56
Bảng 4.8. Đối soát số dòng giữa Bronze và Silver (tập phát triển, 183 ngày) 59
Bảng 4.9. Các bảng chiều và sự kiện của tầng Gold (tập phát triển, 183 ngày)....60
Bảng 4.10. Từ khám phá dữ liệu đến lựa chọn phương pháp phân tích 63
Bảng 4.11. Tham số của bộ phát hiện và lý do chọn (chỉ trên tập phát triển) 65
Bảng 4.12. Một lượt đường ống kích hoạt theo dữ liệu mới (môi trường vận hành, bảy ngày, nhật ký `ops.pipeline_runs`)....74

Bảng 5.1. Lỗi dữ liệu được phát hiện và xử lý ở tầng Silver 76
Bảng 5.2. Kết quả kiểm thử và kiểm tra chất lượng 77
Bảng 5.3. Thời gian chạy của từng bước 77
Bảng 5.4. Kết quả xử lý 11 tình huống dữ liệu bất thường cài cùng lúc (môi trường vận hành, 17/10/2026) 78
Bảng 5.5. Kết quả của phương pháp đề xuất trên hai tập (ngưỡng điểm 3,5) 79
Bảng 5.6. Kết quả theo từng loại sự cố 81
Bảng 5.7. Các sự cố bị bỏ sót hoặc gán sai nguyên nhân 82
Bảng 5.8. Truy vết CN2, tuần 06/05–12/05/2024 (tập phát triển) 84
Bảng 5.9. Cảnh báo trong các tuần có biến động bình thường lớn 85
Bảng 5.10. So sánh với các phương án cơ sở 87
Bảng 5.11. Thiệt hại ước tính từ kho dữ liệu cho các sự cố được phát hiện (tập phát triển) 92
Bảng A.1. Đường dẫn tới mã nguồn và tài liệu của hệ thống 108

DANH MỤC HÌNH

Hình 1.1. Quy trình nghiên cứu của khóa luận 6
Hình 3.1. Sơ đồ ca sử dụng của hệ thống 23
Hình 3.2. Kiến trúc tổng thể của nền tảng 24
Hình 3.3. Chuỗi nhân quả vận hành trong bộ mô phỏng 28
Hình 3.4. Sơ đồ tuần tự của bộ kết nối khi kéo dữ liệu qua API nguồn 34
Hình 3.5. Sơ đồ quan hệ thực thể của kho dữ liệu (lược đồ hình sao), sinh từ siêu dữ liệu dbt 38
Hình 3.6. Cây KPI dùng để truy vết biến động doanh thu và lợi nhuận 42
Hình 3.7. Hai đồ thị tác vụ: hệ thống nguồn và đường ống dữ liệu kích hoạt theo dữ liệu mới 46
Hình 4.1. Ví dụ dữ liệu thô của các hệ thống nguồn, trích nguyên văn từ tệp của tập phát triển 49
Hình 4.2. Trang Tải tệp lên sau khi gửi chín tệp mẫu (môi trường vận hành) 52
Hình 4.3. Truy vấn trên tầng Bronze: hai phiên bản phần mềm POS ghi tổng tiền và thời gian theo hai cách (tập phát triển) 55
Hình 4.4. Phân phối dùng làm căn cứ cho hai ngưỡng làm sạch, trên dữ liệu thô của tập phát triển 57
Hình 4.5. Phả hệ dữ liệu của bảng fact_order, sinh từ siêu dữ liệu dbt 61
Hình 4.6. Một số phân phối của dữ liệu đã làm sạch (tập phát triển, 182 ngày) 63
Hình 4.7. Trang Tổng quan: dashboard Metabase trên kho phục vụ, nhúng vào ứng dụng (tập phát triển, toàn chuỗi) 67
Hình 4.8. Trang chủ Sơ đồ hệ thống với số liệu của từng tầng (tập phát triển) 68
Hình 4.9. Trang Trung tâm cảnh báo (tập phát triển) 69
Hình 4.10. Phần kết luận và đề xuất xử lý của trang Truy vết nguyên nhân: CN2, tuần 06/05/2024 (tập phát triển) 70
Hình 4.11. Trang Vận hành hằng ngày sau khi đưa vào bảy ngày kinh doanh mới (môi trường vận hành) 71
Hình 4.12. Trang Bộ mô phỏng: sự thật của một ngày đặt cạnh những gì các hệ thống nguồn ghi lại (CN2, 11/05/2024, tập phát triển) 72
Hình 4.13. Sơ đồ triển khai của nền tảng trên Docker Compose 73
Hình 5.1. Cảnh báo của bộ phát hiện đặt cạnh thời gian các sự cố, theo chi nhánh × tuần (ngưỡng điểm 3,5) 80
Hình 5.2. Tín hiệu của bốn bộ phát hiện quanh sự cố trên tập phát triển 82
Hình 5.3. Điểm cao nhất của nguyên nhân đúng trong cửa sổ từng sự cố, so với ngưỡng cảnh báo và mức theo dõi 83

Hình 5.4. Doanh thu thuần và số ca bếp tối của CN2 so với mức kỳ vọng; vùng tô là thời gian sự cố S4 85

Hình 5.5. Precision, recall theo tuần và F1 trên tập phát triển theo ngưỡng điểm cảnh báo; hai dòng phía trên là số sự cố bắt được và số báo động giả 87

Hình 5.6. Precision, recall theo tuần và F1 của phương pháp đề xuất và hai phương án cơ sở 88

Hình 5.7. F1 và số báo động giả theo cách tính mức kỳ vọng (tập phát triển, ngưỡng điểm 3,5) 89

Hình 5.8. Điểm bằng chứng P1a theo luật đối soát và theo điểm z khi sai lệch hoa hồng kéo dài 17 tuần (giả định trên dữ liệu CN4) 90

Hình 5.9. Labor% và số đơn mỗi giờ công của từng chi nhánh × tuần, theo hạng chi nhánh (tập phát triển) 91

Hình 5.10. Ma trận thực đơn: tỷ trọng số lượng bán và lãi gộp mỗi phần của 28 món (tập phát triển) 92

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

1.1. Bối cảnh và lý do chọn đề tài

Ngành ăn uống (F&B), đặc biệt là mô hình nhà hàng phục vụ nhanh (Quick-Service Restaurant – QSR), có tần suất giao dịch cao, giá trị mỗi đơn nhỏ, nguyên liệu nhanh hỏng và chịu ảnh hưởng mạnh của cách vận hành. Chỉ cần thiếu một nhân viên bếp ca tối, một lô nguyên liệu tươi bị hỏng hay một sai lệch nhỏ trong cách sàn giao đồ ăn tính phí, lợi nhuận của chi nhánh đã có thể giảm mà người quản lý khó nhận ra. Thị trường ăn uống Việt Nam lớn và cạnh tranh gay gắt: theo khảo sát hơn 4.000 nhà hàng của iPOS.vn (2025), doanh thu ngành năm 2024 đạt gần 689.000 tỷ đồng, tăng 16,6%, với khoảng 323.000 cửa hàng, nhưng chỉ khoảng 14,7% doanh nghiệp ghi nhận tăng trưởng. Kênh giao đồ ăn trực tuyến đạt khoảng 1,8 tỷ USD năm 2024, tăng 26%, chia gần đều cho GrabFood và ShopeeFood (Momentum Works, 2025); người tiêu dùng trẻ đã quen đặt món qua ứng dụng (Vu et al., 2023), trong khi hoa hồng cao của các sàn tạo áp lực lớn lên biên lợi nhuận (Feldman et al., 2023; Li et al., 2020). Trong bối cảnh đó, nhận ra sớm nguyên nhân làm doanh thu và lợi nhuận suy giảm là một năng lực cạnh tranh.

Mô hình bán hàng đa kênh khiến dữ liệu vận hành nằm rải rác ở nhiều hệ thống: POS ghi từng hóa đơn tại quầy, ứng dụng riêng lưu đơn và khách hàng, sàn giao đồ ăn chỉ gửi báo cáo đối soát tổng hợp theo tuần, kho được quản lý bằng sổ nhập và phiếu kiểm kê thường ghi bằng Excel, nhân sự được theo dõi bằng máy chấm công. Các hệ thống này dùng những bộ mã khác nhau cho cùng một chi nhánh, nhân viên hay nguyên liệu, và không thống nhất về định dạng cũng như chất lượng dữ liệu. Vì vậy khi doanh thu một chi nhánh biến động, nhà quản lý thường chỉ thấy con số tổng hợp. Doanh thu giảm có thể là chuyện bình thường, như trời mưa hay kỳ nghỉ lễ vừa kết thúc, nhưng cũng có thể do chi nhánh thiếu người nên phải hủy đơn và bị tụt hạng trên sàn; lợi nhuận giảm khi doanh thu không đổi có thể do sàn tính sai hoa hồng, nguyên liệu hao hụt, hàng tồn bị thất thoát hoặc gian lận tại quầy. Tổng quan của Mariani et al. (2018) cũng cho thấy các nghiên cứu ứng dụng phân tích dữ liệu trong ngành nhà hàng, khách sạn còn rời rạc về phạm vi và hạn chế về phương pháp.

Từ thực tế đó, đề tài hướng tới một nền tảng tích hợp các nguồn dữ liệu không đồng nhất thành một kho dữ liệu sạch, nhất quán, rồi áp dụng các phương pháp phân

tích giải thích được để phát hiện sự cố và truy vết nguyên nhân biến động, thay vì dừng ở một bảng điều khiển doanh thu. Bài toán đòi hỏi kết hợp kỹ thuật dữ liệu (Data Engineering) để dựng hạ tầng tích hợp với phân tích dữ liệu (Data Analytics) để diễn giải con số theo nghiệp vụ. Vì những lý do trên, đề tài "Xây dựng nền tảng tích hợp và phân tích dữ liệu vận hành đa nguồn hỗ trợ truy vết nguyên nhân biến động doanh thu cho chuỗi F&B" được lựa chọn làm nội dung khóa luận.

1.2. Phát biểu vấn đề

Đề tài tập trung vào năm vấn đề vận hành phổ biến của chuỗi đồ ăn nhanh (Bảng 1.1). Điểm chung của chúng là không thể phát hiện chắc chắn nếu chỉ nhìn một nguồn dữ liệu; phải đối chiếu ít nhất hai nguồn với nhau.

Bảng 1.1. Năm vấn đề vận hành được nghiên cứu

Mã	Vấn đề vận hành	Biểu hiện và lý do khó phát hiện	Nguồn dữ liệu cần đối chiếu
P1	Sai lệch đối soát với sàn giao đồ ăn	Sàn tính hoa hồng cao hơn hợp đồng; hoặc đơn sàn không được nhập vào POS. Báo cáo sàn chỉ có số tổng theo tuần, không ghi tỷ lệ phí	Báo cáo đối soát GrabFood, ShopeeFood; POS; hợp đồng với sàn
P2	Hao hụt nguyên liệu bất thường	Giá vốn thực tế cao hơn giá vốn lý thuyết theo công thức; chỉ thấy khi đặt lượng nhập kho cạnh lượng bán	Sổ nhập kho; POS và ứng dụng; công thức món
P3	Nhân sự không khớp với tải đơn hàng	Thiếu người làm thời gian chuẩn bị tăng, khách bỏ về, cửa hàng hủy đơn, điểm trên sàn giảm, kéo doanh thu xuống nhiều tuần	Máy chấm công; POS, ứng dụng; báo cáo sàn
P4	Thất thoát hàng tồn kho	Tồn kiểm kê thấp hơn tồn sổ sách; chỉ lộ ra ở kỳ kiểm kê	Phiếu kiểm kê; sổ nhập kho; lượng bán và công thức
P5	Gian lận tại quầy thu ngân	Thu ngân thu tiền mặt rồi hủy hóa đơn; hóa đơn hủy lẫn vào số hủy hợp lệ	POS, gồm người thực hiện hủy; danh sách nhân viên

Nguồn: Tổng hợp từ các tài liệu ở mục 2.1

Bên cạnh năm vấn đề trên, doanh thu còn biến động vì những lý do bình thường: cuối tuần, ngày lễ, ngày mưa, điều chỉnh giá bán. Một hệ thống truy vết tốt phải phân biệt được hai loại biến động này; nếu không, nó sẽ phát ra quá nhiều cảnh báo sai và mất giá trị sử dụng.

1.3. Câu hỏi nghiên cứu

- RQ1, về tích hợp dữ liệu: có thể tích hợp dữ liệu vận hành từ bảy hệ thống nguồn không đồng nhất về định dạng, mã định danh và chất lượng thành một kho dữ liệu nhất quán và kiểm chứng được hay không?
- RQ2, về phát hiện sự cố: các phương pháp thống kê và luật nghiệp vụ giải thích được phát hiện năm vấn đề P1–P5 chính xác đến mức nào, đặc biệt trên các kịch bản chưa từng được dùng để chọn ngưỡng?
- RQ3, về truy vết nguyên nhân: có thể truy một biến động doanh thu hoặc lợi nhuận về đúng nguyên nhân vận hành, đồng thời phân biệt với biến động bình thường do ngày trong tuần, ngày lễ, thời tiết và điều chỉnh giá hay không?

1.4. Mục tiêu nghiên cứu

1.4.1. Mục tiêu tổng quát

Xây dựng một nền tảng dữ liệu hoàn chỉnh, đi từ dữ liệu thô của các hệ thống nguồn đến kho dữ liệu và phân tích, có khả năng tích hợp dữ liệu vận hành đa nguồn của chuỗi F&B, phát hiện sự cố vận hành và hỗ trợ truy vết nguyên nhân biến động doanh thu.

1.4.2. Mục tiêu cụ thể

1. Xây dựng bộ dữ liệu mô phỏng cho một chuỗi đồ ăn nhanh, trong đó các nguồn nhất quán về nhân quả, mang lỗi dữ liệu đặc trưng của từng hệ thống và có đáp án cho mọi sự cố được đưa vào.
2. Xây dựng đường ống dữ liệu theo kiến trúc Medallion: thu thập và nạp tăng dần, làm sạch, chuẩn hóa, giải quyết định danh và cách ly dòng lỗi.
3. Thiết kế kho dữ liệu theo mô hình hóa chiều với lược đồ hình sao, có kiểm thử chất lượng tự động giữa các tầng.

4. Xây dựng bộ chỉ số vận hành theo chuẩn ngành F&B và cây KPI để truy vết nguyên nhân biến động.
5. Xây dựng năm bộ phát hiện cho P1–P5 và đánh giá định lượng trên một tập kịch bản độc lập.
6. Xây dựng ứng dụng cho người dùng nghiệp vụ, lớp báo cáo kinh doanh và cơ chế vận hành tự động hằng ngày.

1.5. Đối tượng và phạm vi nghiên cứu

1.5.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là dữ liệu vận hành đa nguồn của chuỗi nhà hàng phục vụ nhanh cùng các phương pháp tích hợp, mô hình hóa và phân tích dữ liệu đó để phát hiện sự cố, truy vết nguyên nhân biến động doanh thu. Do dữ liệu vận hành của doanh nghiệp F&B mang tính nhạy cảm thương mại và không được công khai, đề tài khảo sát một chuỗi giả định tên Fast&Fat như một trường hợp điển hình (representative case study): 11 chi nhánh tại Thành phố Hồ Chí Minh chia thành ba hạng theo quy mô, bán qua bốn kênh, thực đơn 28 món, 22 loại nguyên liệu và 145 nhân viên làm theo ca. Dữ liệu được xây dựng bằng mô phỏng có neo thực tế (reality-anchored simulation): tham số nền như giá món, tỷ lệ giá vốn, lương giờ lấy theo mức phổ biến trên thị trường; một số quy luật mua hàng được hiệu chỉnh từ dữ liệu giao dịch thật công khai (mục 3.3.5); các giao dịch được sinh theo đúng quy luật vận hành, trong đó nhân sự quyết định tải bếp, tải bếp quyết định thời gian chuẩn bị, tỷ lệ hủy đơn và thứ hạng trên sàn. Cách tiếp cận này cho phép đưa vào các kịch bản sự cố có đáp án biết trước để đánh giá định lượng, điều gần như không làm được với dữ liệu thật.

1.5.2. Phạm vi nghiên cứu

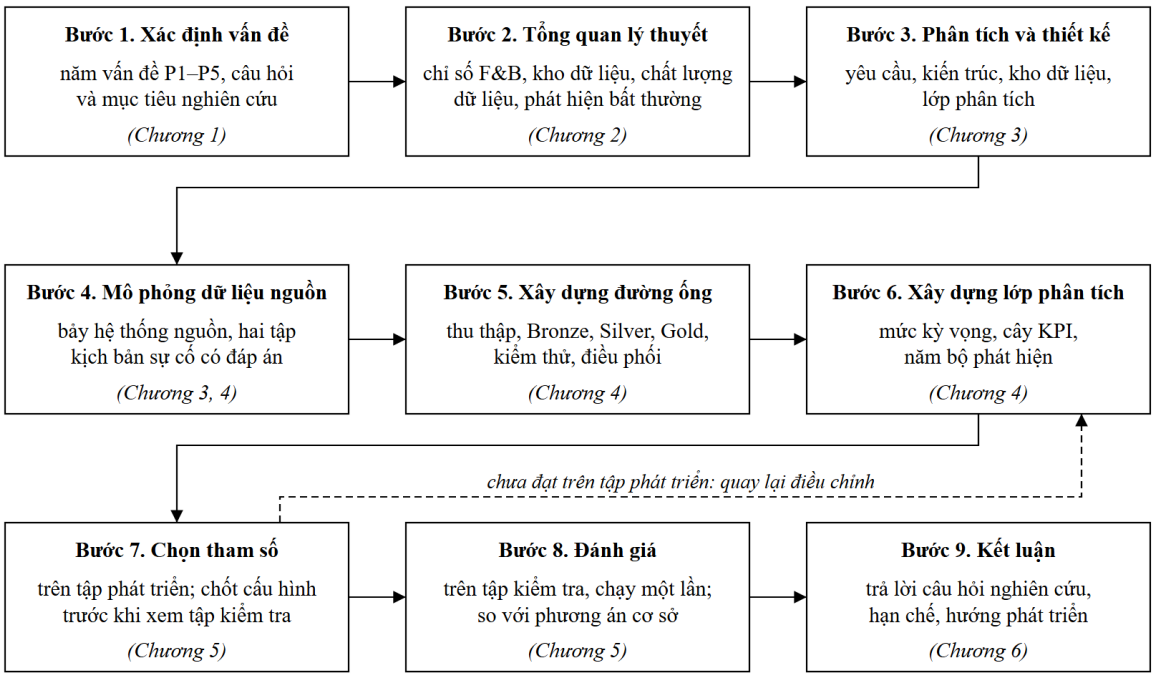
Về dữ liệu, đề tài dùng 26 tuần từ 11/03/2024 đến 08/09/2024 của 11 chi nhánh, khoảng 435 nghìn đơn được phục vụ ở tập dữ liệu chính, từ bảy nhóm hệ thống nguồn; hệ thống được thiết kế để tiếp tục nhận dữ liệu mới theo ngày. Về kỹ thuật, dữ liệu được xử lý theo lô hằng ngày vì chuỗi F&B ra quyết định theo nhịp ngày và tuần; quy mô hàng trăm megabyte nên không dùng nền tảng dữ liệu lớn phân tán. Dữ liệu đến bằng ba kênh như ngoài thực tế là kéo qua API, tệp xuất tự động và tệp do người gửi, trong đó API của phần mềm nguồn là dịch vụ giả lập. Phát hiện sự cố dựa trên thống kê và

luật nghiệp vụ giải thích được; đề tài không xây dựng mô hình dự báo nhu cầu, không gửi cảnh báo qua kênh nhắn tin và không triển khai trên hạ tầng đám mây. Toàn bộ hệ thống được đóng gói bằng Docker Compose và chạy trên một máy.

1.6. Phương pháp nghiên cứu

Khóa luận tiếp cận theo hướng nghiên cứu khoa học thiết kế (Design Science Research) trong hệ thống thông tin (Hevner et al., 2004): sản phẩm nghiên cứu là một nền tảng giải quyết một vấn đề thực tiễn đã xác định và phải được đánh giá bằng thực nghiệm có kiểm soát. Quy trình đi theo sáu hoạt động của Peffers et al. (2007): xác định vấn đề, xác định mục tiêu của giải pháp, thiết kế và phát triển, trình diễn, đánh giá và truyền đạt kết quả. Đề tài kết hợp phương pháp nghiên cứu tài liệu để tổng hợp lý thuyết; phân tích nghiệp vụ để đi từ vấn đề vận hành đến dữ liệu cần có và đầu ra cho người dùng; phân tích khám phá dữ liệu để lập hồ sơ các nguồn và làm căn cứ cho quy tắc làm sạch, phương pháp phân tích; mô phỏng có kiểm soát để sinh dữ liệu nguồn và kịch bản sự cố có đáp án; và thực nghiệm với hai tập kịch bản độc lập. Tập phát triển dùng để xây dựng và chọn tham số; tập kiểm tra chỉ được chạy một lần để đánh giá cuối cùng bằng precision, recall và F1, nhằm tránh hiện tượng quá khớp.

Hình 1.1 tóm tắt quy trình nghiên cứu gồm chín bước. Ba bước đầu xác định vấn đề, tổng hợp lý thuyết và thiết kế; ba bước tiếp theo xây dựng bộ mô phỏng, đường ống dữ liệu và lớp phân tích. Bước 6 và 7 được lặp trên tập phát triển cho tới khi chọn xong phương pháp và tham số; sau khi cấu hình được chốt, bước 8 chạy trên tập kiểm tra đúng một lần và kết quả được báo cáo nguyên trạng.



Nguồn: Phát triển từ Peffers et al. (2007)

Hình 1.1. Quy trình nghiên cứu của khóa luận

1.7. Đóng góp của đề tài

Về khoa học, khóa luận có ba đóng góp: một bộ mô phỏng dữ liệu vận hành đa nguồn nhất quán về nhân quả, kèm lỗi dữ liệu đặc trưng và hai tập kịch bản sự cố có đáp án, dùng lại được để kiểm thử các phương pháp khác; một đường ống và kho dữ liệu có kiểm chứng giữa các tầng; và các bộ phát hiện cùng cây KPI giải thích được, đánh giá trên tập kiểm tra độc lập. Về thực tiễn, nền tảng cho thấy chuỗi F&B quy mô vừa có thể xây dựng hệ thống như vậy bằng công cụ mã nguồn mở trên một máy tính cá nhân.

1.8. Bố cục khóa luận

Ngoài Chương 1, khóa luận gồm Chương 2 về cơ sở lý thuyết và các nghiên cứu liên quan, Chương 3 về phân tích và thiết kế, Chương 4 về hiện thực và kiểm chứng từng thành phần, Chương 5 về thực nghiệm, đánh giá và các phát hiện kinh doanh, và Chương 6 về kết luận, hàm ý quản trị, hạn chế và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

Chương này trình bày cơ sở cho khóa luận theo hai mạch. Mạch nghiệp vụ (mục 2.1) giải thích các chỉ số quản trị vận hành của chuỗi F&B, từ đó xác định dữ liệu cần thu thập và dấu vết mà mỗi vấn đề để lại. Mạch kỹ thuật (mục 2.2 đến 2.7) trình bày kiến trúc dữ liệu, mô hình hóa chiều, chất lượng dữ liệu, phát hiện bất thường, dữ liệu mô phỏng và công nghệ được chọn. Mục 2.8 tổng quan các nghiên cứu liên quan; mục 2.9 nêu khoảng trống nghiên cứu.

2.1. Nghiệp vụ vận hành chuỗi đồ ăn nhanh và các chỉ số then chốt

2.1.1. Bán hàng đa kênh và đối soát với sàn giao đồ ăn

Một chuỗi đồ ăn nhanh thường bán qua bốn kênh: tại quầy qua hệ thống POS, ứng dụng đặt hàng riêng, và các sàn giao đồ ăn như GrabFood, ShopeeFood. Với kênh sàn, tiền khách trả đi qua sàn; mỗi tuần sàn gửi cho cửa hàng một báo cáo đối soát (settlement report) gồm doanh thu món, số đơn, phí hoa hồng, khuyến mãi, quảng cáo và số tiền thực nhận. Quy trình này có hai rủi ro. Thứ nhất, hoa hồng thực tế có thể lệch so với hợp đồng, và vì báo cáo chỉ ghi số tiền chứ không ghi tỷ lệ, sai lệch chỉ lộ ra khi tính lại tỷ lệ hiệu dụng rồi so với hợp đồng. Rủi ro này đáng kể vì hoa hồng là khoản chi lớn nhất của kênh sàn và là nguồn xung đột chính giữa nhà hàng với nền tảng (Feldman et al., 2023; Li et al., 2020). Thứ hai, khi nhân viên phải nhập tay đơn sàn vào POS, đơn bị bỏ sót làm doanh thu nội bộ thiếu so với báo cáo của sàn trong khi nguyên liệu vẫn bị tiêu hao; chỉ đối chiếu số đơn giữa hai nguồn mới phát hiện được.

2.1.2. Giá vốn hàng bán và chênh lệch thực tế – lý thuyết

Giá vốn hàng bán (Cost of Goods Sold – COGS) là giá trị nguyên liệu đã tiêu hao để tạo ra doanh thu. Chỉ số quản trị phổ biến nhất là tỷ lệ giá vốn trên doanh thu:

$$\text{COGS\%} = \frac{\text{Giá vốn hàng bán}}{\text{Doanh thu thuần}} \times 100\% \qquad (2.1)$$

Để biết giá vốn tăng vì sao, các tài liệu về kiểm soát chi phí F&B phân biệt hai loại giá vốn (Dopson & Hayes, 2019). *Giá vốn lý thuyết* là giá vốn lẽ ra phải có nếu mọi món được chế biến đúng định mức:

$$\text{Giá vốn lý thuyết} = \sum_i q_i \sum_j a_{ij}\, p_j \qquad (2.2)$$

trong đó q_i là số lượng bán của món i trong kỳ, a_{ij} là định mức nguyên liệu j cho một phần món i và p_j là đơn giá của nguyên liệu j. *Giá vốn thực tế* được tính từ biến động kho trong một kỳ kiểm kê, quy ra giá trị:

$$\text{Giá vốn thực tế} = \text{Tồn đầu kỳ} + \text{Nhập trong kỳ} - \text{Tồn cuối kỳ} \qquad (2.3)$$

Chênh lệch giữa hai đại lượng, gọi là chênh lệch thực tế – lý thuyết (Actual versus Theoretical – AvT), đo phần nguyên liệu tiêu hao không tạo ra doanh thu: hư hỏng do bảo quản hoặc không xuất kho theo nguyên tắc nhập trước – xuất trước (FIFO), chế biến sai định lượng hoặc thất thoát. Hao hụt phát sinh ở mọi khâu từ nhập, bảo quản, sơ chế đến phục vụ, nên phải đo theo từng khâu mới tìm được biện pháp phòng ngừa (Papargyropoulou et al., 2016). Không có ngưỡng COGS% chung cho mọi nhà hàng, vì tỷ lệ này phụ thuộc mô hình kinh doanh và cơ cấu món (Dopson & Hayes, 2019); khóa luận vì vậy so COGS% và AvT của một chi nhánh với lịch sử của nó và với các chi nhánh cùng hạng.

2.1.3. Chi phí và hiệu suất nhân công

Nhân công là khoản chi lớn thứ hai sau giá vốn. Hai nhóm chỉ số thường dùng là tỷ lệ chi phí nhân công trên doanh thu và năng suất theo giờ công, trong đó SPLH (Sales per Labor Hour) là doanh thu và OPLH (Orders per Labor Hour) là số đơn trên mỗi giờ công:

$$\text{Labor\%} = \frac{\text{Chi phí nhân công}}{\text{Doanh thu thuần}} \times 100\% \qquad (2.4)$$

$$\text{SPLH} = \frac{\text{Doanh thu}}{\text{Tổng giờ công}}, \qquad \text{OPLH} = \frac{\text{Số đơn}}{\text{Tổng giờ công}} \qquad (2.5)$$

Nhu cầu nhà hàng dao động mạnh theo giờ, nên lịch phân ca phải được lập từ nhu cầu theo khung giờ (Thompson, 1998) và quản trị doanh thu nhà hàng lấy công suất theo khung giờ làm đối tượng điều chỉnh chính (Kimes, 1999). Khi ca đông thiếu người, thời gian chuẩn bị kéo dài, khách bỏ về, cửa hàng hủy đơn trực tuyến và điểm đánh giá trên sàn giảm; vì sàn ưu tiên cửa hàng có điểm cao, thiệt hại doanh thu có thể kéo dài nhiều tuần sau khi tình trạng thiếu người đã kết thúc. Mức Labor% hợp lý phụ thuộc quy mô cửa hàng (Dopson & Hayes, 2019): chi nhánh nhỏ vẫn phải duy trì số người tối thiểu

mỗi ca nên Labor% cao hơn mà không có nghĩa là thừa người, do đó so sánh phải đặt trong nhóm cùng hạng.

2.1.4. Tồn kho, kiểm kê và thất thoát

Kiểm soát kho gồm kiểm soát hằng ngày, như theo dõi lượng nhập và áp dụng FIFO, và kiểm kê định kỳ, tức đếm tồn thực tế rồi so với tồn sổ sách tính từ lần kiểm kê trước cộng nhập trừ tiêu hao lý thuyết. Chênh lệch âm vượt mức sai số đếm tay là dấu hiệu thất thoát (inventory shrinkage):

$$\text{Tỷ lệ chênh lệch kiểm kê} = \frac{\text{Tồn kiểm kê} - \text{Tồn sổ sách}}{\text{Tồn sổ sách}} \tag{2.6}$$

Sai lệch tồn kho phổ biến hơn nhiều so với cảm nhận của nhà quản lý: khoảng 65% trong gần 370.000 bản ghi tồn kho của 37 cửa hàng bán lẻ không khớp thực tế, và tần suất kiểm kê là một yếu tố làm giảm sai lệch (DeHoratius & Raman, 2008); thất thoát nhỏ không được ghi nhận, khi tích lũy, đủ gây thiếu hàng nghiêm trọng (Kang & Gershwin, 2005). Khóa luận phân biệt hai vấn đề kho: P2 là hao hụt vượt định mức của hàng tươi giá thấp, thường do bảo quản và chế biến; P4 là thất thoát nguyên liệu giá trị cao, nơi động cơ lấy cắp lớn nhất. Cả hai được đánh giá theo kỳ kiểm kê.

2.1.5. Gian lận tại quầy thu ngân

Chức năng hủy hóa đơn (void) và hoàn tiền (refund) của POS có thể bị lạm dụng: thu ngân nhận tiền mặt, giao món, rồi hủy hóa đơn và giữ lại tiền. Doanh thu trên hệ thống giảm nhưng két không thiếu tiền, nên dấu hiệu chỉ nằm ở mẫu hình, đặc biệt là tỷ lệ hủy của một thu ngân cao bất thường so với đồng nghiệp cùng chi nhánh. Phát hiện gian lận bằng thống kê dựa trên việc so hành vi của một đối tượng với chính nó hoặc với các đối tượng tương tự, và kết quả chỉ là mức nghi vấn để con người kiểm tra tiếp (Bolton & Hand, 2002). Về dữ liệu, cần liên kết hóa đơn POS với danh sách nhân viên, trong khi mã nhân viên trên POS thường khác mã trên hệ thống chấm công.

2.1.6. Nguyên tắc phân tích dữ liệu vận hành F&B

Từ các đặc thù trên, khóa luận áp dụng bốn nguyên tắc phân tích xuyên suốt:

– Không kết luận từ tổng doanh thu; mọi chỉ số được tách theo thời gian, chi nhánh, kênh và món, và luôn đặt doanh thu cạnh chi phí.

– So sánh trong nhóm đồng nhất: một giá trị chỉ bất thường khi so với lịch sử của chính chi nhánh hoặc với các chi nhánh cùng hạng.
– Phân biệt biến động bình thường với sự cố: ngày lễ, thời tiết và điều chỉnh giá tác động lên nhiều chi nhánh cùng lúc, còn sự cố thường chỉ xảy ra ở một chi nhánh, một kênh hoặc một nhân viên.
– Quy mọi phát hiện ra tác động bằng tiền, kèm hành động đề xuất.

2.2. Kiến trúc dữ liệu cho phân tích

2.2.1. Kho dữ liệu, hồ dữ liệu và lakehouse

Kho dữ liệu (data warehouse) là tập hợp dữ liệu hướng chủ đề, tích hợp, ổn định và có tính lịch sử, phục vụ ra quyết định (Inmon, 2005), được tối ưu cho truy vấn phân tích trực tuyến (OLAP) thay vì ghi nhận giao dịch (Chaudhuri & Dayal, 1997). Cách tiếp cận của Kimball xây dựng kho theo từng quy trình nghiệp vụ bằng mô hình chiều, kết nối với nhau qua các chiều dùng chung (Kimball & Ross, 2013); quy trình thiết kế đi từ yêu cầu phân tích của người dùng đến thiết kế khái niệm, logic và vật lý (Golfarelli & Rizzi, 2009). *Hồ dữ liệu* (data lake) lưu dữ liệu thô nhiều định dạng với chi phí thấp nhưng dễ thành "đầm lầy dữ liệu" nếu không quản lý chất lượng; kiến trúc lakehouse kết hợp lưu trữ mở của hồ dữ liệu với khả năng quản trị và hiệu năng của kho dữ liệu (Armbrust et al., 2021).

2.2.2. ELT và kiến trúc Medallion

Theo cách ETL truyền thống, dữ liệu được biến đổi trên máy chủ trung gian rồi mới nạp vào kho (Kimball & Caserta, 2004), với các vấn đề chung như phát hiện thay đổi ở nguồn, chuyển đổi định danh và nạp lại khi lỗi (Vassiliadis, 2009). Cách ELT nạp dữ liệu thô nguyên trạng vào nền tảng phân tích trước rồi biến đổi ngay trong nền tảng bằng SQL, nhờ đó giữ được bản gốc để xử lý lại khi quy tắc làm sạch thay đổi (Reis & Housley, 2022). Kiến trúc Medallion tổ chức dữ liệu ELT thành ba tầng có chất lượng tăng dần (Databricks, n.d.): Bronze giữ nguyên dữ liệu nguồn kèm siêu dữ liệu nạp; Silver ép kiểu, chuẩn hóa, giải quyết định danh và tách dòng lỗi; Gold tổ chức dữ liệu cho phân tích dưới dạng lược đồ hình sao và bảng chỉ số. Mỗi tầng một trách nhiệm, kiểm thử được độc lập, và lỗi ở tầng sau không làm mất dữ liệu gốc ở tầng trước.

2.2.3. Thu thập dữ liệu, nạp tăng dần và tính lũy đẳng

Dữ liệu đến nền tảng theo hai kiểu: đẩy, khi hệ thống nguồn hoặc con người gửi tệp, và kéo, khi đường ống chủ động lấy qua API của phần mềm nguồn (Reis & Housley, 2022). Các API này phần lớn theo phong cách REST (Fielding, 2000) và được mô tả bằng đặc tả OpenAPI (OpenAPI Initiative, 2021). Kéo qua API cần một mốc (watermark) để chỉ lấy phần mới, lấy lại một khoảng trước mốc cho dữ liệu đến trễ, đi hết các trang, đối chiếu tổng số bản ghi và thử lại khi lỗi tạm thời. Với dữ liệu đẩy, rủi ro là tệp sai cấu trúc hoặc gửi trùng; cách phòng ngừa là *hợp đồng dữ liệu*, tức thỏa thuận về cấu trúc và ý nghĩa của dữ liệu được kiểm tra tự động ngay khi dữ liệu đến (Reis & Housley, 2022). Khi dữ liệu đến hằng ngày, đường ống cần *nạp tăng dần* (incremental load), chỉ xử lý phần mới, và *lũy đẳng* (idempotency), tức chạy lại cùng một lần nạp cho cùng kết quả. Thao tác lũy đẳng là điều kiện để thử lại an toàn sau lỗi (Kleppmann, 2017), thường đạt được bằng nhật ký nạp ghi mã băm của từng tệp và giao dịch bao trọn mỗi lần nạp.

2.3. Mô hình hóa dữ liệu chiều

2.3.1. Bảng sự kiện, bảng chiều và lược đồ hình sao

Mô hình hóa chiều tổ chức dữ liệu thành *bảng sự kiện* (fact table) lưu các đo lường của một quy trình nghiệp vụ và *bảng chiều* (dimension table) lưu ngữ cảnh mô tả sự kiện (Kimball & Ross, 2013). Khái niệm trung tâm là *hạt dữ liệu* (grain), tức mỗi dòng của bảng sự kiện đại diện cho điều gì; khai báo hạt ở mức chi tiết nhất giúp bảng sự kiện trả lời được nhiều câu hỏi chưa lường trước. Bảng sự kiện có thể là bảng giao dịch hoặc bảng ảnh chụp định kỳ, như tồn kho tại kỳ kiểm kê. Trong *lược đồ hình sao* (star schema), mỗi bảng sự kiện liên kết trực tiếp với các bảng chiều đã phi chuẩn hóa, dễ hiểu với người dùng và truy vấn nhanh. Khi có nhiều quy trình, các bảng sự kiện dùng chung *chiều đồng nhất* (conformed dimension), được thiết kế bằng *ma trận bus* (Kimball & Ross, 2013); trong đề tài, chiều chi nhánh và chiều ngày phải dùng chung thì mới đặt được doanh thu cạnh giá vốn và chi phí nhân công của cùng chi nhánh, cùng ngày.

2.3.2. Chiều thay đổi chậm

Thuộc tính của chiều thay đổi theo thời gian, như giá món hay lương nhân viên. Kỹ thuật *chiều thay đổi chậm* (Slowly Changing Dimension – SCD) xác định cách lưu

các thay đổi này (Bảng 2.1). Đề tài dùng SCD kiểu 2 cho chiều món và chiều nhân viên, vì giá bán và lương tại thời điểm giao dịch quyết định giá vốn lý thuyết và chi phí nhân công; nếu ghi đè, mọi phân tích trước ngày điều chỉnh giá sẽ sai.

Bảng 2.1. Các kiểu chiều thay đổi chậm phổ biến

Kiểu	Cách xử lý	Hệ quả
Kiểu 0	Giữ nguyên giá trị ban đầu	Không phản ánh thay đổi
Kiểu 1	Ghi đè giá trị cũ	Mất lịch sử; sự kiện cũ hiển thị theo giá trị mới
Kiểu 2	Thêm dòng mới với khoảng hiệu lực và cờ bản hiện hành	Giữ đầy đủ lịch sử; sự kiện liên kết đúng phiên bản tại thời điểm xảy ra
Kiểu 3	Thêm cột lưu giá trị trước đó	Chỉ giữ được một mức lịch sử

Nguồn: Kimball và Ross (2013)

2.4. Chất lượng dữ liệu

2.4.1. Các chiều chất lượng dữ liệu

Chất lượng dữ liệu là mức độ phù hợp của dữ liệu với mục đích sử dụng. Wang và Strong (1996) đề xuất khung chất lượng nhìn từ phía người sử dụng; các nghiên cứu sau tổng hợp thành những chiều đo lường được (Batini & Scannapieco, 2016) và định lượng từng chiều bằng các tỷ lệ đơn giản như tỷ lệ bản ghi đầy đủ hay hợp lệ (Pipino et al., 2002). Rahm và Do (2000) phân biệt lỗi trong một nguồn, như sai miền, trùng, thiếu, với lỗi chỉ xuất hiện khi tích hợp nhiều nguồn, như một thực thể mang nhiều mã; dữ liệu của đề tài có cả hai loại (Bảng 2.2).

Bảng 2.2. Các chiều chất lượng dữ liệu và ví dụ trong đề tài

Chiều	Định nghĩa	Ví dụ lỗi trong dữ liệu nguồn của đề tài
Đầy đủ (completeness)	Dữ liệu cần có thì phải có	Quên quẹt thẻ khi ra ca; ô kiểm kê bỏ trống; đơn sàn không được nhập vào POS
Hợp lệ (validity)	Giá trị đúng kiểu, định dạng, miền giá trị	Số lượng nhập kho gõ theo gam vào cột kilôgam; số lượng dính đơn vị như “53.6kg”
Duy nhất (uniqueness)	Một thực thể chỉ được ghi một lần	Máy chấm công ghi trùng lượt quẹt
Nhất quán (consistency)	Cùng thông tin thống nhất giữa các nguồn	Một chi nhánh có sáu cách gọi trên sáu hệ thống; tên nguyên liệu có dấu và không dấu
Kịp thời (timeliness)	Dữ liệu sẵn sàng đúng lúc cần	Báo cáo đối soát sàn chỉ có sau khi kết thúc tuần
Chính xác (accuracy)	Phản ánh đúng thực tế	Sai số đếm tay khi kiểm kê

Nguồn: Tổng hợp từ Wang và Strong (1996), Batini và Scannapieco (2016)

2.4.2. Khám phá dữ liệu, kiểm thử, cách ly và phả hệ

Trước khi đặt quy tắc làm sạch hay chọn phương pháp, dữ liệu cần được khám phá. Phân tích khám phá dữ liệu (exploratory data analysis, EDA) dùng thống kê mô tả và đồ thị để hiểu cấu trúc, phân phối và giá trị bất thường của dữ liệu trước khi đặt giả thuyết hay chọn mô hình (Tukey, 1977). Với dữ liệu nhiều bảng, bước này bắt đầu bằng lập hồ sơ dữ liệu (data profiling): đếm số dòng, giá trị thiếu, giá trị khác nhau, miền giá trị, tìm khóa và phụ thuộc giữa các cột (Abedjan et al., 2015). Kết quả là căn cứ để chọn quy tắc làm sạch và ngưỡng nhận diện giá trị bất thường. Kiểm thử dữ liệu (data testing) là các khẳng định tự động chạy sau mỗi lần biến đổi: khóa không trùng, khóa ngoại tồn tại, giá trị thuộc miền cho phép, tổng tiền không đổi qua các tầng. Các hệ thống kiểm định dữ liệu trong công nghiệp như Deequ (Schelter et al., 2018) và kiểm định dữ liệu trong TFX của Google (Breck et al., 2019) đều khai báo ràng buộc và kiểm tra tự động mỗi lô dữ liệu mới, vì sự phụ thuộc vào dữ liệu là nguồn nợ kỹ thuật khó nhận ra (Sculley et al., 2015). Dòng vi phạm có thể được *cách ly* (quarantine) sang bảng riêng kèm lý do, để các dòng hợp lệ tiếp tục được xử lý mà dòng lỗi không bị bỏ qua im lặng. Cần phân biệt lỗi kỹ thuật, như lượt quẹt thẻ bị ghi trùng, với tín hiệu nghiệp vụ, như hóa đơn bị hủy hay quên quẹt ra: loại sau là bằng chứng cho tầng phân tích nên phải được giữ lại và gắn cờ. Để truy một con số về dữ liệu gốc, mỗi bản ghi cần mang thông tin nguồn gốc, gọi là phả hệ dữ liệu (data provenance) (Simmhan et al., 2005).

2.4.3. Giải quyết định danh thực thể

Giải quyết định danh thực thể (entity resolution) xác định các bản ghi ở những nguồn khác nhau cùng chỉ một thực thể (Christen, 2012). Fellegi và Sunter (1969) mô hình hóa việc ghép cặp như một bài toán quyết định dựa trên độ tương đồng của các trường; Elmagarmid et al. (2007) tổng hợp các thước đo tương đồng chuỗi, trong đó độ đo Jaro (Jaro, 1989) và biến thể Jaro–Winkler ưu tiên chuỗi trùng phần đầu (Winkler, 1990), phù hợp với tên viết tắt. Thực tiễn thường kết hợp bảng ánh xạ do người hiểu nghiệp vụ lập cho thực thể ít và ổn định, quy tắc chuẩn hóa xác định như bỏ dấu, và khớp mờ có ngưỡng cho trường nhập tự do.

2.5. Phát hiện bất thường và truy vết nguyên nhân

2.5.1. Phân loại bất thường và phương pháp thống kê vững

Chandola et al. (2009) phân bất thường thành bất thường điểm, bất thường theo ngữ cảnh, khi giá trị chỉ bất thường trong một ngữ cảnh nhất định, và bất thường tập thể, khi một chuỗi giá trị cùng nhau tạo thành mẫu bất thường; Hodge và Austin (2004) phân biệt phương pháp có giám sát và không giám sát tùy việc có dữ liệu gán nhãn hay không. Phần lớn sự cố vận hành F&B thuộc hai loại sau: hao hụt tăng 20% trong mười ngày chỉ lộ ra khi xét trong ngữ cảnh của chi nhánh đó. *Điểm chuẩn* (z-score) đo khoảng cách của một giá trị so với trung bình của tập tham chiếu:

$$z = \frac{x - \mu}{\sigma} \tag{2.7}$$

trong đó μ và σ là trung bình và độ lệch chuẩn của tập tham chiếu. Ngưỡng ba độ lệch chuẩn là giới hạn quen thuộc của biểu đồ kiểm soát (Montgomery, 2019), nhưng trung bình và độ lệch chuẩn bị chính các giá trị bất thường kéo lệch. *Điểm chuẩn hiệu chỉnh* dùng trung vị và độ lệch tuyệt đối trung vị (MAD) nên vững hơn trước ngoại lai (Leys et al., 2013; Rousseeuw & Croux, 1993); Iglewicz và Hoaglin (1993) đề xuất coi giá trị có $|M| > 3{,}5$ là ngoại lai:

$$M = \frac{0{,}6745\ (x - \tilde{x})}{\mathrm{MAD}}, \qquad \mathrm{MAD} = \mathrm{med}(|x_i - \tilde{x}|) \tag{2.8}$$

trong đó $\tilde{x}$ là trung vị của tập tham chiếu và med là phép lấy trung vị. Để đưa ngữ cảnh vào phép so sánh, *đường cơ sở theo nhóm đồng nhất* so một chi nhánh với lịch sử của chính nó hoặc với các chi nhánh cùng hạng, khiến các yếu tố tác động lên toàn chuỗi như ngày lễ tự triệt tiêu; tách thành phần mùa vụ trước khi xét phần dư là cách làm chuẩn trong phân tích chuỗi thời gian (Hyndman & Athanasopoulos, 2021). Với dịch chuyển nhỏ nhưng kéo dài, biểu đồ tổng tích lũy CUSUM (Page, 1954) nhạy hơn việc xét từng điểm.

2.5.2. Luật nghiệp vụ và kiểm định trên số đếm

Với các quy định đã biết trước như tỷ lệ hoa hồng trong hợp đồng, luật so sánh trực tiếp với giá trị cam kết đúng đắn hơn thống kê dựa trên lịch sử: nếu sàn tính sai liên tục, trung bình lịch sử cũng sai theo và z-score không bao giờ phát hiện được. Với tỷ lệ trên số lần thử nhỏ, như tỷ lệ hủy hóa đơn của một thu ngân trong một tuần, *kiểm định*

nhị thức đánh giá khả năng quan sát được số lần hủy đó nếu thu ngân có cùng tỷ lệ với đồng nghiệp; khi tỷ lệ nhỏ, phân phối nhị thức được xấp xỉ bằng phân phối Poisson (Agresti, 2013). Khi kiểm định đồng thời nhiều đối tượng, hiệu chỉnh Bonferroni chia mức ý nghĩa cho số phép kiểm định để giữ xác suất dương tính giả chung dưới mức mong muốn (Dunn, 1961).

2.5.3. Phân rã chỉ số và cây KPI

Để truy vết một biến động, chỉ số tổng được phân rã theo *cây KPI* (driver tree), trong đó mỗi nút cha là hàm của các nút con. Với doanh thu R của một chi nhánh, gọi N_k là số đơn và AOV_k là giá trị trung bình mỗi đơn của kênh k; khi doanh thu thay đổi giữa kỳ gốc (chỉ số 0) và kỳ quan sát (chỉ số 1), phần thay đổi được phân bổ cho từng kênh, từng thành phần lượng và giá:

$$R = \sum_k N_k \cdot \mathrm{AOV}_k \tag{2.9}$$

$$\Delta R = \sum_k (\Delta N_k \cdot \mathrm{AOV}_{k,0} + N_{k,1} \cdot \Delta \mathrm{AOV}_k) \tag{2.10}$$

Phân rã chỉ ra biến động nằm ở nhánh nào; các tín hiệu đi kèm ở nhánh đó, như thời gian chuẩn bị tăng hay giờ công ca tối giảm, thu hẹp về một nguyên nhân vận hành. Bài toán định vị nguyên nhân trên chỉ số cộng dồn nhiều chiều đã được nghiên cứu trong vận hành hệ thống trực tuyến, như Adtributor (Bhagwan et al., 2014), iDice (Lin et al., 2016) và HotSpot (Sun et al., 2018); khóa luận dùng cùng ý tưởng phân rã nhưng kết hợp với tín hiệu từ các nguồn vận hành khác để gán nguyên nhân.

2.5.4. Đánh giá bộ phát hiện

Khi có đáp án, chất lượng bộ phát hiện được đo bằng ma trận nhầm lẫn: dương tính đúng (TP) là cảnh báo trùng sự cố thật, dương tính sai (FP) là cảnh báo không ứng với sự cố nào, âm tính sai (FN) là sự cố không được cảnh báo:

$$\mathrm{Precision} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}, \qquad \mathrm{Recall} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}} \tag{2.11}$$

$$F_1 = \frac{2 \cdot \mathrm{Precision} \cdot \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}} \tag{2.12}$$

Precision quyết định niềm tin của người dùng vào cảnh báo, recall cho biết bao nhiêu sự cố được phát hiện. Với sự cố kéo dài, đánh giá theo *mức sự kiện*, tức một sự cố được tính là phát hiện nếu có ít nhất một cảnh báo đúng trong khoảng thời gian của nó,

kèm độ trễ phát hiện, phù hợp với cách quản lý sử dụng hơn; Tatbul et al. (2018) mở rộng precision và recall cho bất thường dạng khoảng thời gian. Khi rất ít tuần có sự cố, precision và recall phản ánh chất lượng tốt hơn độ chính xác tổng thể (Saito & Rehmsmeier, 2015). Điều kiện để kết quả có giá trị là tập đánh giá phải độc lập với tập dùng để chọn tham số, vì chọn và đánh giá trên cùng một tập cho ước lượng lạc quan (Cawley & Talbot, 2010), còn để thông tin của đáp án lọt vào bước xây dựng mô hình là lỗi rò rỉ dữ liệu (Kaufman et al., 2012).

2.6. Dữ liệu mô phỏng trong nghiên cứu

Dữ liệu mô phỏng (synthetic data) được dùng khi dữ liệu thật nhạy cảm, khó tiếp cận, hoặc khi cần đáp án biết trước để đánh giá phương pháp. Dữ liệu tổng hợp mô phỏng đúng quan hệ giữa các bảng có thể thay dữ liệu thật trong nhiều tác vụ phát triển và kiểm thử (Patki et al., 2016), nhưng giá trị của nó phụ thuộc vào việc giữ được những tính chất nào của dữ liệu thật (Jordon et al., 2022). PaySim mô phỏng giao dịch ví điện tử từ một mẫu dữ liệu thật để tạo bộ dữ liệu có nhãn gian lận (Lopez-Rojas et al., 2016); các bộ dữ liệu đánh giá phát hiện bất thường cũng thường được dựng có kiểm soát với bất thường biết trước (Emmott et al., 2013; Laptev et al., 2015). Rủi ro chính là dữ liệu quá "sạch" khiến phương pháp trông tốt hơn thực chất. Khóa luận giảm rủi ro này bằng bốn nguyên tắc: mô phỏng đúng các quy luật vận hành đã biết, chẳng hạn thời gian chờ tăng phi tuyến theo $1/(1-\rho)$ khi mức tải ρ tiến gần năng lực (Kleinrock, 1975); sinh mọi nguồn từ cùng một tập sự kiện; đưa vào lỗi dữ liệu đặc trưng của từng hệ thống; và ước lượng phân phối đầu vào từ dữ liệu quan sát thật khi có thể, tức bước mô hình hóa dữ liệu đầu vào (input modeling) của phương pháp mô phỏng (Law, 2015).

2.7. Công nghệ sử dụng

Công nghệ được chọn theo nguyên tắc tương xứng với quy mô. Dữ liệu của bài toán ở mức hàng trăm megabyte mỗi năm, nằm trong khả năng của một máy tính cá nhân, nên đề tài không dùng nền tảng phân tán như Spark hay Hadoop. DuckDB là hệ quản trị phân tích dạng nhúng, lưu theo cột và thực thi theo vector (Raasveldt & Mühleisen, 2019); dbt viết các bước biến đổi bằng SQL có quản lý phiên bản, tự dựng đồ thị phụ thuộc và có sẵn kiểm thử dữ liệu (dbt Labs, n.d.); Apache Airflow điều phối các bước thành đồ thị có hướng không chu trình (DAG), chạy theo lịch hoặc khi một tập dữ liệu vừa cập nhật (Apache Software Foundation, n.d.). PostgreSQL đóng vai kho

phục vụ cho nhiều người đọc đồng thời (PostgreSQL Global Development Group, n.d.), vì tách máy tính toán khỏi nơi phục vụ người đọc là cách làm phổ biến (Reis & Housley, 2022). Docker đóng gói mỗi thành phần vào container (Merkel, 2014) và Docker Compose dựng lại cả nền tảng bằng một lệnh (Docker Inc., n.d.). FastAPI được dùng để dựng API giả lập phía nguồn (FastAPI, n.d.); Python cùng pandas (McKinney, 2010), NumPy (Harris et al., 2020) và scikit-learn (Pedregosa et al., 2011) dùng cho bộ mô phỏng, bước nạp và các bộ phát hiện; Metabase phục vụ báo cáo kinh doanh (Metabase, n.d.) và Streamlit cho các trang phân tích có logic riêng (Streamlit, n.d.). Bảng 2.3 tóm tắt lý do chọn từng công nghệ.

Bảng 2.3. Lựa chọn công nghệ và lý do

Nhu cầu	Công nghệ chọn	Lý do và phương án không chọn
Tính toán và lưu trữ của đường ống	DuckDB	Dữ liệu cỡ trăm MB, một máy; truy vấn phân tích theo cột nhanh, không cần máy chủ; không cần cụm Spark
Biến đổi dữ liệu Silver, Gold	dbt (dbt-duckdb)	SQL có kiểm thử, tài liệu và lineage; thay cho các script Python rời rạc khó kiểm thử
Thu thập qua API	Bộ kết nối Python dùng thư viện chuẩn	Chỉ có hai nguồn API, cần kiểm soát mốc và đối chiếu theo nghiệp vụ; công cụ dựng sẵn như Airbyte cần thêm một hệ thống chạy riêng
Kho phục vụ cho người đọc	PostgreSQL	Tệp DuckDB chỉ cho một tiến trình ghi và không có tài khoản người dùng; PostgreSQL cho nhiều kết nối đọc đồng thời và tài khoản chỉ đọc
Báo cáo kinh doanh	Metabase	Mã nguồn mở, chạy trong Docker, dựng dashboard bằng API nên tái lập được; Power BI cần tài khoản trả phí để chia sẻ, nhúng
Điều phối	Airflow, Docker Compose	Chạy theo lịch và theo dữ liệu mới, theo dõi lỗi; không cần Kafka vì nhịp nghiệp vụ là theo ngày
Ứng dụng phân tích	Streamlit	Xây dựng nhanh bằng Python cho các trang cảnh báo, truy vết, vận hành dữ liệu

Nguồn: Đề xuất của nghiên cứu

2.8. Các nghiên cứu liên quan

Các nghiên cứu liên quan thuộc bốn nhóm. Nhóm thứ nhất nghiên cứu dữ liệu và phân tích trong ngành nhà hàng, khách sạn: tổng quan của Mariani et al. (2018) cho thấy lĩnh vực này tăng nhanh nhưng còn rời rạc về phạm vi và hạn chế về phương pháp;

Thompson (1998), Kimes (1999) và Feldman et al. (2023) cung cấp khái niệm về công suất, phân ca và hợp đồng với sàn nhưng không xây dựng hệ thống tích hợp dữ liệu. Nhóm thứ hai nghiên cứu sai lệch tồn kho bằng dữ liệu bán lẻ (DeHoratius & Raman, 2008) và bằng mô hình giải tích, mô phỏng (Kang & Gershwin, 2005), chưa gắn với tiêu hao theo công thức món. Nhóm thứ ba phát hiện bất thường và gian lận trên hóa đơn bán hàng bằng học không giám sát (Malashin et al., 2024) hoặc có giám sát (Begen et al., 2023), đều làm việc trên một nguồn dữ liệu và cần trường hợp bất thường đã biết. Nhóm thứ tư định vị nguyên nhân trên chỉ số nhiều chiều (Bhagwan et al., 2014; Sun et al., 2018), nhưng chỉ trên một chỉ số và các thuộc tính của chính nó. Bảng 2.4 tóm tắt các nghiên cứu tiêu biểu.

Bảng 2.4. Tổng hợp các nghiên cứu liên quan

Nghiên cứu	Lĩnh vực, dữ liệu	Phương pháp	Kết quả chính	Khác biệt so với khóa luận
Mariani et al. (2018)	Nhà hàng, khách sạn, du lịch; các công bố đến năm 2016	Tổng quan tài liệu có hệ thống	Nghiên cứu tăng nhanh nhưng rời rạc về phạm vi, hạn chế về phương pháp	Khóa luận xây dựng hệ thống trên dữ liệu vận hành đa nguồn
DeHoratius và Raman (2008)	Bán lẻ; gần 370.000 bản ghi tồn kho của 37 cửa hàng	Mô hình tuyến tính phân cấp	Khoảng 65% bản ghi tồn kho sai lệch; kiểm kê giúp giảm sai lệch	Khóa luận đối chiếu kiểm kê với tiêu hao theo công thức món
Kang và Gershwin (2005)	Hệ thống tồn kho; mô hình và mô phỏng	Mô hình giải tích, mô phỏng	Thất thoát nhỏ tích lũy gây thiếu hàng nghiêm trọng	Khóa luận phát hiện thất thoát từ dữ liệu thay vì mô hình hóa tác động
Feldman et al. (2023)	Nhà hàng và sàn giao đồ ăn	Mô hình toán về hợp đồng	Hợp đồng hoa hồng theo tỷ lệ không điều phối được lợi ích hai bên	Khóa luận kiểm tra việc tuân thủ hợp đồng từ báo cáo đối soát
Malashin et al. (2024)	Khoảng 2,7 triệu hóa đơn nhà hàng	Isolation Forest, bộ mã hóa tự động, giải thuật di truyền	Phát hiện được 25 trên 100 trường hợp bất thường đã biết ở tập kiểm tra	Một nguồn dữ liệu; mục tiêu là tuân thủ thuế, không truy nguyên nhân vận hành
Begen et al. (2023)	Nhật ký POS chuỗi đồ ăn nhanh	Random Forest, XGBoost, LightGBM, cân bằng mẫu	Kết quả khả quan ở giai đoạn đầu	Cần nhãn gian lận; khóa luận dùng kiểm định thống kê không cần nhãn

Nghiên cứu	Lĩnh vực, dữ liệu	Phương pháp	Kết quả chính	Khác biệt so với khóa luận
Bhagwan et al. (2014); Sun et al. (2018)	Doanh thu quảng cáo; chỉ số vận hành hệ thống trực tuyến	Phân rã chỉ số nhiều chiều, tìm tổ hợp gây bất thường	Định vị nhanh chiều và giá trị gây biến động	Chỉ trên một chỉ số; khóa luận kết hợp tín hiệu từ nhiều hệ thống nguồn
Lopez-Rojas et al. (2016)	Giao dịch ví điện tử	Mô phỏng dựa trên tác tử từ mẫu dữ liệu thật	Bộ dữ liệu có nhãn gian lận cho nghiên cứu	Khóa luận mô phỏng nhiều hệ thống nguồn nhất quán nhân quả

Nguồn: Tổng hợp từ các nghiên cứu được trích dẫn

2.9. Khoảng trống nghiên cứu và tiểu kết chương

Các nghiên cứu hiện có hoặc dừng ở khái niệm và mô hình, hoặc phân tích một nguồn dữ liệu cho một loại sự cố. Khoảng trống mà khóa luận hướng tới là kết hợp ba yếu tố thường bị tách rời: tích hợp đầy đủ các nguồn vận hành không đồng nhất của một chuỗi F&B, kể cả sổ kho và phiếu kiểm kê ghi tay; một kho dữ liệu có kiểm chứng chất lượng làm nền cho phân tích; và đánh giá định lượng khả năng phát hiện, truy vết nhiều loại sự cố trên một tập kịch bản độc lập có đáp án. Về nghiệp vụ, chương này xác định các chỉ số COGS%, AvT, Labor%, tỷ lệ hoa hồng hiệu dụng và tỷ lệ hủy theo thu ngân làm dấu vết của các vấn đề P1–P5; về kỹ thuật, kiến trúc Medallion, mô hình hóa chiều, kiểm thử dữ liệu, thống kê vững và cây KPI là công cụ để biến dữ liệu rời rạc thành bằng chứng kiểm chứng được. Chương 3 vận dụng các cơ sở này để thiết kế hệ thống.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

Chương này trình bày thiết kế của nền tảng theo phương pháp nghiên cứu khoa học thiết kế đã nêu ở mục 1.6: mỗi quyết định thiết kế có căn cứ từ Chương 2 và có tiêu chí kiểm chứng ở Chương 5. Mục 3.1 đi từ câu hỏi nghiên cứu đến yêu cầu của hệ thống; các mục tiếp theo đi theo chiều của dữ liệu, từ kiến trúc tổng thể, bộ mô phỏng tạo dữ liệu nguồn, đường ống tới tầng Silver, kho dữ liệu, kiểm soát chất lượng, lớp phân tích, đến ứng dụng, kho phục vụ và điều phối.

3.1. Phân tích yêu cầu

3.1.1. Từ câu hỏi nghiên cứu đến thiết kế

Mỗi câu hỏi nghiên cứu ở mục 1.3 được chuyển thành một giả thuyết thiết kế, tức một nhận định về cách tổ chức hệ thống mà nếu đúng thì câu hỏi được trả lời, kèm thành phần hiện thực và tiêu chí kiểm chứng (Bảng 3.1). Theo Hevner et al. (2004), sản phẩm thiết kế phải được đánh giá bằng tiêu chí xác định trước, gắn với vấn đề nó giải quyết; nhờ vậy thiết kế ở chương này và đánh giá ở Chương 5 dùng chung một khung.

Bảng 3.1. Liên hệ giữa câu hỏi nghiên cứu, giả thuyết thiết kế và cách kiểm chứng

Câu hỏi	Giả thuyết thiết kế	Thành phần hiện thực	Tiêu chí kiểm chứng
RQ1	Tách thu thập, lưu bản gốc, làm sạch có cách ly và kiểm thử giữa các tầng thì tích hợp được bảy nguồn không đồng nhất mà không thất lạc hay làm sai dữ liệu	Tầng thu thập, Bronze, Silver, Gold, kiểm soát chất lượng (mục 3.4–3.6)	Số dòng bảo toàn giữa các tầng; số kiểm thử đạt; lỗi dữ liệu được phát hiện và xử lý; khả năng chịu dữ liệu bất thường; thời gian xử lý một ngày (mục 5.2)
RQ2	So mỗi chỉ số với nhóm chi nhánh cùng hạng và lịch sử của chính chi nhánh, kết hợp luật đối soát và kiểm định trên số đếm, thì phát hiện được các sự cố mà theo dõi doanh thu bỏ sót	Mức kỳ vọng, năm bộ phát hiện (mục 3.7)	Precision, recall, F1 và độ trễ trên tập kiểm tra độc lập; so với hai phương án cơ sở; độ nhạy theo ngưỡng và cách tính mức kỳ vọng (mục 5.3, 5.5)

Câu hỏi	Giả thuyết thiết kế	Thành phần hiện thực	Tiêu chí kiểm chứng
RQ3	Đặt phân rã doanh thu theo cây KPI cạnh dấu hiệu đặc trưng của từng nguyên nhân trên nhiều nguồn thì gán được nguyên nhân và không nhầm biến động bình thường thành sự cố	Cây KPI, chấm điểm giả thuyết, bằng chứng gốc (mục 3.7, 3.8)	Tỷ lệ sự cố được gán đúng nguyên nhân hạng một; số cảnh báo trong các tuần lễ, mưa, điều chỉnh giá (mục 5.4)

Nguồn: Đề xuất của nghiên cứu

Ràng buộc chung cho cả ba câu hỏi là tính độc lập của đánh giá: đường ống và các bộ phát hiện không được đọc đáp án của bộ mô phỏng, và mọi tham số chỉ được chọn trên tập phát triển.

3.1.2. Yêu cầu chức năng và phi chức năng

Hệ thống phục vụ bốn nhóm người dùng. Quản lý vận hành chuỗi cần biết chi nhánh nào có vấn đề, vấn đề gì và mất bao nhiêu tiền; kế toán cần danh sách sai lệch đối soát, chênh lệch kiểm kê và hóa đơn hủy bất thường; quản lý chi nhánh cần biết ca nào thiếu người, nguyên liệu nào hao hụt; kỹ sư dữ liệu cần đường ống tự nạp dữ liệu mới và cho biết dòng nào bị cách ly, vì sao. Từ đó hình thành chín yêu cầu chức năng (Bảng 3.2) và tám yêu cầu phi chức năng (Bảng 3.3).

Bảng 3.2. Yêu cầu chức năng

Mã	Yêu cầu	Người dùng
FR1	Thu nhận dữ liệu từ bảy nhóm hệ thống nguồn qua đúng kênh mỗi hệ thống hỗ trợ (API, tệp xuất tự động, tệp do người gửi); nhận dạng tệp theo nội dung, từ chối tệp sai hợp đồng dữ liệu kèm lý do; chỉ nạp phần mới	Kỹ sư dữ liệu, kế toán, quản lý chi nhánh
FR2	Làm sạch, chuẩn hóa và giải quyết định danh chi nhánh, nhân viên, món, nguyên liệu giữa các hệ thống	Kỹ sư dữ liệu
FR3	Cách ly dòng vi phạm quy tắc kèm lý do; báo cáo tình trạng chất lượng dữ liệu	Kỹ sư dữ liệu
FR4	Lưu dữ liệu sạch vào kho dạng lược đồ hình sao, giữ lịch sử thay đổi giá món và lương	Kỹ sư dữ liệu
FR5	Tính các chỉ số vận hành theo chi nhánh, ngày, ca, kênh: doanh thu, số đơn, AOV, COGS%, Labor%, OPLH, thời gian chuẩn bị, tỷ lệ hủy	Quản lý vận hành
FR6	Phát hiện năm loại sự cố P1–P5, đưa ra danh sách cảnh báo có mức độ, bằng chứng và thiệt hại ước tính	Quản lý vận hành, kế toán

Mã	Yêu cầu	Người dùng
FR7	Truy vết biến động doanh thu của một chi nhánh trong một tuần về kênh, thành phần lượng và giá, và nguyên nhân vận hành	Quản lý vận hành
FR8	Xem bản ghi gốc làm căn cứ cho một cảnh báo	Quản lý vận hành, chi nhánh
FR9	Tự động chạy toàn bộ đường ống khi có dữ liệu mới và đưa kết quả sang kho phục vụ cho công cụ báo cáo	Kỹ sư dữ liệu

Nguồn: Đề xuất của nghiên cứu

Bảng 3.3. Yêu cầu phi chức năng

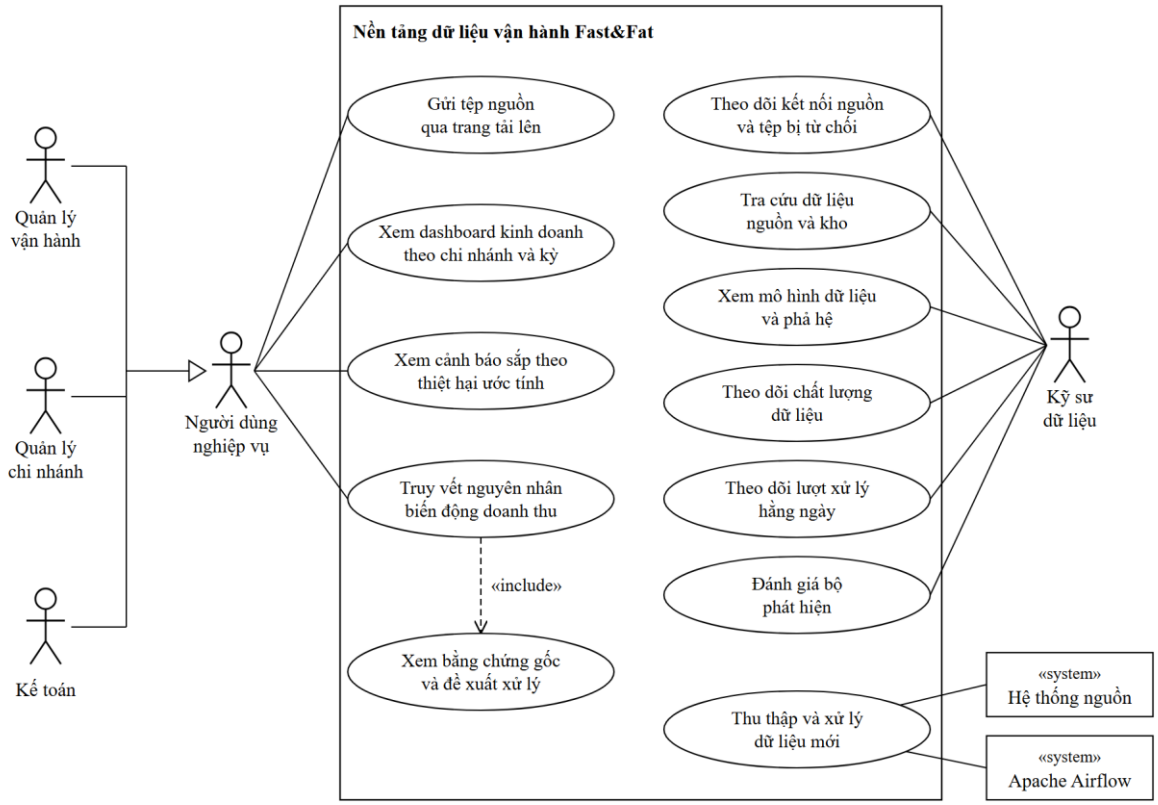
Mã	Thuộc tính	Yêu cầu
NFR 1	Tái lập	Cùng dữ liệu nguồn và mã nguồn cho cùng kết quả; dữ liệu mô phỏng tái lập được nhờ hạt giống ngẫu nhiên cố định
NFR 2	Lũy đẳng, tăng dần	Chạy lại không sinh dữ liệu trùng; mỗi ngày chỉ xử lý dữ liệu mới
NFR 3	Truy vết nguồn gốc	Mọi dòng dữ liệu truy ngược được về tệp và dòng gốc
NFR 4	Kiểm chứng được	Kiểm thử chất lượng tự động sau mỗi lần biến đổi; đối soát số dòng và tổng tiền giữa các tầng
NFR 5	Giải thích được	Mọi cảnh báo kèm chỉ số, ngưỡng và dữ liệu làm căn cứ; không dùng mô hình hộp đen
NFR 6	Độc lập đánh giá	Đường ống và bộ phát hiện không đọc đáp án của bộ mô phỏng; tham số chỉ chọn trên tập phát triển
NFR 7	Hiệu năng	Chạy trên một máy tính cá nhân; xử lý một ngày dữ liệu mới trong vài phút
NFR 8	Chịu lỗi nguồn	Tệp hỏng, sai hợp đồng, thiếu tệp hay API không phản hồi không làm dừng các nguồn khác, không bị bỏ qua im lặng và không dẫn tới kết luận sự cố sai

Nguồn: Đề xuất của nghiên cứu

3.1.3. Ca sử dụng

Sơ đồ ca sử dụng ở Hình 3.1 dùng ký hiệu UML 2.5 (Object Management Group, 2017). Quản lý vận hành, quản lý chi nhánh và kế toán dùng chung các chức năng phân tích và gửi tệp, nên được khái quát thành tác nhân người dùng nghiệp vụ; bên cạnh đó là kỹ sư dữ liệu và hai tác nhân hệ thống là hệ thống nguồn và Airflow. Các ca sử dụng hợp thành ba luồng. Luồng phân tích dành cho quản lý và kế toán: từ danh sách cảnh báo sắp theo thiệt hại ước tính, người dùng đi vào truy vết gồm kết luận, đề xuất xử lý, doanh thu so với mức kỳ vọng, cây KPI và cuối cùng là bản ghi gốc, vì một kết luận thống kê chỉ có giá trị khi kiểm tra lại được trên dữ liệu thật. Luồng đưa dữ liệu vào:

phần lớn dữ liệu đến tự động qua API hoặc tệp xuất theo lịch, còn báo cáo sàn, sổ kho và phiếu kiểm kê do người gửi; hệ thống tự xác định tệp thuộc nguồn nào, đúng hợp đồng không, là bản mới, bản sửa hay bản trùng, và báo ngay lý do nếu từ chối. Luồng vận hành tự động: khi có dữ liệu mới, đường ống tự chạy từ thu thập đến kho phục vụ; nếu dữ liệu thiếu nghiêm trọng hoặc một kiểm thử thất bại, lượt chạy dừng và người dùng tiếp tục thấy bản kết quả trước, không bao giờ thấy kết quả dở dang.

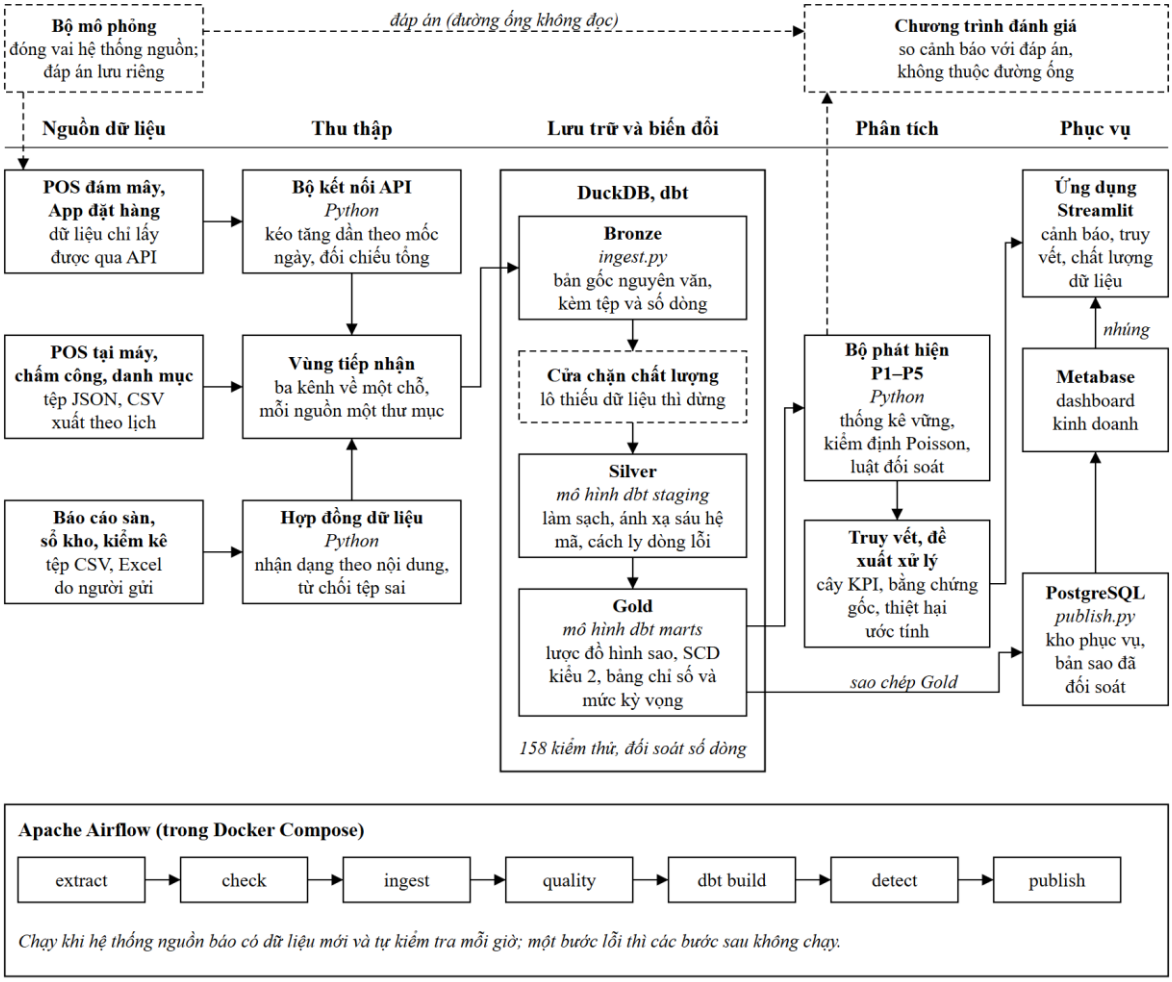


Nguồn: Đề xuất của nghiên cứu

Hình 3.1. Sơ đồ ca sử dụng của hệ thống

3.2. Kiến trúc tổng thể

Hình 3.2 trình bày nền tảng theo chiều đi của dữ liệu: mỗi cột là một chặng, mỗi khối ghi thành phần, công nghệ và vấn đề mà thành phần đó giải quyết; thanh dưới cùng là thứ tự các bước do Airflow điều phối trong một lượt chạy. Lý do chọn từng công nghệ đã trình bày ở Bảng 2.3.



Nguồn: Đề xuất của nghiên cứu

Hình 3.2. Kiến trúc tổng thể của nền tảng

Nền tảng gồm sáu lớp. Lớp nguồn và thu thập đưa dữ liệu từ ba kênh, gồm API của POS đám mây và ứng dụng đặt hàng, tệp xuất theo lịch của POS cài tại máy và máy chấm công, tệp do người gửi, về một vùng tiếp nhận và kiểm tra theo hợp đồng dữ liệu. Trong khóa luận, các hệ thống nguồn do bộ mô phỏng đóng vai và phía API do một dịch vụ giả lập phục vụ; khi triển khai thực tế chỉ phần nguồn được thay, các lớp phía sau giữ nguyên. Lớp nạp lưu bản gốc vào tầng Bronze của DuckDB. Lớp biến đổi gồm các mô hình dbt làm sạch, cách ly dòng lỗi ở tầng Silver và tổ chức lược đồ hình sao, bảng chỉ số ở tầng Gold. Lớp phân tích tính mức kỳ vọng, cây KPI, năm bộ phát hiện và đề xuất xử lý. Lớp phục vụ sao tầng Gold và bảng cảnh báo sang PostgreSQL cho Metabase đọc bằng tài khoản chỉ đọc. Lớp trình bày và điều phối gồm ứng dụng Streamlit là địa chỉ duy nhất cho người dùng, và Airflow chạy toàn bộ chuỗi khi có dữ liệu mới.

DuckDB và PostgreSQL có vai trò khác nhau. DuckDB là máy tính toán: mọi phép biến đổi và kiểm thử diễn ra trong một tệp, nhanh và dễ tái lập, nhưng một tệp DuckDB

chỉ cho một tiến trình ghi và không có tài khoản người dùng. PostgreSQL phục vụ nhiều người đọc đồng thời, và bản sao chỉ được thay khi một lượt chạy đã qua hết kiểm thử, nên người đọc không bao giờ thấy dữ liệu dở dang. Ràng buộc kiến trúc quan trọng nhất là đáp án của bộ mô phỏng nằm ngoài đường ống: chỉ chương trình kiểm chứng, chương trình đánh giá ở Chương 5 và trang Bộ mô phỏng của ứng dụng được đọc, còn đường ống và các bộ phát hiện chỉ thấy dữ liệu nguồn, giống điều kiện triển khai thực tế.

3.3. Thiết kế bộ mô phỏng dữ liệu nguồn

3.3.1. Nguyên lý "một thế giới, nhiều góc nhìn"

Sinh ngẫu nhiên từng nguồn độc lập tạo ra dữ liệu không nhất quán: báo cáo sàn không khớp với đơn trong POS, mã thu ngân không ứng với ai trong danh sách chấm công, thiếu nhân sự không ảnh hưởng gì tới doanh thu. Trên dữ liệu như vậy, "tích hợp đa nguồn" chỉ là hình thức và không phương pháp truy vết nào kiểm chứng được. Bộ mô phỏng vì vậy theo nguyên lý ngược lại: mỗi ngày, các sự kiện thật của chuỗi được sinh đúng một lần, gồm đơn hàng, ca làm, tải bếp, nguyên liệu dùng, hỏng, mất, hàng giao và kiểm kê; sau đó mỗi hệ thống nguồn xuất phần sự kiện nó quan sát được theo định dạng riêng, kèm lỗi đặc trưng (Bảng 3.4). Nhờ vậy các nguồn nhất quán với nhau như ngoài thực tế, và một sự cố đưa vào thế giới để lại dấu vết đồng thời ở nhiều nguồn.

Bảng 3.4. Các hệ thống nguồn và phần sự kiện mỗi hệ thống quan sát được

Hệ thống nguồn	Phần sự kiện quan sát được	Định dạng	Quy ước riêng
POS tại quầy	Đơn tại quầy mọi trạng thái và đơn sàn đã hoàn thành do nhân viên nhập tay	JSON theo chi nhánh, theo ngày; 43 trường	Mã chi nhánh theo tiền tố máy POS; mã thu ngân dạng `NV0012`
Ứng dụng riêng	Đơn đặt qua ứng dụng mọi trạng thái, khách hàng	JSON từ API theo ngày; 30 trường	Giờ UTC; mã chi nhánh, mã món riêng
GrabFood	Tổng hợp tuần của đúng các đơn Grab thật	CSV theo tuần, tiếng Anh	Tên cửa hàng tự do; chỉ có số tiền hoa hồng
ShopeeFood	Tổng hợp tuần của đúng các đơn Shopee thật	Excel theo tuần, tiếng Việt	Mã cửa hàng riêng; có dòng tiêu đề báo cáo
Sổ nhập kho	Từng lần giao hàng	Excel do quản lý ghi, hai mẫu	Tên nguyên liệu nhập tự do
Phiếu kiểm kê	Tồn thực tế hai tuần một lần	Excel dạng phiếu	Mã nguyên liệu `NL01…NL22`

Hệ thống nguồn	Phần sự kiện quan sát được	Định dạng	Quy ước riêng
Máy chấm công	Lượt quẹt vào, ra	CSV theo chi nhánh, theo ngày	Mã nhân viên dạng số, mã chi nhánh `BR01`
Hệ thống trụ sở	Danh mục chi nhánh, món, giá, nguyên liệu, công thức, nhân viên, hợp đồng sàn	CSV, xuất lại khi thay đổi	Ảnh chụp theo ngày hiệu lực
Thời tiết	Lượng mưa, tình trạng thời tiết theo ngày	JSON theo ngày	Nguồn bên ngoài

Nguồn: Đề xuất của nghiên cứu

3.3.2. Mô hình nhu cầu và chuỗi nhân quả vận hành

Số đơn kỳ vọng của chi nhánh b, kênh k, ngày d được mô hình hóa dạng tích các hệ số:

$$\lambda_{b,k,d} = Q_{g(b)} \cdot h_b \cdot w_{t(d)} \cdot \varepsilon_{b,d} \cdot s_k \cdot L_{k,d} \cdot M_{k,d} \cdot X_{b,k,d} \quad (3.1)$$

trong đó $Q_{g(b)}$ là mức đơn cơ sở theo hạng $g(b)$ của chi nhánh, h_b là hệ số riêng của chi nhánh, $w_{t(d)}$ là hệ số theo thứ trong tuần, $\varepsilon_{b,d}$ là nhiễu theo ngày, s_k là tỷ trọng kênh, $L_{k,d}$ và $M_{k,d}$ là hệ số ngày lễ và ngày mưa theo kênh, $X_{b,k,d}$ là hệ số thứ hạng trên sàn, chỉ áp dụng cho kênh sàn. Số đơn thực tế rút từ phân phối Poisson với kỳ vọng λ, rồi phân bổ vào các giờ mở cửa theo trọng số giờ (Bảng 3.5).

Bảng 3.5. Tham số chính của mô hình nhu cầu

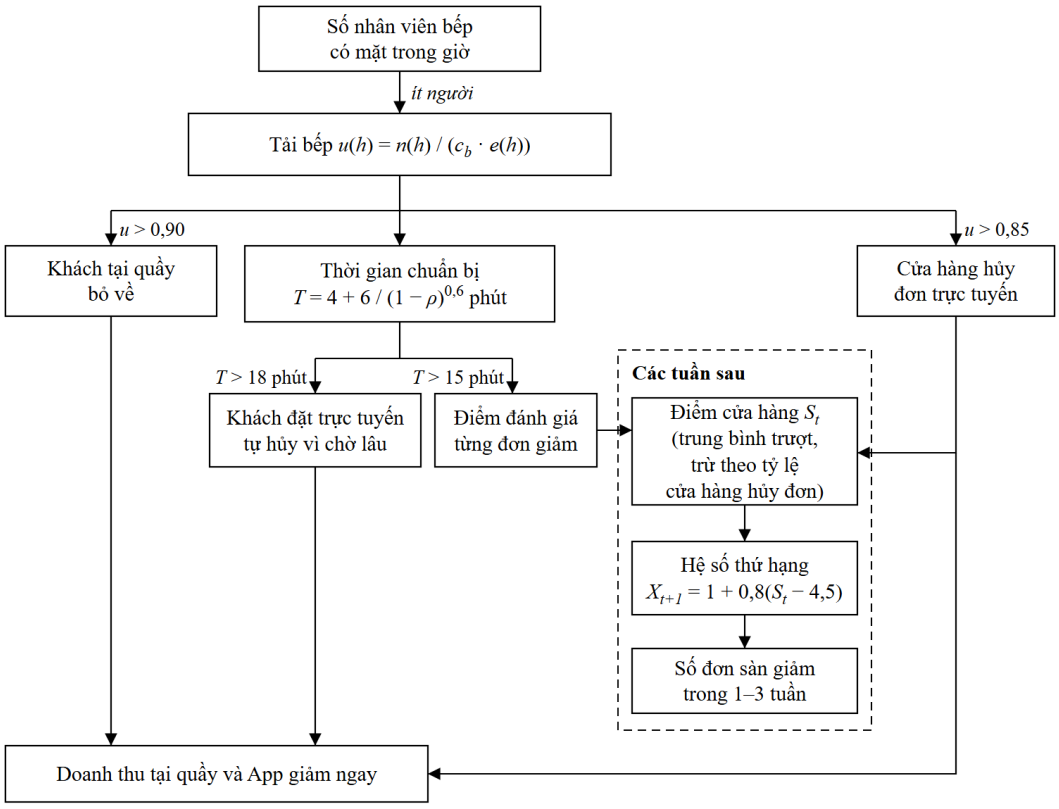
Tham số	Giá trị
Mức đơn cơ sở theo hạng (đơn/ngày)	Hạng A: 380; hạng B: 170; hạng C: 60 (3, 5 và 3 chi nhánh)
Tỷ trọng kênh	Tại quầy 55%, ứng dụng riêng 20%, GrabFood 15%, ShopeeFood 10%
Hệ số ngày trong tuần (T2 → CN)	0,92; 0,90; 0,95; 0,98; 1,10; 1,25; 1,20
Ngày lễ	18/4, 30/4, 1/5, 2/9, 3/9/2024: tại quầy ×1,35; ứng dụng ×1,30; sàn ×1,15
Ngày mưa	Mùa mưa (tháng 5–10) 45% số ngày, mùa khô 8%; tại quầy ×0,75; ứng dụng ×1,20; sàn ×1,25
Giờ mở cửa và cao điểm	7h–22h; khung 11h–14h và 18h–21h có trọng số gấp ba
Số món mỗi đơn	1, 2, 3, từ 4 món với xác suất 42%, 32%, 16%, 10% (hiệu chỉnh từ dữ liệu thật)
Mức độ bán chạy của món	Phân phối Zipf số mũ 1,06 theo thứ hạng món (hiệu chỉnh từ dữ liệu thật)

Tham số	Giá trị
Độ dao động ngẫu nhiên theo ngày	Độ lệch chuẩn 0,075 trên thang logarit (hiệu chỉnh từ dữ liệu thật)
Điều chỉnh giá	01/06/2024 tăng giá 6 món, căn cứ để dựng chiều thay đổi chậm kiểu 2
Khách hàng ứng dụng	4.200 khách, tần suất mua dạng Zipf

Nguồn: Đề xuất của nghiên cứu

Các tham số không ghi hiệu chỉnh là giả định cho một chuỗi đồ ăn nhanh tại TP.HCM: hệ số ngày trong tuần và hai khung cao điểm theo đặc điểm nhu cầu theo giờ của nhà hàng (Thompson, 1998); tỷ trọng giao hàng khoảng 45% theo mức phổ biến của giao đồ ăn trực tuyến tại Việt Nam (Momentum Works, 2025), còn tỷ lệ giữa hai sàn là giả định.

Phần quan trọng nhất của bộ mô phỏng là chuỗi nhân quả nối nhân sự với doanh thu (Hình 3.3). Mỗi nhân viên có ca ưu tiên, sáng từ 6h45 đến 14h hoặc tối từ 13h45 đến 22h, và đi làm với xác suất cao hơn vào cuối tuần; quản lý luôn gọi người bù nếu ca có ít hơn số nhân viên bếp tối thiểu, lần lượt 3, 2 và 1 người với chi nhánh hạng A, B và C. Kịch bản thiếu nhân sự được áp dụng sau bước này, tức là thiếu người do điều phối sai chứ không do vắng ngẫu nhiên.



Nguồn: Đề xuất của nghiên cứu

Hình 3.3. Chuỗi nhân quả vận hành trong bộ mô phỏng

Với mỗi giờ h, mức tải bếp $u(h)$ bằng số đơn $n(h)$ chia năng lực bếp, tức số nhân viên bếp có mặt $e(h)$ nhân năng lực c_b của một người, tính bằng số đơn mỗi giờ. Năng lực c_b được hiệu chỉnh riêng cho từng chi nhánh sao cho giờ cao điểm của ngày đông nhất, với số nhân viên bếp tối thiểu, có tải 95%; khi vận hành bình thường tải dưới 1 và chỉ vượt 1 khi thiếu người. Thời gian chuẩn bị tăng phi tuyến khi tải tiến gần năng lực, theo dạng của mô hình hàng đợi ở mục 2.6, với $\rho = min(u;\ 0{,}97)$:

$$u(h) = \frac{n(h)}{c_b \cdot e(h)} \tag{3.2}$$

$$T_{\text{chuẩn bị}} = 4 + \frac{6}{(1-\rho)^{0{,}6}} \quad \text{(phút)} \tag{3.3}$$

Quá tải để lại nhiều hệ quả. Khi tải vượt 0,90, một phần khách tại quầy bỏ về với tỷ lệ 0,60 × (u − 0,90), tối đa 40%; đơn của họ không xuất hiện trong hệ thống nào, tức phần doanh thu mất đi không để lại dấu vết trực tiếp. Khi tải vượt 0,85, cửa hàng hủy đơn trực tuyến với xác suất 0,006 + 0,30 × (u − 0,85). Khi thời gian chuẩn bị vượt 18 phút, khách đặt trực tuyến tự hủy với xác suất tăng 0,004 mỗi phút; điểm đánh giá mỗi

đơn có kỳ vọng 4,7 và giảm 0,05 cho mỗi phút vượt 15 phút. Cuối tuần, điểm cửa hàng trên mỗi sàn được cập nhật theo trung bình trượt có trọng số và bị trừ theo tỷ lệ hủy do cửa hàng, rồi quyết định hệ số thứ hạng của tuần sau, giới hạn trong khoảng 0,55 đến 1,08:

$$S_t = 0{,}6\, S_{t-1} + 0{,}4(\overline{r}_t - 2\, c_t), \qquad X_{t+1} = 1 + 0{,}8(S_t - 4{,}5) \tag{3.4}$$

trong đó S_t là điểm của cửa hàng sau tuần t, $\overline{r}_t$ là điểm trung bình các đơn trong tuần và c_t là tỷ lệ đơn bị cửa hàng hủy. Hệ số X nhân vào số đơn kỳ vọng của kênh sàn ở công thức (3.1), nên thiếu người làm giảm doanh thu theo hai đường: ngay trong kỳ qua khách bỏ về và đơn bị hủy, và kéo dài nhiều tuần sau khi cửa hàng tụt hạng trên sàn rồi hồi phục dần.

Về kho, hàng tươi được giao mỗi sáng từ thứ Hai đến thứ Bảy, hàng khô vào thứ Hai và thứ Năm; lượng đặt bằng tiêu hao trung bình bảy ngày nhân số ngày dự trữ trừ tồn hiện tại. Tiêu hao thực tế bằng tiêu hao theo công thức của các món đã làm nhân hệ số hao hụt tự nhiên, 1,02–1,05 với hàng tươi và 1,00–1,02 với hàng khô. Đơn sàn không nhập POS và hóa đơn bị hủy do gian lận vẫn tiêu hao nguyên liệu, có chủ đích để P1 và P5 cũng để lại dấu vết chéo ở dữ liệu kho. Kho được kiểm kê vào Chủ nhật, hai tuần một lần.

3.3.3. Mô hình lỗi của dữ liệu nguồn

Để phần kỹ thuật dữ liệu phải xử lý vấn đề có thật, mỗi hệ thống nguồn mang các lỗi đặc trưng của dữ liệu do nhiều phần mềm khác nhau tạo ra hoặc do người ghi tay (Bảng 3.6).

Bảng 3.6. Các lỗi dữ liệu đặc trưng của từng hệ thống nguồn

Hệ thống	Lỗi được mô phỏng	Chiều chất lượng
POS	Ba chi nhánh dùng phiên bản cũ: ngày dạng ISO thay vì dd/mm/yyyy, tiền là chuỗi có dấu chấm ngăn cách (“125.000”), cột tổng tiền mang tên khác, thiếu bốn trường	Nhất quán, hợp lệ
POS	Tên món có nhiều biến thể; khoảng 3% đơn sàn không được nhập; một số bản ghi đồng bộ lỗi	Nhất quán, đầy đủ
Ứng dụng	Giờ UTC; mã chi nhánh, mã món khác hệ thống trụ sở; tên món tiếng Việt có dấu	Nhất quán
GrabFood	Tên cửa hàng nhập tự do; ngày dạng “19 Mar 2024”; không có tỷ lệ hoa hồng	Nhất quán

Hệ thống	Lỗi được mô phỏng	Chiều chất lượng
ShopeeFood	Excel có dòng tiêu đề trước bảng; tiêu đề cột tiếng Việt; mã cửa hàng khác	Biểu diễn, nhất quán
Sổ nhập kho	Mẫu A có tiêu đề phiếu, tên có dấu, dòng "Tổng cộng"; mẫu B tiếng Anh không dấu, số lượng dính đơn vị ("53.6kg"); khoảng 5% tên viết tắt; khoảng 0,5% số lượng gõ theo gam vào cột kilôgam	Hợp lệ, nhất quán
Phiếu kiểm kê	Sai số đếm tay khoảng ±2%; khoảng 2% ô bỏ trống	Chính xác, đầy đủ
Máy chấm công	Khoảng 3% lượt quẹt bị ghi trùng; khoảng 5% ca thiếu lượt quẹt ra	Duy nhất, đầy đủ

Nguồn: Đề xuất của nghiên cứu

3.3.4. Kịch bản sự cố và tập đánh giá

Sự cố được đưa vào thế giới chứ không vào từng tệp, nên tự để lại dấu vết ở mọi nguồn liên quan. Khóa luận thiết kế hai tập kịch bản độc lập với hạt giống ngẫu nhiên riêng (Bảng 3.7). Tập kiểm tra cố ý khó hơn: sự cố nhẹ hơn, một số rơi vào chi nhánh nhỏ có ít dữ liệu, và vào sàn khác.

Bảng 3.7. Hai tập kịch bản sự cố

Vấn đề	Tập phát triển	Tập kiểm tra
P1a. Sàn tính sai hoa hồng	S1: CN4, GrabFood, 13/5–2/6; 30% thay vì 25%	H1: CN10, ShopeeFood, 5/8–18/8; 26% thay vì 22%
P1b. Đơn sàn không nhập POS	S2: CN6, 15/7–28/7; 20% đơn	H2: CN3, 22/4–5/5; 15% đơn
P2. Hao hụt nguyên liệu tươi	S3: CN7, 10/4–20/4; hao hụt ×1,15–1,30	H3: CN1, 3/6–14/6; ×1,12–1,25
P3. Thiếu nhân sự ca tối	S4: CN2, 6/5–19/5; điều 55% nhân viên ca tối sang ca sáng	H4: CN8, 22/7–31/7; điều 45%
P4. Thất thoát kho	S5: CN9, 17/6–30/6; mất 1,5%/ngày tồn thịt, tôm, phô mai	H5: CN5, 12/8–25/8; mất 1,2%/ngày
P5. Gian lận tại quầy	S6: CN8, 1/7–28/7; một thu ngân hủy 12% hóa đơn tiền mặt sau khi thu tiền	H6: CN10, 1/4–28/4; tỷ lệ 10%

Nguồn: Đề xuất của nghiên cứu

Mọi lựa chọn về phương pháp, cửa sổ thời gian và ngưỡng chỉ được thực hiện trên tập phát triển; tập kiểm tra chỉ chạy một lần khi các bộ phát hiện đã cố định. Chỉ có một điều chỉnh đối với tập kiểm tra: H6 ban đầu đặt ở chi nhánh nhỏ nhất trong ba tuần chỉ tạo ba hóa đơn gian lận, quá ít để phân biệt với nhiễu, nên được chuyển sang một chi

nhánh hạng B trong bốn tuần. Điều chỉnh này dựa trên độ lớn tác động và được làm trước khi xây dựng bộ phát hiện nào, nên không ảnh hưởng tính độc lập của đánh giá.

3.3.5. Hiệu chỉnh từ dữ liệu giao dịch thật công khai và giới hạn

Hóa đơn chi tiết của chuỗi F&B nằm trong hệ thống nội bộ, không thể thu thập hợp pháp từ bên ngoài, nhưng các quy luật thống kê của hành vi mua hàng có thể ước lượng từ bộ dữ liệu giao dịch thật đã công bố ẩn danh. Đây là bước mô hình hóa dữ liệu đầu vào (input modeling) của phương pháp mô phỏng (Law, 2015). Bộ dữ liệu tham chiếu phải là giao dịch thật chứ không của doanh nghiệp giả định, thuộc loại hình bán đồ ăn, thức uống tại quầy, có từng giao dịch kèm thời điểm và món, và có giấy phép sử dụng; các bộ "đơn hàng nhà hàng" phổ biến được mô tả là của nhà hàng giả định nên bị loại. Bộ được chọn là The Bread Basket, giao dịch thật của một tiệm bánh tại Edinburgh trên OpenML (mã 43422, giấy phép CC0) (Vanschoren et al., 2013), gồm 9.465 giao dịch trong 159 ngày. Toàn bộ việc ước lượng nằm trong `simulator/calibrate_public.py` để tái lập.

Độ dao động theo ngày cần ước lượng cẩn thận. Độ lệch chuẩn thô của logarit số giao dịch mỗi ngày sau khi loại hệ số thứ là 0,381, nhưng con số này gồm cả xu hướng mùa và nhiễu do quy mô nhỏ, trung bình chỉ 59,5 giao dịch mỗi ngày. Độ dao động vì vậy được ước lượng lại theo ba bước: loại xu hướng bằng trung vị trượt 28 ngày, dùng ước lượng vững 1,4826 × MAD, và trừ phần phương sai do bản chất Poisson, xấp xỉ $1/\overline{\lambda}$ trên thang logarit:

$$\sigma^2_{\text{thêm}} = \sigma^2_{\text{vững}} - \frac{1}{\overline{\lambda}} \tag{3.5}$$

trong đó $\overline{\lambda}$ là số giao dịch trung bình mỗi ngày. Kết quả $\sigma_{\text{thêm}} = 0{,}075$, rất gần giá trị 0,08 đã giả định trước, tức giả định ban đầu được dữ liệu thật xác nhận. Bảng 3.8 cho thấy từng quy luật được xét riêng về khả năng chuyển giao: chỉ những quy luật phản ánh hành vi mua hàng chung của loại hình bán tại quầy mới được đưa vào.

Bảng 3.8. Kết quả hiệu chỉnh tham số từ dữ liệu giao dịch thật

Quy luật thống kê	Dữ liệu thật	Giả định trước	Sau hiệu chỉnh	Chuyển giao sang bộ mô phỏng?
Số món khác nhau mỗi đơn (1 / 2 / 3 / ≥4)	41,7% / 32,3% / 15,5% / 10,4%	55% / 30% / 12% / 3%	42% / 32% / 16% / 10%	Có. Hành vi chọn món chính kèm đồ uống, đồ ăn kèm tương đồng giữa các loại hình phục vụ nhanh
Số lượng mỗi dòng món (1 / 2)	92% / 8%	90% / 10%	92% / 8%	Có
Độ tập trung món bán chạy	Món đầu 26,7% số phần, 5 món đầu 59,1%; Zipf số mũ 1,06	Gần như đồng đều	Zipf 1,06	Có, chỉ lấy độ dốc; thứ tự món là giả định
Độ dao động theo ngày	0,075 (công thức 3.5)	0,08	0,075	Có; xác nhận giả định
Hệ số ngày trong tuần	Thứ Bảy 1,51; Chủ nhật 0,92	Thứ Bảy 1,20; Chủ nhật 1,15	Giữ giả định	Không. Tiệm bánh ở khu du lịch có nhịp cuối tuần khác chuỗi đồ ăn nhanh phục vụ gia đình
Phân bố theo giờ	Cao điểm 10h–13h, gần như không bán sau 17h	Hai cao điểm trưa và tối	Giữ giả định	Không. Tiệm bánh đóng cửa chiều

Nguồn: Tính toán từ dữ liệu The Bread Basket (OpenML, 2022)

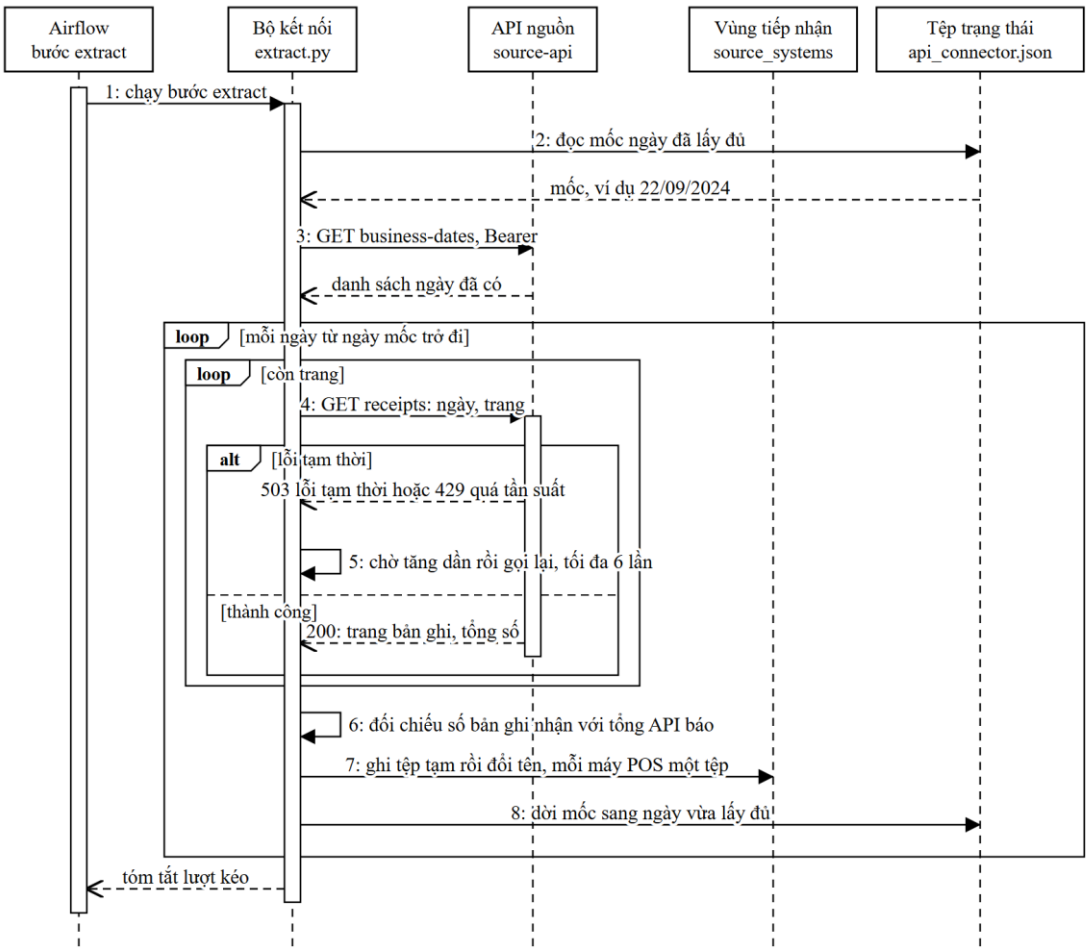
Các tham số hành vi còn lại, như hệ số ngày lễ, mức giảm khách khi mưa hay độ dốc tỷ lệ hủy theo tải, phản ánh đúng chiều tác động đã biết nhưng chưa được hiệu chỉnh bằng dữ liệu thật. Hai giả định còn giới hạn phạm vi phân tích: nhân viên chỉ làm hai ca cố định nên dữ liệu không dùng để đề xuất phân ca theo giờ; khách hàng ứng dụng được chọn theo một phân phối cố định, không có rời bỏ, nên không dùng cho phân tích giữ chân hay phân khúc RFM.

3.4. Thiết kế đường ống dữ liệu

Đường ống đưa dữ liệu qua bốn chặng: tầng thu thập nhận và kiểm tra tệp, tầng Bronze lưu bản gốc, tầng Silver làm sạch và chuẩn hóa, tầng Gold tổ chức lại cho phân tích (mục 3.5). Mỗi chặng một trách nhiệm và không làm thay chặng sau, nhờ đó khi một quy tắc làm sạch thay đổi chỉ cần chạy lại từ Bronze mà không phải thu thập lại.

3.4.1. Tầng thu thập

Tầng thu thập theo bốn nguyên tắc. Thứ nhất, ba kênh API, tệp xuất tự động và tải lên ghi vào cùng một vùng tiếp nhận, mỗi nguồn một thư mục, nên phần phía sau không phụ thuộc dữ liệu đến bằng kênh nào. Thứ hai, mỗi nguồn có một hợp đồng dữ liệu khai báo định dạng, cột hoặc khóa bắt buộc và cách đọc chi nhánh, ngày từ nội dung; tệp được nhận dạng theo nội dung chứ không theo tên, và tệp sai hợp đồng bị từ chối kèm lý do. Tệp phải khớp hợp đồng trước khi được tính vị trí chuẩn, rồi mới so với tệp đang có ở vị trí đó để phân biệt bản sửa với bản trùng; tệp có nội dung giống hệt tệp khác nhưng rơi vào vị trí khác, như gửi nhầm tên ngày, bị từ chối vì nạp thêm sẽ đếm doanh thu hai lần. Thứ ba, dữ liệu API được kéo tăng dần theo mốc, như Hình 3.4: bộ kết nối lưu ngày kinh doanh cuối cùng đã lấy đủ, mỗi lượt lấy các ngày sau mốc và lấy lại chính ngày mốc để nhận hóa đơn đồng bộ trễ, xử lý lỗi tạm thời và giới hạn tần suất bằng chờ tăng dần, và chỉ ghi dữ liệu, dời mốc khi số bản ghi khớp tổng do API báo; lượt bị gián đoạn vì vậy làm tiếp đúng từ ngày chưa lấy đủ. Thứ tư, lỗi của một nguồn không làm dừng nguồn khác: API không phản hồi không chặn các nguồn tệp, phần dữ liệu thiếu được cửa chặn chất lượng phát hiện (mục 3.6) và bộ phát hiện không kết luận trên phần đó (mục 3.7.3).



Nguồn: Đề xuất của nghiên cứu

Hình 3.4. Sơ đồ tuần tự của bộ kết nối khi kéo dữ liệu qua API nguồn

3.4.2. Tầng Bronze

Tầng Bronze giữ nguyên giá trị gốc: mọi giá trị lưu dạng chuỗi, bản ghi JSON lưu nguyên văn trong cột `payload`, không ép kiểu và không loại dòng nào, kể cả dòng "Tổng cộng" của sổ kho, để khi quy tắc làm sạch thay đổi có thể xử lý lại từ bản gốc. Mỗi dòng mang siêu dữ liệu truy vết gồm tệp nguồn (`_source_file`), mã băm nội dung (`_file_hash`), số dòng trong tệp (`_row_number`), mã lô (`_batch_id`) và thời điểm nạp (`_ingested_at`); với tệp Excel dạng phiếu, các dòng tiêu đề phía trên bảng được giữ trong các cột `_doc_line_k`. Bảng nhật ký `bronze._ingest_log` ghi mọi tệp đã xử lý cùng mã băm MD5: tệp cùng nội dung bị bỏ qua, tệp bị sửa thì bản cũ bị xóa và nạp lại, tệp hỏng hoặc sai hợp đồng được ghi trạng thái và lý do mà không làm dừng các tệp khác. Dữ liệu và nhật ký của mỗi nguồn được ghi trong một giao dịch, nên lỗi giữa chừng không để lại dữ liệu dở dang.

3.4.3. Tầng Silver và giải quyết định danh

Tầng Silver chuyển mỗi bảng Bronze thành bảng sạch, đúng kiểu, đúng đơn vị và gắn với định danh chuẩn của hệ thống trụ sở (Bảng 3.9). Bảng `silver_quarantine` lưu mọi dòng bị loại cùng nguồn, tệp, số dòng gốc và quy tắc vi phạm. Bảng `silver_row_reconciliation` đối soát từng nguồn: số dòng Bronze phải bằng số dòng Silver cộng số dòng cách ly cộng số dòng cấu trúc như dòng tổng cộng, chữ ký; phần chênh không giải thích được phải bằng 0.

Bảng 3.9. Quy tắc làm sạch và chuẩn hóa chính ở tầng Silver

Nguồn	Xử lý	Dòng vi phạm
POS	Hợp nhất hai phiên bản lược đồ: nhận diện định dạng ngày, chuyển "125.000" thành số, đổi tên cột tổng tiền; tách mảng món thành bảng dòng món; xác định chi nhánh từ tiền tố máy POS; giữ hóa đơn hủy, hoàn và gắn cờ	Thiếu hoặc trùng số hóa đơn, tổng tiền không đọc được hoặc âm, không xác định được chi nhánh, hóa đơn không có món → cách ly
Ứng dụng	Đổi UTC sang giờ Việt Nam và xác định lại ngày; ánh xạ chi nhánh; ánh xạ món qua tên đã chuẩn hóa; tính thời gian chuẩn bị	Không ánh xạ được món hoặc chi nhánh → cách ly
GrabFood, ShopeeFood	Hợp nhất hai định dạng về một lược đồ; tách ngày đầu tuần từ chuỗi kỳ báo cáo; ánh xạ cửa hàng về chi nhánh; tính tỷ lệ hoa hồng hiệu dụng	Không ánh xạ được cửa hàng → cách ly
Sổ nhập kho	Hợp nhất hai mẫu; tách dòng tổng cộng, chữ ký; lấy ngày và chi nhánh từ tiêu đề phiếu hoặc đường dẫn; tách số lượng và đơn vị; ánh xạ tên nguyên liệu	Số lượng lớn hơn 20 lần trung vị cùng nguyên liệu, nghi gõ gam vào cột kg → cách ly
Phiếu kiểm kê	Lấy ngày, chi nhánh từ tiêu đề; ánh xạ mã nguyên liệu; ô trống giữ là giá trị thiếu kèm cờ, không thay bằng 0	—
Chấm công	Ánh xạ mã nhân viên; ghép cặp vào – ra; ca thiếu lượt ra được gắn cờ, không tự gán số giờ	Lượt quẹt cùng loại lặp lại trong 5 phút → cách ly
Danh mục	Dựng lịch sử hiệu lực từ các ảnh chụp danh mục: giá món, vai trò và lương nhân viên	—

Nguồn: Đề xuất của nghiên cứu

Cùng một thực thể được gọi theo nhiều cách ở các hệ thống khác nhau, và cách giải quyết được chọn theo mức ổn định của thực thể (Bảng 3.10): bảng ánh xạ do người hiểu nghiệp vụ duy trì cho 11 chi nhánh ít thay đổi, quy tắc xác định cho mã có cấu trúc, và khớp nhiều tầng cho tên nguyên liệu nhập tự do.

Bảng 3.10. Các hệ thống định danh và cách giải quyết

Thực thể	Cách gọi ở các hệ thống (ví dụ chi nhánh 1, nhân viên 12)	Cách giải quyết
Chi nhánh	Trụ sở: 1; POS: `POS-01-…`; ứng dụng: `FNF-Q3-01`; GrabFood: “Fast&Fat - District 3 (#1)”; ShopeeFood: `FASTFAT_DISTRICT3_01`; chấm công: `BR01`; sổ kho: tên trong tiêu đề phiếu	Bảng ánh xạ do người hiểu nghiệp vụ duy trì
Nhân viên	Trụ sở và chấm công: 12; POS: `NV0012`	Quy tắc chuẩn hóa xác định
Món	Trụ sở: mã 1, tên không dấu; POS: `SKU-001`; ứng dụng: mã riêng, tên có dấu	POS: quy tắc; ứng dụng: khớp tên sau khi bỏ dấu, chuẩn hóa
Nguyên liệu	Trụ sở: mã và tên không dấu; sổ kho mẫu A: tên có dấu, đôi khi viết tắt; mẫu B: tên không dấu; kiểm kê: mã `NL01`	Ba tầng: khớp chính xác sau chuẩn hóa → bảng biến thể do người hiểu nghiệp vụ lập → khớp mờ Jaro–Winkler ngưỡng 0,9; không khớp thì cách ly

Nguồn: Đề xuất của nghiên cứu

3.5. Thiết kế kho dữ liệu

3.5.1. Bảng sự kiện và ma trận bus

Kho dữ liệu được thiết kế theo phương pháp Kimball với sáu quy trình nghiệp vụ dùng chung các chiều đồng nhất. Bảng 3.11 gộp ma trận bus với hạt dữ liệu và đo lường của từng bảng sự kiện.

Bảng 3.11. Các bảng sự kiện: hạt dữ liệu, chiều liên kết và đo lường

Bảng sự kiện	Loại, hạt dữ liệu	Chiều liên kết	Đo lường chính
`fact_order`	Giao dịch; một đơn ở một kênh	Ngày, chi nhánh, kênh, nhân viên, khách hàng	Tạm tính, giảm giá, tổng tiền, cờ hủy, hoàn, hủy do cửa hàng, thời gian chuẩn bị, phút từ thanh toán đến hủy
`fact_order_line`	Giao dịch; một dòng món trong đơn	Ngày, chi nhánh, kênh, món	Số lượng, đơn giá, thành tiền, giá vốn định mức tại ngày bán
`fact_marketplace_settlement`	Ảnh chụp định kỳ; chi nhánh × sàn × tuần	Ngày, chi nhánh, kênh	Doanh thu món, số đơn, đơn hủy, hoa hồng, tỷ lệ hiệu dụng và hợp đồng, khuyến mãi, thực nhận, điểm đánh giá

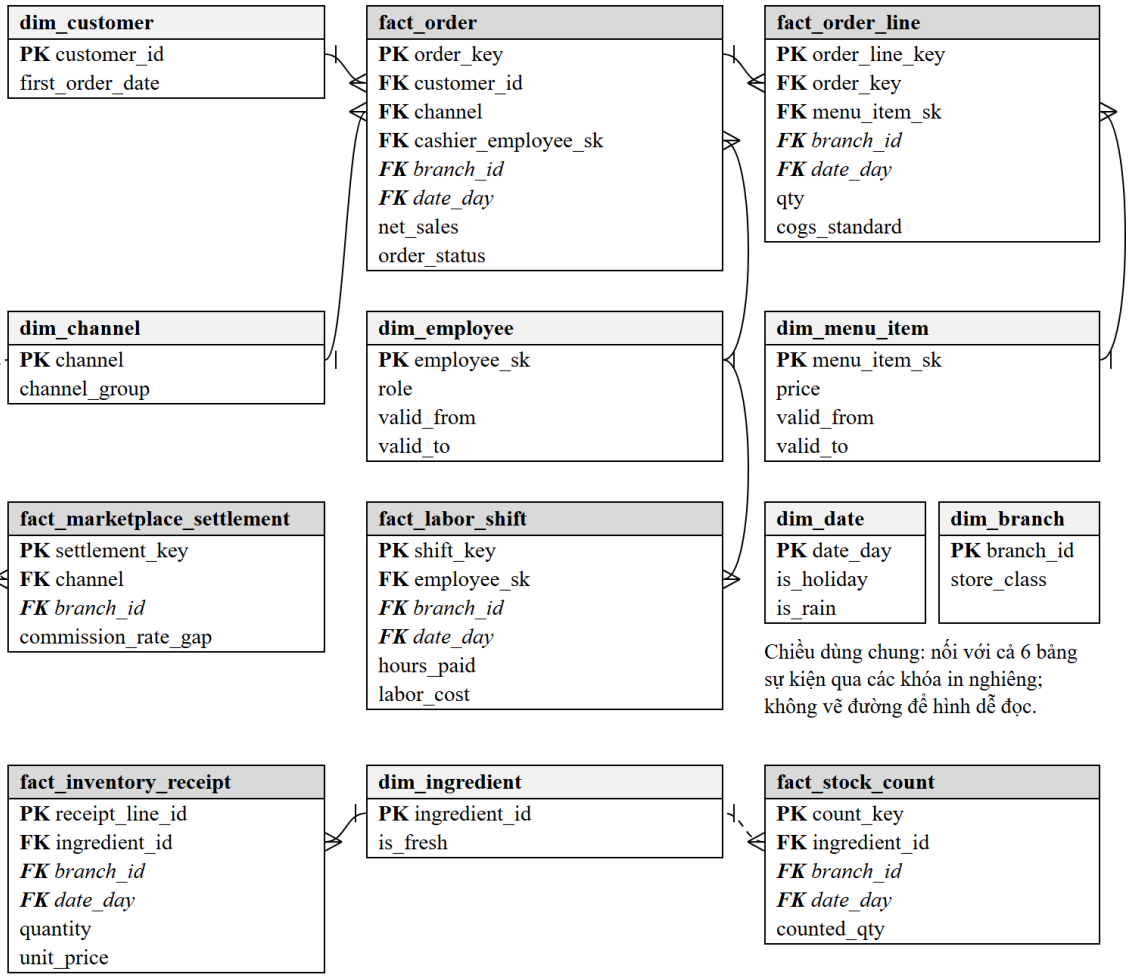
Bảng sự kiện	Loại, hạt dữ liệu	Chiều liên kết	Đo lường chính
`fact_inventory_receipt`	Giao dịch; một dòng phiếu nhập	Ngày, chi nhánh, nguyên liệu	Số lượng theo đơn vị chuẩn, đơn giá, thành tiền
`fact_stock_count`	Ảnh chụp định kỳ; chi nhánh × nguyên liệu × kỳ kiểm kê	Ngày, chi nhánh, nguyên liệu	Tồn đếm được, cờ thiếu số liệu
`fact_labor_shift`	Giao dịch; một nhân viên × một ca	Ngày, chi nhánh, nhân viên	Giờ vào, ra, số giờ, cờ thiếu lượt ra, chi phí nhân công theo lương tại ngày làm

Nguồn: Đề xuất của nghiên cứu

3.5.2. Bảng chiều và chiều thay đổi chậm

Kho có bảy bảng chiều. `dim_date` gồm thứ, cuối tuần, ngày lễ, tuần, tháng và thời tiết của ngày, vì thời tiết áp dụng chung cho toàn thành phố. `dim_branch` gồm hạng, quận, tọa độ và toàn bộ mã của chi nhánh ở các hệ thống nguồn. `dim_channel` gồm bốn kênh; `dim_ingredient` gồm đơn vị, nhóm hàng tươi hay khô và đơn giá chuẩn; `dim_customer` gồm mã khách đã băm và ngày mua đầu tiên. Hai chiều `dim_menu_item` (giá bán, giá vốn chuẩn) và `dim_employee` (vai trò, lương giờ) là chiều thay đổi chậm kiểu 2 với ngày bắt đầu, kết thúc hiệu lực và cờ bản hiện hành. Bảng sự kiện liên kết với phiên bản có hiệu lực tại ngày phát sinh, nên giá vốn định mức và chi phí nhân công đúng cả trước và sau mỗi lần điều chỉnh.

Lịch sử của hai chiều này được dựng từ chuỗi ảnh chụp danh mục có ghi ngày mà trụ sở xuất định kỳ, không dùng chức năng *snapshot* của dbt. Snapshot ghi lại trạng thái nguồn tại thời điểm đường ống chạy, nên lịch sử phụ thuộc vào những ngày đường ống đã chạy và mất đi khi kho được dựng lại; ảnh chụp có ngày cho cùng một lịch sử mỗi lần dựng lại, phù hợp với NFR1. Snapshot của dbt chỉ là lựa chọn phù hợp khi nguồn chỉ cung cấp trạng thái hiện tại. Hình 3.5 là sơ đồ quan hệ của kho, sinh trực tiếp từ siêu dữ liệu của dbt.



Nét liền: khóa ngoại có kiểm thử relationships trong dbt; nét đứt: khóa nối theo ma trận bus; chân quạ ở phía bảng sự kiện (nhiều), gạch ở phía bảng chiều (một).

Nguồn: Đề xuất của nghiên cứu

Hình 3.5. Sơ đồ quan hệ thực thể của kho dữ liệu (lược đồ hình sao), sinh từ siêu dữ liệu dbt

3.5.3. Chiến lược cập nhật kho

Kho dữ liệu lớn thường cập nhật tăng dần: mỗi lượt chỉ tính phần mới rồi gộp vào bảng cũ theo khóa. Khóa luận chọn dựng lại toàn bộ tầng Silver và Gold từ Bronze mỗi lượt, trừ hai mô hình giải mã JSON của POS và ứng dụng, vì ba lý do. Thứ nhất, nguồn được phép sửa lùi: phiếu kiểm kê đếm lại hay báo cáo sàn điều chỉnh thay bản cũ ở Bronze, và nếu gộp theo khóa thì dòng chỉ có trong bản cũ vẫn nằm lại trong kho. Thứ hai, bảng chỉ số dùng cửa sổ trượt tám tuần và so sánh giữa chi nhánh cùng tuần, nên một ngày mới hay một tệp sửa lùi làm đổi kết quả của nhiều tuần trước; tính tăng dần đúng cho các bảng này phức tạp hơn nhiều so với lợi ích. Thứ ba, ở quy mô khoảng nửa triệu dòng, một lượt dựng lại chỉ mất 15 đến 25 giây và kết quả luôn là hàm xác định của Bronze nên dễ kiểm chứng.

Hai mô hình giải mã là ngoại lệ vì tốn thời gian nhất và mỗi tệp giải mã độc lập: chúng chạy tăng dần với khóa là tệp nguồn, tệp được gửi lại bản sửa thì toàn bộ dòng của tệp đó bị xóa và giải mã lại. Như vậy NFR2 được đáp ứng ở hai bước có chi phí tăng theo lượng dữ liệu là nạp Bronze và giải mã; Silver và Gold không tăng dần nhưng vẫn lũy đẳng. Khi một lượt dbt mất tới vài phút, hướng chuyển là cập nhật theo ngày nghiệp vụ: mỗi lượt xóa rồi tính lại các ngày có tệp mới hoặc tệp sửa, cộng một khoảng lùi phủ cửa sổ tám tuần.

3.6. Thiết kế kiểm soát chất lượng dữ liệu

Kiểm soát chất lượng gồm bốn lớp nối tiếp trên đường đi của dữ liệu: hợp đồng dữ liệu ở tầng thu thập loại tệp sai cấu trúc trước khi nạp; cửa chặn chất lượng kiểm tra cả lô vừa nạp vào Bronze trước khi dbt chạy; quy tắc cách ly ở tầng Silver (Bảng 3.9); và kiểm thử dbt trên Silver, Gold sau mỗi lần dựng. Kiểm thử dbt được tổ chức theo cách dbt khuyến nghị: ràng buộc phổ biến dùng kiểm thử dựng sẵn khai báo trong tệp cấu hình mô hình; ràng buộc khóa ghép được viết thành một kiểm thử tổng quát bằng macro để dùng lại; luật nghiệp vụ riêng như bảo toàn số dòng hay khớp số tiền được viết thành kiểm thử dạng câu SQL (*singular test*), đạt khi câu truy vấn trả về rỗng (Bảng 3.12).

Bảng 3.12. Các nhóm kiểm thử chất lượng dữ liệu

Nhóm kiểm thử	Nội dung kiểm tra	Cách hiện thực	Chiều chất lượng
Khóa	Khóa của mọi bảng Silver, Gold không trùng, không rỗng; bảng chỉ số không trùng tổ hợp khóa; mỗi chi nhánh × tuần chỉ một dòng đối soát GrabFood	`unique`, `not_null`; kiểm thử tổng quát khóa ghép bằng macro; một kiểm thử SQL	Duy nhất, đầy đủ
Toàn vẹn tham chiếu	Mọi khóa chi nhánh, món, nguyên liệu, nhân viên trong bảng sự kiện tồn tại ở bảng chiều	`relationships`	Nhất quán
Miền giá trị	Trạng thái đơn, kênh, phiên bản POS, loại lượt chấm công, ca, hạng chi nhánh, sàn, cách khớp nguyên liệu thuộc danh sách cho phép	`accepted_values`	Hợp lệ
Bảo toàn số dòng	Mọi nguồn: Bronze bằng Silver cộng cách ly cộng dòng cấu trúc	Kiểm thử SQL	Đầy đủ

Nhóm kiểm thử	Nội dung kiểm tra	Cách hiện thực	Chiều chất lượng
Nhất quán số tiền	Tạm tính hóa đơn POS bằng tổng dòng món; thực nhận ở báo cáo sàn khớp công thức của báo cáo; doanh thu thuần Gold bằng tổng tính từ Silver theo chi nhánh × ngày	Kiểm thử SQL	Chính xác
Lịch sử chiều	Phiên bản của cùng món, cùng nhân viên không chồng lấn, không hở	Kiểm thử SQL	Nhất quán
Độ mới	Ngày mới nhất mỗi nguồn không cũ hơn ngưỡng: một ngày với dữ liệu ngày, tám ngày với dữ liệu tuần, mười lăm ngày với kiểm kê	Cửa chặn chất lượng, trước dbt	Kịp thời
Đầy đủ theo chi nhánh	Chi nhánh thường gửi POS, chấm công mà một ngày trong lô thiếu tệp thì cảnh báo; từ một phần ba số chi nhánh cùng thiếu thì chặn	Cửa chặn chất lượng, trước dbt	Đầy đủ

Nguồn: Đề xuất của nghiên cứu

Hai nhóm cuối chạy trên Bronze trước khi dbt dựng lại kho: nếu lô vừa nạp thiếu nghiêm trọng, đường ống dừng và kho phục vụ giữ bản trước thay vì đưa ra kết quả sai.

3.7. Thiết kế lớp phân tích

3.7.1. Các chỉ số vận hành

Các chỉ số được tính sẵn trong năm bảng chỉ số (mart) của tầng Gold theo các hạt chi nhánh × ngày, chi nhánh × tuần kèm số liệu đối soát sàn, chi nhánh × nguyên liệu × kỳ kiểm kê, thu ngân × tuần, và chi nhánh × tuần × chỉ số kèm mức kỳ vọng, điểm bất thường. Bảng 3.13 trình bày định nghĩa các chỉ số chính.

Bảng 3.13. Định nghĩa các chỉ số vận hành trong kho dữ liệu

Chỉ số	Cách tính	Nguồn (bảng Gold)
Doanh thu thuần theo kênh	Tiền món sau giảm giá của đơn hoàn thành; kênh sàn theo phần ghi trên POS, doanh thu theo báo cáo sàn dùng để đối soát	`fact_order`, `fact_marketplace_settlement`
Số đơn, AOV	Số đơn hoàn thành; doanh thu thuần chia số đơn, theo kênh và toàn chi nhánh	`fact_order`
Giá vốn định mức, COGS%	Công thức (2.2) theo phiên bản món tại ngày bán, combo tách thành món thành phần; COGS% theo (2.1)	`fact_order_line`, `dim_menu_item`

Chỉ số	Cách tính	Nguồn (bảng Gold)
Hao hụt so với định mức (AvT)	Theo kỳ kiểm kê của từng nguyên liệu: tiêu hao thực tế theo (2.3) trừ tiêu hao định mức bằng số món đã làm × công thức, quy ra tiền	`mart_ingredient_avt`
Giờ công, Labor%	Giờ ca nhân lương giờ theo phiên bản nhân viên; ca thiếu lượt ra nội suy bằng trung vị cùng ca, vai trò và gắn cờ; công thức (2.4), chỉ gồm lương giờ trực tiếp	`fact_labor_shift`, `dim_employee`
Số ca bếp tối, OPLH	Số ca theo vai trò và ca; số đơn ca tối chia số ca tối; công thức (2.5)	`fact_order`, `fact_labor_shift`
Thời gian chuẩn bị, hủy, đánh giá	Thời gian chuẩn bị đơn App và theo báo cáo sàn; tỷ lệ đơn App bị cửa hàng hủy, bị khách hủy vì chờ lâu; điểm đánh giá	`fact_order`, `fact_marketplace_settlement`
Hoa hồng hiệu dụng, chênh lệch hợp đồng	Hoa hồng chia doanh thu món theo báo cáo sàn, trừ tỷ lệ hợp đồng có hiệu lực; tiền thu thừa bằng chênh lệch nhân doanh thu món	`fact_marketplace_settlement`
Độ phủ POS đơn sàn	Số đơn sàn có trên POS chia số đơn hoàn thành theo báo cáo sàn, theo tuần	`fact_order`, `fact_marketplace_settlement`
Hủy, hoàn, giảm giá tại quầy	Theo từng thu ngân: số hóa đơn bị hủy, hoàn, có giảm giá chia số hóa đơn, so với thu ngân khác cùng chi nhánh, cùng tuần	`mart_cashier_weekly`

Nguồn: Đề xuất của nghiên cứu

Bộ chỉ số giám sát gồm 24 chỉ số thuộc sáu nhóm: kết quả kinh doanh, vận hành và nhân sự, trải nghiệm khách hàng, đối soát sàn, quầy thu ngân và chi phí. Mỗi chỉ số có một chiều bất thường: số ca bếp tối, độ phủ POS và điểm đánh giá thấp là xấu; thời gian chuẩn bị, tỷ lệ hủy và COGS% cao là xấu; doanh thu và số đơn lệch chiều nào cũng đáng chú ý.

3.7.2. Mức kỳ vọng và cây KPI truy vết nguyên nhân

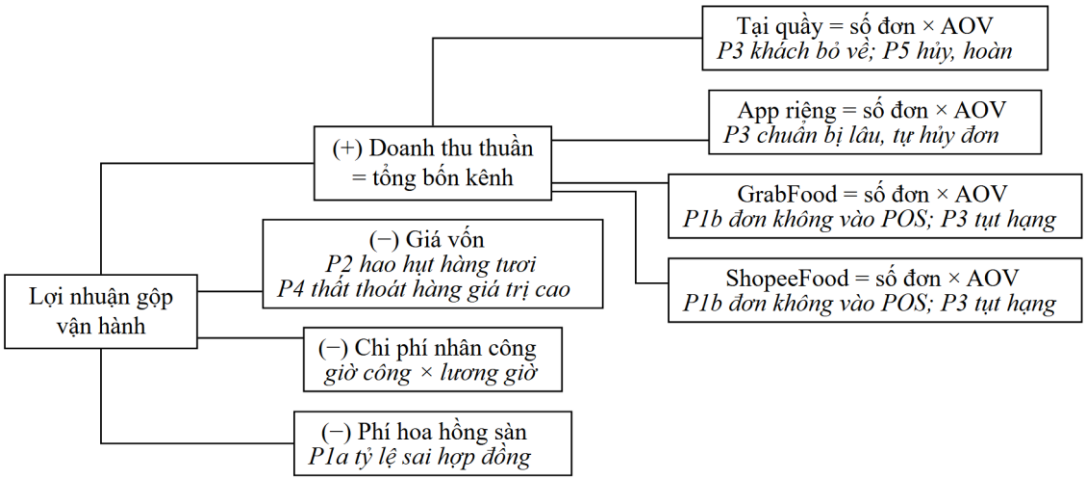
Để phân biệt biến động bình thường với biến động do sự cố, mỗi chỉ số của chi nhánh b trong tuần t được so với mức kỳ vọng gồm hai thành phần: mức của các chi nhánh cùng hạng trong chính tuần đó, và độ chênh thường ngày của b so với nhóm. Với chỉ số dạng mức, gọi $x_{b,t}$ là giá trị của chi nhánh và $m_{g,t}$ là trung vị của các chi nhánh khác cùng hạng g trong tuần:

$$r_{b,t} = \ln \frac{x_{b,t}}{m_{g,t}}, \qquad \overline{r}_{b,t} = \mathrm{med}(r_{b,t-8}, \dots, r_{b,t-1}) \tag{3.6}$$

$$\hat{x}_{b,t} = m_{g,t}\, e^{\overline{r}_{b,t}}, \qquad z_{b,t} = \frac{r_{b,t} - \overline{r}_{b,t}}{s_{b,t}} \tag{3.7}$$

trong đó $\hat{x}_{b,t}$ là mức kỳ vọng, $s_{b,t}$ là độ dao động tự nhiên bằng 1,4826 lần MAD của $r_{b,t}$ trong tám tuần trước (Rousseeuw & Croux, 1993), có sàn bằng trung vị độ dao động của các chi nhánh cùng chỉ số, cùng tuần. Với chỉ số dạng tỷ lệ, phép chia và logarit được thay bằng phép trừ.

Mỗi lựa chọn có lý do riêng. Ngày lễ, mưa hay điều chỉnh giá tác động lên cả nhóm cùng hạng nên đi vào $m_{g,t}$ và tự triệt tiêu khỏi $r_{b,t}$. Trung vị và MAD được dùng để một tuần bất thường trong quá khứ không kéo lệch mức nền các tuần sau. Sàn độ dao động tránh trường hợp tám tuần quá đều làm $z_{b,t}$ bị thổi phồng. Một chỉ số chỉ được đánh giá khi đã có ít nhất bốn tuần lịch sử.



Nguồn: Đề xuất của nghiên cứu

Hình 3.6. Cây KPI dùng để truy vết biến động doanh thu và lợi nhuận

Truy vết một chi nhánh trong một tuần đi theo cây KPI ở Hình 3.6 qua bốn bước. Bước một so doanh thu thuần với mức kỳ vọng theo (3.7): |z| từ 3 là bất thường, từ 2 là cần theo dõi. Bước hai tách doanh thu theo kênh theo (2.9), mỗi kênh thành số đơn và AOV, mỗi nút có mức kỳ vọng riêng; vì ln(doanh thu) = ln(số đơn) + ln(AOV), độ lệch của một kênh xấp xỉ tổng độ lệch hai thành phần, nên dễ thấy biến động nằm ở lượng hay giá. Bước ba đối chiếu các chỉ số vận hành gắn với nhánh đó trong cùng tuần và các tuần trước, vì một số tác động đến trễ qua thứ hạng sàn; chẳng hạn số đơn sàn giảm kèm thời gian chuẩn bị tăng, cửa hàng tự hủy đơn tăng và số ca bếp tối giảm là dấu hiệu của P3. Bước bốn xếp hạng các giả thuyết P1–P5 bằng các bộ phát hiện ở mục 3.7.3. Các nhánh chi phí như giá vốn và phí sàn không làm đổi doanh thu bán hàng, nên được giám sát trực tiếp bằng P1a, P2 và P4.

3.7.3. Thiết kế các bộ phát hiện

Mỗi bộ phát hiện cho một điểm bằng chứng từ 0 đến 6 cho một giả thuyết, ở mỗi chi nhánh và tuần. Với tín hiệu đã quy về z, điểm là phần z vượt theo đúng chiều bất thường, cắt trong [0, 6]; với kiểm định trên số đếm, xác suất đuôi được đổi ra z tương đương trước khi cắt (Bảng 3.14).

Bảng 3.14. Thiết kế năm bộ phát hiện

Bộ phát hiện	Đơn vị đánh giá	Phương pháp	Loại
P1a. Hoa hồng sai hợp đồng	Chi nhánh × sàn × tuần	Tỷ lệ hiệu dụng trên báo cáo trừ tỷ lệ hợp đồng có hiệu lực; vượt dung sai 0,5 điểm % thì nhận điểm tối đa	Luật nghiệp vụ
P1b. Đơn sàn không vào POS	Chi nhánh × sàn × tuần	Số đơn sàn báo hoàn thành mà không có trên POS so với tỷ lệ thiếu thường ngày của chi nhánh (trung vị các tuần trước, sàn 1%) bằng kiểm định Poisson; hiệu chỉnh Bonferroni cho hai sàn (Dunn, 1961)	Kiểm định
P2. Hao hụt vượt định mức	Chi nhánh × kỳ kiểm kê	Hao hụt mỗi ngày của hàng tươi giá thấp chia tiêu hao định mức thường ngày; so cắt ngang với các chi nhánh khác cùng kỳ bằng trung vị và MAD, sàn 0,5 điểm %	Thống kê
P3. Thiếu nhân sự, bếp quá tải	Chi nhánh × tuần	Trung bình điểm của năm tín hiệu: số ca bếp tối thấp, thời gian chuẩn bị App và Grab cao, tỷ lệ cửa hàng tự hủy đơn App cao, tỷ lệ khách hủy vì chờ lâu cao	Thống kê, gộp bằng chứng
P4. Thất thoát hàng giá trị cao	Chi nhánh × kỳ kiểm kê	Như P2 cho nguyên liệu giá chuẩn từ 80.000 đồng mỗi đơn vị; điểm giảm một nửa khi hàng tươi giá thấp cũng vượt, hoặc khi P1b đủ bằng chứng	Thống kê, gộp bằng chứng
P5. Gian lận tại quầy	Thu ngân × tuần	Số hóa đơn bị hủy, hoàn, giảm giá của từng thu ngân so với tỷ lệ của thu ngân khác cùng chi nhánh, cùng tuần; kiểm định Poisson, hiệu chỉnh Bonferroni theo số phép thử; chỉ xét thu ngân có từ 30 hóa đơn	Kiểm định

Nguồn: Đề xuất của nghiên cứu

Hai quyết định cần giải thích. P1a dùng luật thay vì thống kê, vì nếu sàn tính sai liên tục thì mức nền lịch sử cũng sai theo và z không bao giờ phát hiện được. P5 đánh giá từng thu ngân thay vì tỷ lệ cấp chi nhánh, vì gian lận gắn với người thực hiện và ở chi nhánh nhỏ tỷ lệ cấp chi nhánh dao động mạnh. Từ điểm bằng chứng, mỗi chi nhánh × tuần được xếp vào ba mức. Mức cảnh báo khi giả thuyết mạnh nhất có điểm từ 3,5,

hoặc doanh thu lệch kỳ vọng với |z| từ 3; trường hợp sau mà không giả thuyết nào đủ điểm thì nguyên nhân ghi là "chưa xác định", không gán bừa. Mức theo dõi khi điểm hoặc |z| từ 2; còn lại là bình thường. Ngưỡng 3,5 được chọn trên tập phát triển theo F1 lớn nhất.

Dữ liệu nguồn thiếu tạo ra đúng những tín hiệu mà bộ phát hiện tìm kiếm: thiếu tệp POS một ngày thì doanh thu thấp và đơn sàn "biến mất" khỏi POS như P1b, lượng bán thấp lại làm hao hụt tăng như P2, P4; thiếu tệp chấm công thì số ca bếp thấp như P3. Vì vậy có hai quy tắc không kết luận. Chi nhánh có ngày thiếu dữ liệu POS hoặc chấm công trong tuần thì các giả thuyết dựa trên nguồn đó chỉ ở mức theo dõi, kèm ghi chú chưa kết luận. Khi từ một phần ba số chi nhánh cùng thiếu, chẳng hạn vì API nguồn không phản hồi, trung vị nhóm so sánh bị kéo lệch, nên các giả thuyết dựa trên so sánh giữa chi nhánh, gồm doanh thu, P2, P3 và P4, cũng không kết luận. Lượt chạy sau tự đánh giá lại khi tệp về đủ; P1a dựa trên báo cáo sàn và hợp đồng nên không bị ảnh hưởng.

Mỗi cảnh báo gồm chi nhánh, tuần, nguyên nhân hạng một và hạng hai cùng điểm, bằng chứng dạng chữ như "NV0093: 20/270 hóa đơn bị hủy, tức 7,4%, thu ngân khác 1,0%", và doanh thu thực tế so với kỳ vọng. Lớp phân tích bổ sung đề xuất xử lý cho từng nguyên nhân gồm việc cần xác minh, việc cần làm, việc theo dõi, người phụ trách, thời hạn và thiệt hại ước tính, nên danh sách cảnh báo được sắp theo thiệt hại (FR6). Người phụ trách phải xác minh bằng nguồn ngoài hệ thống trước khi xử lý, vì thống kê chỉ cho biết nghi vấn; tuần kế tiếp, nếu chỉ số còn lệch so với mức kỳ vọng thì cảnh báo xuất hiện lại. Nền tảng chưa lưu trạng thái giao việc, nên việc theo dõi kết quả xử lý dựa vào chính các chỉ số tuần sau.

3.8. Thiết kế ứng dụng, kho phục vụ và điều phối

3.8.1. Ứng dụng và truy vết về dữ liệu gốc

Ứng dụng là một địa chỉ duy nhất cho người dùng nghiệp vụ và kỹ sư dữ liệu. Sau trang chủ là sơ đồ hệ thống, các trang xếp theo dòng dữ liệu thành bốn nhóm: Nguồn dữ liệu gồm kết nối nguồn, tải tệp lên và xem tệp gốc; Dữ liệu gồm vận hành hằng ngày, kho dữ liệu có ô truy vấn SQL, mô hình và phả hệ, chất lượng dữ liệu; Phân tích vận hành gồm tổng quan, trung tâm cảnh báo và truy vết nguyên nhân; Kiểm chứng gồm bộ mô phỏng và đánh giá bộ phát hiện, là nhóm duy nhất đọc đáp án và tách khỏi phần sản

phẩm. Mọi trang dùng chung bộ lọc môi trường dữ liệu, chi nhánh và khoảng thời gian; môi trường mặc định là môi trường vận hành, nơi duy nhất nhận dữ liệu mới.

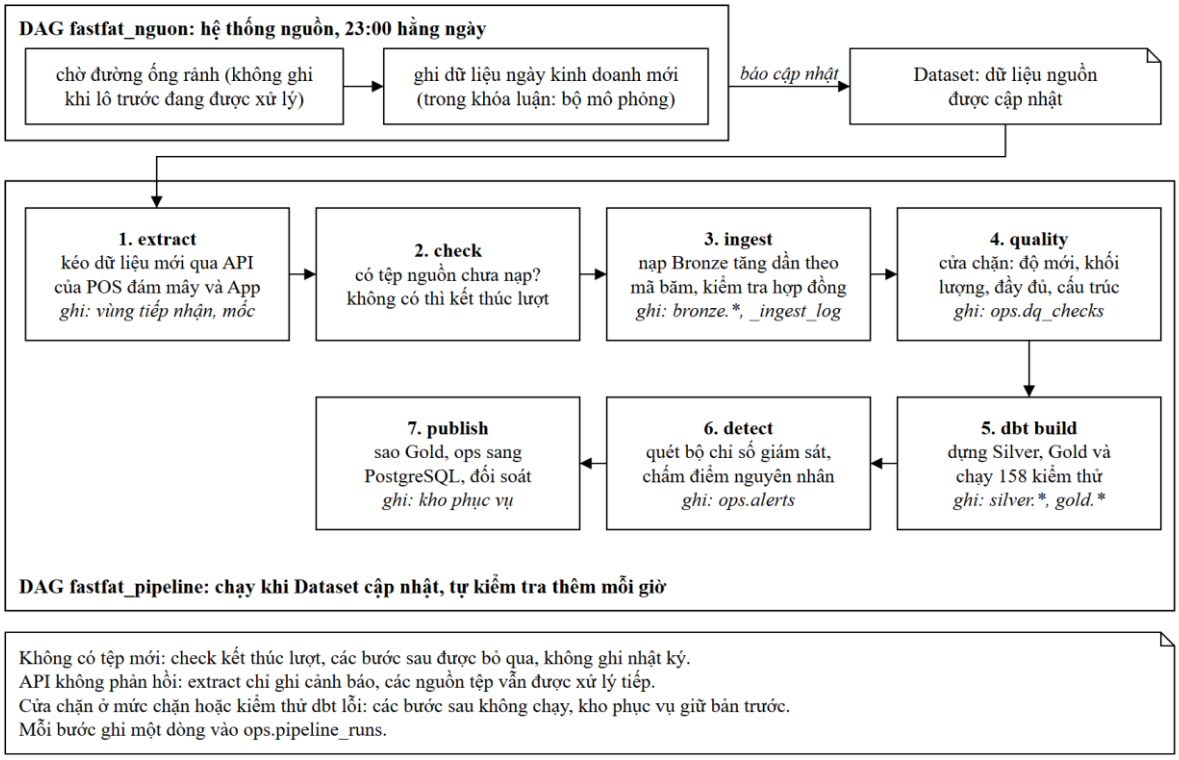
Một kết luận chỉ đáng tin khi người dùng kiểm tra lại được trên dữ liệu mà hệ thống nguồn đã xuất. Yêu cầu này được đáp ứng nhờ phả hệ ở mức bản ghi (Simmhan et al., 2005): Bronze lưu tên tệp và số dòng gốc của mỗi dòng, các tầng sau mang theo khóa bản ghi, nên từ một cảnh báo có thể đi ngược về đúng dòng trong tệp gốc. Trang Truy vết đọc kho ở chế độ chỉ đọc, chấm điểm, lập đề xuất và truy vấn các bản ghi bằng chứng kèm tên tệp, số dòng; nút mở tệp gốc chuyển sang trang Tệp nguồn, nơi tệp được đọc lại nguyên văn từ vùng tiếp nhận chứ không phải bản đã qua xử lý.

3.8.2. Kho phục vụ và công cụ BI

Sau mỗi lượt chạy thành công, tầng Gold cùng bảng cảnh báo và nhật ký vận hành được sao sang PostgreSQL: nạp vào lược đồ tạm, đối soát số dòng từng bảng với DuckDB, rồi đổi lược đồ tạm thành lược đồ chính trong một giao dịch, nên người đọc chỉ thấy bản cũ hoặc bản mới hoàn chỉnh. Metabase kết nối bằng tài khoản chỉ đọc và phục vụ các báo cáo chuẩn về doanh thu, đơn, AOV, COGS%, Labor%, kênh, chi nhánh, thực đơn và cảnh báo; ứng dụng chỉ tự xây những trang cần logic riêng như cảnh báo và truy vết.

3.8.3. Điều phối

Điều phối gồm hai đồ thị tác vụ Airflow theo đúng vai trò trong doanh nghiệp (Hình 3.7). DAG `fastfat_nguon` đóng vai hệ thống nguồn, lúc 23 giờ ghi dữ liệu của ngày kinh doanh vừa kết thúc rồi báo cập nhật một Dataset. DAG `fastfat_pipeline` là đường ống, chạy ngay khi Dataset cập nhật và tự kiểm tra thêm mỗi giờ để kéo dữ liệu API và nhận tệp do người gửi; không có tệp mới thì lượt kết thúc ngay ở bước kiểm tra. Cửa chặn chất lượng giữa Bronze và Silver kiểm tra độ mới, khối lượng so với trung vị 14 ngày, độ đầy đủ theo chi nhánh, tệp bị từ chối và thay đổi cấu trúc; mức chặn gồm nguồn hằng ngày chậm từ bốn ngày, một ngày không có dòng nào, và từ một phần ba số chi nhánh cùng thiếu. Có mục ở mức chặn hoặc một kiểm thử dbt thất bại thì các bước sau không chạy, nên không có cảnh báo hay báo cáo nào từ dữ liệu sai; API không phản hồi chỉ là cảnh báo, không chặn các nguồn tệp. Vì DuckDB chỉ cho một tiến trình ghi, mỗi lúc chỉ một lượt đường ống được chạy.



Nguồn: Đề xuất của nghiên cứu

Hình 3.7. Hai đồ thị tác vụ: hệ thống nguồn và đường ống dữ liệu kích hoạt theo dữ liệu mới

3.9. Tiểu kết chương

Chương này đã chuyển ba câu hỏi nghiên cứu thành giả thuyết thiết kế, yêu cầu và một thiết kế cụ thể có tiêu chí kiểm chứng. Bộ mô phỏng tạo một thế giới vận hành nhất quán, trong đó mỗi hệ thống nguồn chỉ thấy phần của mình và mang lỗi riêng, còn sự cố để lại dấu vết đồng thời ở nhiều nguồn. Đường ống đi qua tầng thu thập, Bronze, Silver và Gold, mỗi tầng một trách nhiệm, với kiểm soát chất lượng ở cả đầu vào lẫn bên trong kho. Lớp phân tích so mỗi chỉ số với mức kỳ vọng tính từ nhóm cùng hạng và lịch sử của chính chi nhánh, rồi dùng năm bộ phát hiện để chấm điểm từng giả thuyết nguyên nhân. Chương 4 trình bày việc hiện thực thiết kế này và các kết quả đo được.

CHƯƠNG 4. HIỆN THỰC HỆ THỐNG

Chương này trình bày việc cài đặt các thành phần đã thiết kế ở Chương 3 và kết quả kiểm chứng từng thành phần theo thứ tự dòng dữ liệu: bộ mô phỏng, tầng thu thập và Bronze, khám phá dữ liệu thô, Silver, Gold, khám phá dữ liệu đã làm sạch, bộ phát hiện, kho phục vụ, ứng dụng và điều phối. Các số liệu đều được đo trực tiếp trên hệ thống.

4.1. Môi trường và cấu trúc mã nguồn

Bảng 4.1. Môi trường hiện thực

Thành phần	Phiên bản, cấu hình
Máy tính	AMD Ryzen 5 5600H, RAM 16 GB, Windows 11 Home
Ngôn ngữ và xử lý dữ liệu	Python 3.12.4; pandas 3.0.6, NumPy 2.5.3, PyArrow 25.0.1, openpyxl 3.1.5
Kho dữ liệu và biến đổi	DuckDB 1.5.6; dbt-core 1.12.5, dbt-duckdb 1.11.0
Kho phục vụ và báo cáo	PostgreSQL 16.15; Metabase 0.58.36.1
Ứng dụng	Streamlit 1.65.0
Điều phối	Apache Airflow 2.10.5, Docker Compose (Docker 29.4)
API nguồn giả lập	FastAPI 0.143.3, Uvicorn 0.34.0

Nguồn: Cấu hình thực nghiệm

Mã nguồn được tổ chức theo đúng ranh giới kiến trúc: `simulator/` đóng vai các hệ thống nguồn, `source_api/` là API giả lập phía nguồn, `pipeline/` gồm thu thập, nạp, cửa chặn chất lượng và điều phối từng bước, `dbt/` gồm các mô hình Silver, Gold và kiểm thử, `analytics/` gồm bộ phát hiện, đề xuất xử lý và chương trình đánh giá, `app/` là ứng dụng, `airflow/` và `docker/` là cấu hình điều phối. Đáp án nằm trong thư mục `ground_truth/` của từng tập và chỉ được đọc bởi phần kiểm chứng, phần đánh giá và trang Bộ mô phỏng; `pipeline/`, `dbt/` và bộ phát hiện `analytics/detect.py` không đọc thư mục này.

4.2. Hiện thực bộ mô phỏng

4.2.1. Tổ chức chương trình và sinh dữ liệu tăng dần

Bộ mô phỏng gồm năm mô-đun Python. `config.py` tập trung toàn bộ tham số nghiệp vụ (Bảng 3.5) để mọi giả định truy vết được tại một nơi. `world.py` chứa lớp `World` giữ trạng thái của thế giới như tồn kho, điểm trên sàn, lịch sử mua của khách và bộ sinh

số ngẫu nhiên; hàm `simulate_day()` lần lượt cho mỗi chi nhánh giao hàng, xếp ca, sinh nhu cầu, tính tải bếp và kết quả phục vụ từng đơn, cập nhật tồn kho và kiểm kê khi đến kỳ. `views.py` chuyển sự kiện thật thành bản ghi theo định dạng từng hệ thống và là nơi tạo các lỗi ở Bảng 3.6; `exporters.py` ghi tệp JSON, CSV và Excel; `run.py` điều khiển một lần chạy.

Sau mỗi lần chạy, toàn bộ đối tượng `World`, kể cả trạng thái bộ sinh số ngẫu nhiên, được lưu lại, nên sinh 182 ngày một lần cho kết quả giống hệt sinh 181 ngày rồi thêm một ngày. Nhờ vậy hệ thống vận hành như một doanh nghiệp đang hoạt động: mỗi ngày bộ mô phỏng thêm tệp của ngày mới và đường ống xử lý tăng dần. Hạt giống cố định là 2024 cho tập phát triển và 777 cho tập kiểm tra. Sinh một ngày của 11 chi nhánh mất khoảng một giây, toàn bộ 182 ngày khoảng 3,5 phút.

4.2.2. Dữ liệu nguồn được tạo ra

Bảng 4.2. Khối lượng dữ liệu nguồn của tập phát triển (182 ngày, 11 chi nhánh)

Hệ thống nguồn	Số tệp	Dung lượng	Số bản ghi
POS	2.002	474,2 MB	339.989 hóa đơn
Ứng dụng riêng	182	106,9 MB	96.779 đơn
GrabFood	26	< 0,1 MB	286 dòng chi nhánh × tuần
ShopeeFood	26	0,2 MB	286 dòng chi nhánh × tuần
Sổ nhập kho	1.699	9,6 MB	18.424 dòng, cả dòng tổng cộng, chữ ký
Phiếu kiểm kê	143	0,9 MB	3.146 dòng
Máy chấm công	2.002	2,6 MB	42.375 lượt quẹt
Thời tiết	182	< 0,1 MB	182 ngày
Danh mục trụ sở	11	< 0,1 MB	8 ảnh chụp ban đầu và 3 ảnh chụp cập nhật

Nguồn: Kết quả thực nghiệm

Tập phát triển chứa 445.153 lượt nhu cầu, trong đó 435.279 đơn được phục vụ với tổng giá trị khoảng 38,67 tỷ đồng, AOV 88.844 đồng; gồm 227.182 đơn tại quầy, 93.664 đơn ứng dụng, 68.742 đơn GrabFood và 45.691 đơn ShopeeFood. Phần không được phục vụ gồm 1.149 lượt khách bỏ về, 2.096 đơn bị cửa hàng hủy và 4.797 đơn bị khách hủy. Tập kiểm tra có 384.918 đơn được phục vụ, khoảng 34,15 tỷ đồng. Hình 4.1 trích nguyên văn dữ liệu thô của một số nguồn, cho thấy mức độ không đồng nhất mà đường ống phải xử lý.

(a) Sổ nhập kho mẫu A `NhapKho_CN01_20240313.xlsx`

	A	B	C	D	E	F
1	PHIẾU NHẬP KHO					
2	Chi nhánh: Fast&Fat 250 Ly Chính Thắng					
3	Ngày nhập: 13/03/2024					
4						
5	STT	Tên nguyên liệu	ĐVT	Số lượng	Đơn giá	Thành tiền
6	1	Thịt bò xay	kg	1.4	141700	198380
7	2	Rau xà lách	kg	0.8	25600	20480
8	3	Cà chua	kg	0.9	19900	17910
9	4	Bắp cải	kg	1	15400	15400
10	5	Trứng gà	quả	14	3400	47600
11		Tổng cộng				299770
12						
13	Người lập phiếu: Quản lý CN01					

Tiêu đề phiếu, ô gộp, dòng Tổng cộng và chữ ký nằm lẫn trong bảng; tên nguyên liệu có dấu.

(b) Sổ nhập kho mẫu B
`receipts_CN03_20240904.xlsx`

	A	B	C
1	date	item	quantity
2	2024-09-04	Thit ga tuoi	75.7kg
3	2024-09-04	Thit bo xay	5.6kg
4	2024-09-04	Thit tom	0.8kg
5	2024-09-04	Rau xa lach	1.7kg
6	2024-09-04	Ca chua	2300kg
7	2024-09-04	Bap cai	2.0kg
8	2024-09-04	Trung ga	27.0qua

Số lượng dính đơn vị, tên không dấu hoặc viết khác; dòng Ca chua 2300kg là gam gõ vào cột kg.

(c) Báo cáo đối soát ShopeeFood `ShopeeFood_DoiSoat_20240311_20240317.xlsx`

	A	B	C	D	E	F
1	BÁO CÁO ĐỐI SOÁT ShopeeFood					
2	Kỳ đối soát: 11/03/2024 - 17/03/2024					
3						
4	Mã cửa hàng	Số đơn hoàn thành	Số đơn hủy	Doanh thu món (VNĐ)	Phí dịch vụ (VNĐ)	Khuyến mãi do quán tài tr...
5	FASTFAT_DISTRICT3_01	128	4	12247000	2694340	282000
6	FASTFAT_DISTRICT1_02	333	6	27956000	6150320	544000
7	FASTFAT_DISTRICT1_03	337	16	27398000	6027560	638000
8	FASTFAT_DISTRICT4_04	30	3	2360000	519200	38000

Báo cáo theo tuần, hai dòng tiêu đề phía trên bảng; cửa hàng ghi theo hệ mã của sàn. Bảng gốc có 11 cột, hình chỉ hiện 6 cột đầu.

(d) Cùng một phần mềm POS, hai phiên bản `POS-01/pos_export_2024-03-11.json · POS-05/pos_export_2024-03-11.json`

```
{
  "receipt_no": "POS-01-01-20240311-00001",
  "cashier_code": "NV0004",
  "txn_time": "11/03/2024 07:19:19",
  "items": [{"sku": "SKU-012", …}, …],
  "subtotal_amount": 177000,
  …,
  "pos_software_version": "v3.2.1",
  "total_paid": 177000
}
```

```
{
  "receipt_no": "POS-05-01-20240311-00001",
  "cashier_code": "NV0058",
  "txn_time": "2024-03-11T07:03:49",
  "items": [{"sku": "SKU-025", …}, …],
  "subtotal_amount": "157.000",
  …,
  "pos_software_version": "v2.8.0",
  "grand_total": "157.000"
}
```

Khác định dạng ngày giờ, tiền là số hoặc chuỗi có dấu chấm ngăn cách, tên trường tổng tiền khác nhau. Hình lược bớt các trường không liên quan (…).

(e) Máy chấm công `punch_BR01_20240311.csv`

```
employee_code,branch_code,event_type,event_time,device_id,verification_method
9,BR01,CHECK_IN,2024-03-11 06:41:44,DEV-TK-01,face
4,BR01,CHECK_IN,2024-03-11 06:46:53,DEV-TK-01,pin
11,BR01,CHECK_IN,2024-03-11 06:47:05,DEV-TK-01,face
1,BR01,CHECK_IN,2024-03-11 13:40:27,DEV-TK-01,pin
10,BR01,CHECK_IN,2024-03-11 13:47:12,DEV-TK-01,pin
```

Mã nhân viên dạng số, không phải NV0xxx; mã chi nhánh BR01.

(f) Một chi nhánh, sáu cách ghi mã

POS	`POS-01`
App riêng	`FNF-Q3-01`
GrabFood	`Fast&Fat - District 3 (#1)`
ShopeeFood	`FASTFAT_DISTRICT3_01`
Chấm công	`BR01`
Kho, kiểm kê	`CN01`

Tầng Silver ánh xạ về một mã chi nhánh duy nhất (seed `branch_code_map`).

Nguồn: Trích từ tệp nguồn của tập phát triển

Hình 4.1. Ví dụ dữ liệu thô của các hệ thống nguồn, trích nguyên văn từ tệp của tập phát triển

4.2.3. Kiểm chứng bộ mô phỏng

Trước khi dùng dữ liệu để xây dựng và đánh giá đường ống, cần kiểm chứng bộ mô phỏng tạo đúng các tác động đã thiết kế. Chương trình `validate.py`, được phép đọc đáp án vì chỉ phục vụ bộ mô phỏng, so giai đoạn sự cố với bốn tuần trước đó của cùng chi nhánh; với kịch bản thiếu nhân sự còn so với các chi nhánh cùng hạng để loại biến động chung (Bảng 4.3, Bảng 4.4).

Bảng 4.3. Tác động đo được của các kịch bản sự cố trên hai tập

Vấn đề	Tập phát triển	Tập kiểm tra
P1a	S1: hoa hồng GrabFood của CN4 bị tính 30% trong đúng ba tuần bắt đầu 13/5, 20/5, 27/5	H1: hoa hồng ShopeeFood của CN10 bị tính 26% trong hai tuần bắt đầu 5/8, 12/8
P1b	S2: tỷ lệ đơn sàn không có trên POS của CN6 tăng từ 2,6% lên 15,5%; giá trị mất dấu vết 8,52 triệu đ	H2: CN3 tăng từ 3,2% lên 16,4%; 18,70 triệu đ
P2	S3: hao hụt vượt định mức mỗi ngày của CN7 tăng từ khoảng 119 lên 801 nghìn đ	H3: CN1 tăng từ khoảng 101 lên 533 nghìn đ
P3	S4: bếp ca tối CN2 giảm từ 3,6 xuống 1,8 người; tải đỉnh 0,80 → 1,67; thời gian chuẩn bị 15,5 → 20,4 phút; khách bỏ về 1,2 → 16,9 lượt/ngày; đơn bị cửa hàng hủy 1,9 → 16,6/ngày; hệ số thứ hạng GrabFood 0,98 → 0,90 trong kỳ và 0,84 ba tuần sau. Doanh thu thấp hơn nhóm cùng hạng 16,9% trong kỳ, 6,7% ba tuần sau	H4: bếp ca tối CN8 giảm từ 4,6 xuống 3,0 người; tải đỉnh 0,66 → 0,99; thời gian chuẩn bị 13,0 → 16,0 phút; khách bỏ về 0,1 → 5,9 lượt/ngày; đơn bị cửa hàng hủy 1,3 → 4,0/ngày. Doanh thu chỉ thấp hơn nhóm cùng hạng 1,4% trong kỳ, 0,9% ba tuần sau
P4	S5: nguyên liệu bị mất tại CN9 trong 14 ngày khoảng 0,83 triệu đ	H5: CN5, khoảng 0,18 triệu đ
P5	S6: thu ngân NV0093 của CN8 hủy 60 hóa đơn tiền mặt sau khi thu tiền, 5,31 triệu đ	H6: NV0126 của CN10 hủy 29 hóa đơn, 2,62 triệu đ

Nguồn: Kết quả thực nghiệm

Bảng 4.4. Các biến động bình thường đo được (ngày không có sự cố)

Yếu tố	Tập phát triển	Tập kiểm tra
Doanh thu cuối tuần so với ngày thường	+25,0%	+25,4%
Doanh thu ngày lễ so với ngày thường	+22,7%	+21,2%
Số đơn tại quầy ngày mưa so với ngày khô	−25,9%	−25,5%
Số đơn giao hàng ngày mưa so với ngày khô	+22,4%	+21,1%
AOV trước và sau điều chỉnh giá 1/6	87.450 → 90.014 đ	87.173 → 90.141 đ

Nguồn: Kết quả thực nghiệm

Cả mười hai kịch bản đều tạo tác động đúng chỗ, đúng thời điểm và đúng chiều. S4 tái hiện đủ chuỗi nhân quả: thời gian chuẩn bị tăng, khách bỏ về, cửa hàng hủy đơn, rồi thứ hạng sàn giảm và doanh thu còn thấp nhiều tuần sau khi sự cố kết thúc; H4 nhẹ hơn có tín hiệu vận hành rõ nhưng doanh thu gần như không đổi, đúng với thực tế là

không phải lần thiếu người nào cũng gây mất doanh thu rõ rệt. Trong khi đó các yếu tố bình thường tạo biến động bằng hoặc lớn hơn tác động của sự cố: ngày lễ làm doanh thu tăng 21–23%, ngày mưa làm số đơn mỗi kênh đổi 21–26%. Vì vậy, như RQ3 đặt ra, phương pháp chỉ nhìn độ lớn biến động sẽ cảnh báo sai rất nhiều. Thiệt hại của thất thoát kho và gian lận chỉ 0,2 đến 5,3 triệu đồng, nhỏ so với doanh thu hàng trăm triệu mỗi tuần; mức này có chủ đích, vì ngoài thực tế các vấn đề này thường nhỏ lẻ, kéo dài và không lộ ra ở chỉ số tổng hợp.

4.3. Hiện thực tầng thu thập và Bronze

4.3.1. Kênh thu thập và hợp đồng dữ liệu

Danh mục nguồn và hợp đồng dữ liệu được khai báo một lần trong `pipeline/contracts.py`, dùng chung cho kênh tải lên, bước nạp và trang Kết nối nguồn (Bảng 4.5).

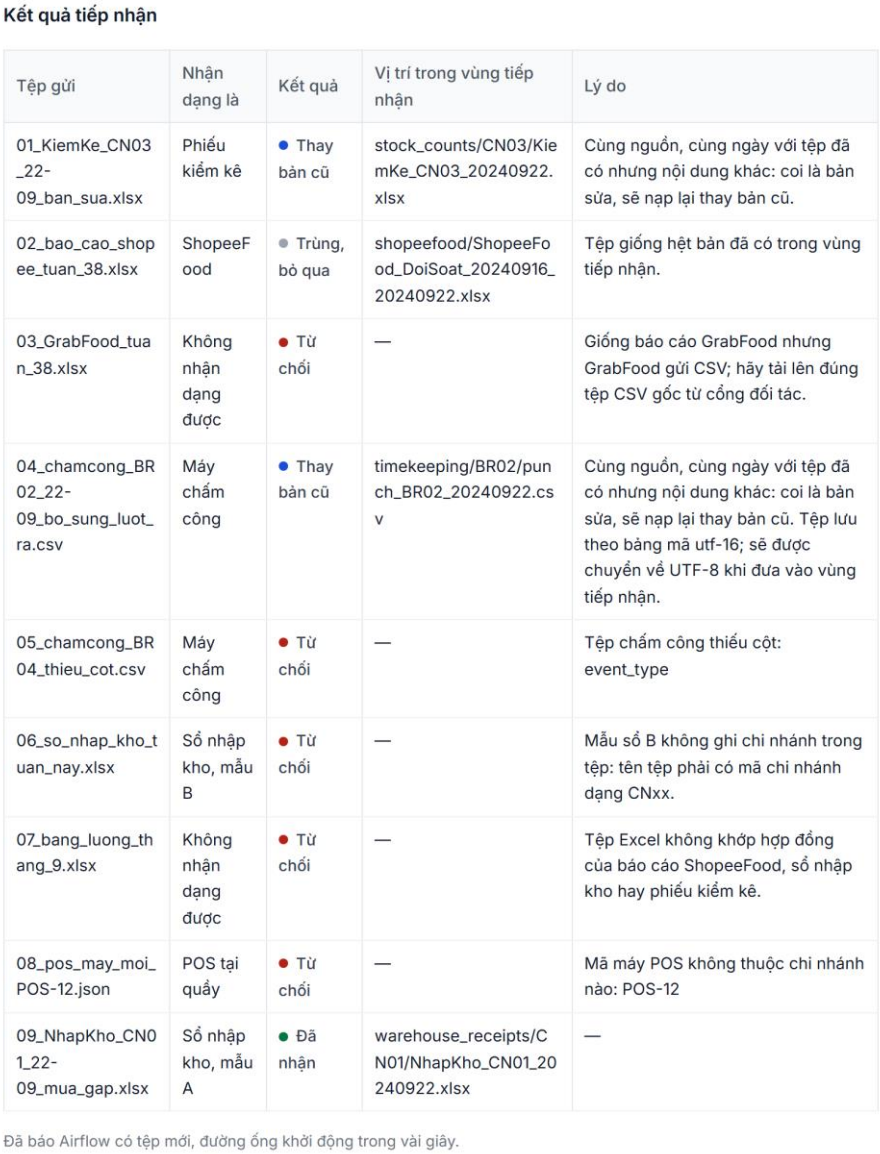
Bảng 4.5. Kênh thu thập của từng nguồn

Nguồn	Ngoài thực tế thường đến bằng	Trong hệ thống này	Tần suất
POS tại quầy	API của POS đám mây; POS cài tại máy xuất tệp mỗi đêm	8 chi nhánh dùng POS đám mây: kéo qua API; CN5, CN7, CN10 dùng POS cài tại máy: tệp JSON mỗi đêm	Hằng ngày
App đặt hàng riêng	API hoặc bản sao cơ sở dữ liệu của công ty	Kéo qua API	Hằng ngày
GrabFood, ShopeeFood	Kế toán tải báo cáo từ cổng đối tác hoặc nhận qua email	Tệp CSV, Excel vào vùng tiếp nhận hoặc tải lên	Hằng tuần
Sổ nhập kho, phiếu kiểm kê	Quản lý cửa hàng điền Excel, gửi qua email hoặc nhắn tin	Tệp Excel vào vùng tiếp nhận hoặc tải lên	Mỗi lần nhập; hai tuần
Máy chấm công	Phần mềm đi kèm máy vân tay xuất CSV	Tệp CSV vào vùng tiếp nhận	Hằng ngày
Thời tiết, danh mục trụ sở	API thời tiết; tệp xuất khi danh mục đổi	Tệp JSON, CSV vào vùng tiếp nhận	Hằng ngày; khi đổi

Nguồn: Đề xuất của nghiên cứu

Hàm nhận dạng đọc nội dung tệp chứ không dựa vào tên: từ khóa JSON, dòng tiêu đề cột của CSV hay dòng tiêu đề phiếu của Excel cho biết nguồn, chi nhánh và ngày, từ đó ra vị trí chuẩn trong vùng tiếp nhận. CSV được đọc thử lần lượt với các bảng mã UTF-8, UTF-16, Windows-1258 và Windows-1252, vì phần mềm cũ hay xuất UTF-16.

Kênh tải lên trong `pipeline/intake.py` cho bốn kết quả là đã nhận, thay bản cũ, trùng nên bỏ qua và từ chối kèm lý do; tệp được ghi ra tệp tạm rồi đổi tên trong một thao tác nên bước nạp không đọc phải tệp ghi dở, và sau khi nhận, ứng dụng báo Airflow để đường ống chạy ngay. Hình 4.2 là kết quả gửi chín tệp mẫu, gồm cả các trường hợp sai như báo cáo GrabFood lưu nhầm thành Excel, tệp chấm công thiếu cột, bảng lương gửi nhầm và tệp của một máy POS chưa khai báo.



Kết quả tiếp nhận

Tệp gửi	Nhận dạng là	Kết quả	Vị trí trong vùng tiếp nhận	Lý do
01_KiemKe_CN03_22-09_ban_sua.xlsx	Phiếu kiểm kê	Thay bản cũ	stock_counts/CN03/KiemKe_CN03_20240922.xlsx	Cùng nguồn, cùng ngày với tệp đã có nhưng nội dung khác: coi là bản sửa, sẽ nạp lại thay bản cũ.
02_bao_cao_shopee_tuan_38.xlsx	ShopeeFood	Trùng, bỏ qua	shopeefood/ShopeeFood_DoiSoat_20240916_20240922.xlsx	Tệp giống hệt bản đã có trong vùng tiếp nhận.
03_GrabFood_tuan_38.xlsx	Không nhận dạng được	Từ chối	—	Giống báo cáo GrabFood nhưng GrabFood gửi CSV; hãy tải lên đúng tệp CSV gốc từ cổng đối tác.
04_chamcong_BR02_22-09_bo_sung_luot_ra.csv	Máy chấm công	Thay bản cũ	timekeeping/BR02/punch_BR02_20240922.csv	Cùng nguồn, cùng ngày với tệp đã có nhưng nội dung khác: coi là bản sửa, sẽ nạp lại thay bản cũ. Tệp lưu theo bảng mã utf-16; sẽ được chuyển về UTF-8 khi đưa vào vùng tiếp nhận.
05_chamcong_BR04_thieu_cot.csv	Máy chấm công	Từ chối	—	Tệp chấm công thiếu cột: event_type
06_so_nhap_kho_tuan_nay.xlsx	Sổ nhập kho, mẫu B	Từ chối	—	Mẫu sổ B không ghi chi nhánh trong tệp: tên tệp phải có mã chi nhánh dạng CNxx.
07_bang_luong_thang_9.xlsx	Không nhận dạng được	Từ chối	—	Tệp Excel không khớp hợp đồng của báo cáo ShopeeFood, sổ nhập kho hay phiếu kiểm kê.
08_pos_may_moi_POS-12.json	POS tại quầy	Từ chối	—	Mã máy POS không thuộc chi nhánh nào: POS-12
09_NhapKho_CN01_22-09_mua_gap.xlsx	Sổ nhập kho, mẫu A	Đã nhận	warehouse_receipts/CN01/NhapKho_CN01_20240922.xlsx	—

Đã báo Airflow có tệp mới, đường ống khởi động trong vài giây.

Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.2. Trang Tải tệp lên sau khi gửi chín tệp mẫu (môi trường vận hành)

4.3.2. API nguồn và bộ kết nối

Để đường API được kiểm chứng như thực tế, phía nguồn có một dịch vụ FastAPI riêng (`source_api/app.py`). Ở môi trường vận hành, bộ mô phỏng ghi hóa đơn của tám chi nhánh POS đám mây và đơn App vào kho riêng của phần mềm nguồn, bên ngoài chỉ

lấy được qua API. Dịch vụ có bốn điểm cuối cho danh sách ngày và danh sách bản ghi theo ngày của POS và App, phân trang tối đa 500 bản ghi kèm tổng số để đối chiếu, xác thực bằng mã Bearer; như API thật, dịch vụ giới hạn 20 lượt gọi mỗi giây, vượt thì trả mã 429, và trả lỗi tạm thời 503 với xác suất 8%. Hai tập đánh giá vẫn đi đường tệp để kết quả đã chốt không đổi.

Bộ kết nối `pipeline/extract.py` chỉ dùng thư viện HTTP chuẩn của Python. Mỗi lượt, nó lấy các ngày sau mốc và lấy lại ngày mốc theo trang 200 bản ghi rồi so tổng với số API báo; lỗi 503, 429 hoặc mất kết nối được thử lại tối đa sáu lần với thời gian chờ 0,5 đến 8 giây hoặc theo yêu cầu của API, còn mã 401, 403 dừng ngay. Dữ liệu được ghi vào vùng tiếp nhận đúng định dạng tệp của nguồn; tệp có nội dung không đổi thì không ghi lại, nên lấy lại ngày mốc không làm đường ống nạp lại. Mốc và thống kê từng lượt được lưu trong `landing/api_connector.json`.

Bảng 4.6. Một lượt kéo bảy ngày kinh doanh 23–29/09/2024 qua API (môi trường vận hành, chạy trong Airflow)

Hệ thống	Số ngày	Bản ghi	Trang	Lần gọi	Thử lại	Tệp ghi	Thời gian
POS đám mây (8 chi nhánh)	7	10.365	55	62	6	56	7,2 giây
App đặt hàng	7	3.880	24	26	1	7	1,2 giây

Nguồn: Kết quả thực nghiệm

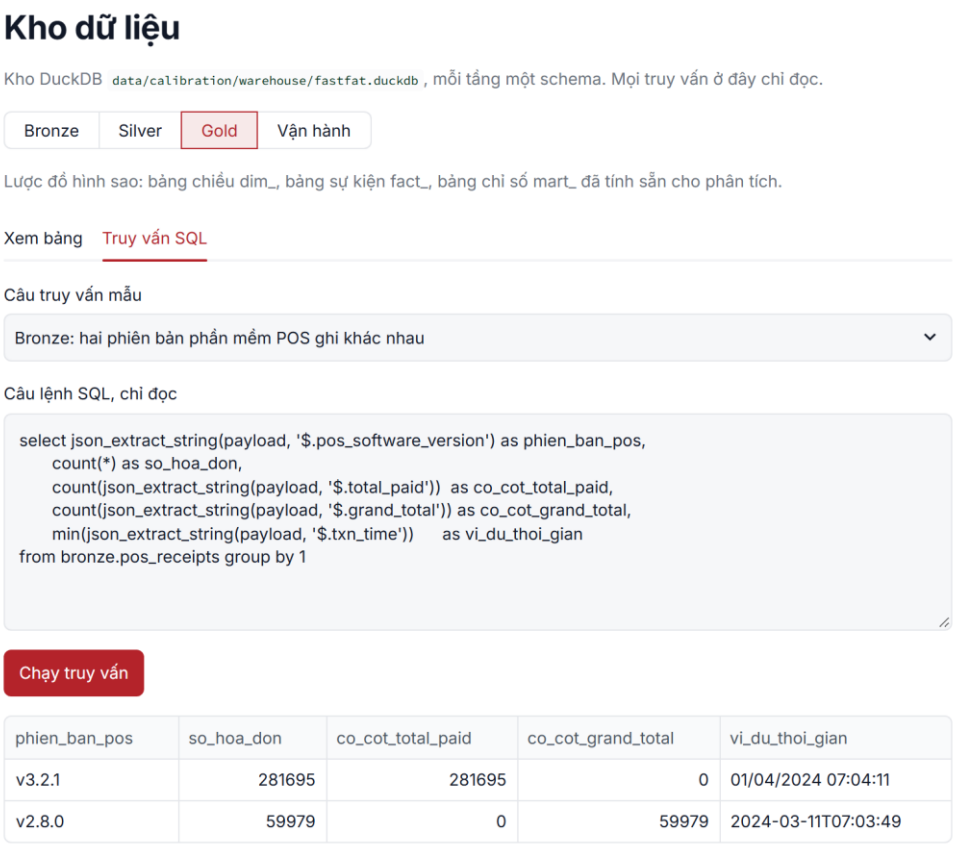
Bảy lần thử lại ở Bảng 4.6 do lỗi 503 ngẫu nhiên và đều thành công ở lần sau. Để kiểm chứng đường API không làm thay đổi dữ liệu, 56 tệp POS trong vùng tiếp nhận được so với tệp gốc trong kho của phần mềm nguồn: cả 56 giống nhau đến từng byte. Lần chạy thật đầu tiên lộ ra một lỗi: mốc khởi tạo lấy ngày mới nhất trên mọi thư mục POS, trong khi ba chi nhánh POS cài tại máy đã có tệp tới 29/09, nên mốc nhảy qua sáu ngày 23–28/09 của POS đám mây. Lỗi được sửa bằng cách lấy ngày nhỏ nhất trong các ngày mới nhất của từng máy, kèm kiểm thử hồi quy; lượt lỗi đó vô tình trở thành một phép thử thiếu dữ liệu hàng loạt (mục 5.2.3).

4.3.3. Nạp tầng Bronze

Chương trình `pipeline/ingest.py` khai báo danh sách nguồn như một bảng cấu hình gồm bảng Bronze đích, mẫu đường dẫn và bộ đọc, nên thêm một nguồn chỉ cần thêm một dòng. Bốn bộ đọc được xây dựng cho JSON của POS, JSON có vỏ bọc API

của App, CSV và Excel; bộ đọc Excel tự xác định dòng tiêu đề cột là dòng đầu tiên có từ ba ô có giá trị và giữ các dòng phía trên trong cột `_doc_line_k`. Mọi giá trị giữ dạng chuỗi; chỉ tên cột được chuyển sang dạng an toàn cho SQL, ví dụ "Doanh thu món (VNĐ)" thành `doanh_thu_mon_vnd`. Khi nguồn xuất hiện cột mới, chương trình tự thêm cột vào bảng Bronze thay vì báo lỗi. Trước khi đọc, mỗi tệp được kiểm tra theo hợp đồng của thư mục chứa nó, vì tệp có thể được thả thẳng vào vùng tiếp nhận: tệp sai hợp đồng có trạng thái `rejected`, kể cả tệp POS ngày 23/09 bị chép thành tên ngày 30/09; tệp ngoài mọi mẫu đường dẫn là `unrecognized`; tệp không đọc được là `failed`. Tệp POS rỗng là hợp lệ vì cửa hàng có thể nghỉ, nhưng cửa chặn chất lượng coi như chi nhánh đó thiếu dữ liệu.

Lần nạp đầu của tập phát triển xử lý 6.273 tệp thành 17 bảng Bronze với khoảng 502 nghìn dòng trong 80 giây, không có tệp lỗi; số dòng mỗi bảng bằng đúng số bản ghi ở Bảng 4.2. Chạy lại ngay khi không có tệp mới mất 5 giây và không tạo dòng nào. Khi bộ mô phỏng thêm ngày 09/9/2024, chương trình chỉ nạp đúng 35 tệp, 2.561 dòng của ngày đó trong 5 giây, tức chi phí hằng ngày tỷ lệ với lượng dữ liệu mới chứ không với kích thước lịch sử (NFR2). Bronze giữ nguyên mọi khác biệt của dữ liệu gốc. Hình 4.3 là một truy vấn trên trang Kho dữ liệu: 281.695 hóa đơn phiên bản 3.2.1 ghi tổng tiền ở cột `total_paid` và thời gian dạng ngày/tháng/năm, còn 59.979 hóa đơn phiên bản 2.8.0 ghi ở `grand_total` với thời gian dạng ISO; tổng hai nhóm đúng bằng 341.674 hóa đơn POS.



Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.3. Truy vấn trên tầng Bronze: hai phiên bản phần mềm POS ghi tổng tiền và thời gian theo hai cách (tập phát triển)

4.4. Khám phá dữ liệu thô

Trước khi viết quy tắc làm sạch, dữ liệu thô trong Bronze được khám phá theo trình tự ở mục 2.4.2: xác định hạt dữ liệu và khóa của từng nguồn, lập hồ sơ cấu trúc, giá trị thiếu, trùng lặp và định dạng, kiểm tra các ràng buộc nghiệp vụ, rồi xem phân phối để tìm giá trị bất thường. Mọi số liệu được tính bằng truy vấn SQL trên kho của tập phát triển, tập hợp trong chương trình `tools/kham_pha_du_lieu.py`; tập kiểm tra không được dùng ở bước này để các quy tắc không khớp theo nó.

4.4.1. Hạt dữ liệu và hồ sơ từng nguồn

Bảng 4.7 tóm tắt hồ sơ của các nguồn chính và hệ quả của từng phát hiện cho bước làm sạch.

Bảng 4.7. Hồ sơ dữ liệu thô của các nguồn chính (tập phát triển, 183 ngày)

Nguồn	Hạt dữ liệu, quy mô	Phát hiện khi lập hồ sơ	Hệ quả cho bước làm sạch
POS	Một hóa đơn, khóa là số hóa đơn, kèm mảng 1–4 dòng món; 341.674 hóa đơn	Hai cấu trúc: 281.695 hóa đơn 43 trường, 59.979 hóa đơn 39 trường ghi ngày dạng ISO và tiền dạng chuỗi "89.000"; không trùng số hóa đơn; 34 cách ghi tên cho 28 mã món; người hủy, lý do hủy trống ở 99,4% hóa đơn, số điện thoại thành viên trống ở 92%	Nhận diện phiên bản theo từng hóa đơn; nối món theo mã thay vì tên; không điền giá trị cho trường trống theo nghiệp vụ
Ứng dụng	Một đơn, khóa là mã đơn; 97.207 đơn, 30 trường	Thời gian theo UTC; bốn trạng thái đơn; giờ bếp làm xong trống ở 1% đơn vì bị hủy trước khi làm, điểm đánh giá trống ở 66,5% vì khách không chấm, nhận xét trống hoàn toàn	Đổi giờ trước khi xác định ngày, ca; điểm trung bình chỉ tính trên đơn có chấm
GrabFood, ShopeeFood	Một chi nhánh × một tuần, gộp mọi đơn sàn trong tuần; 286 dòng mỗi sàn	Mỗi sàn có 11 tên hoặc mã cửa hàng riêng; kỳ báo cáo là chuỗi "11/03/2024 - 17/03/2024"; không có tỷ lệ hoa hồng	Ánh xạ cửa hàng về chi nhánh; hạt tuần khác hạt hóa đơn nên phải cộng POS lên tuần trước khi đối soát
Sổ nhập kho	Một dòng nguyên liệu trong một lần giao; 14.116 dòng mẫu A, 4.536 dòng mẫu B	Mẫu A có 1.243 dòng tổng cộng và 1.243 dòng chữ ký nằm lẫn trong bảng; mọi số lượng ở mẫu B dính đơn vị; 73 cách viết tên cho 21 nguyên liệu; đơn vị lúc có dấu lúc không, như "quả" và "qua"	Tách dòng cấu trúc; tách số và đơn vị; ánh xạ tên ba tầng
Phiếu kiểm kê	Một chi nhánh × một nguyên liệu × một kỳ hai tuần; 3.146 dòng	77 ô trống, chiếm 2,4%	Giữ là giá trị thiếu, vì thay bằng 0 sẽ tạo hao hụt giả ở kỳ đó
Chấm công	Một lượt quẹt; hai lượt vào và ra thành một ca; 42.594 lượt của 145 nhân viên	Có lượt cùng loại lặp lại sát nhau; một phần ca chỉ có lượt vào	Cách ly lượt trùng; ghép vào và ra; gắn cờ ca thiếu lượt ra

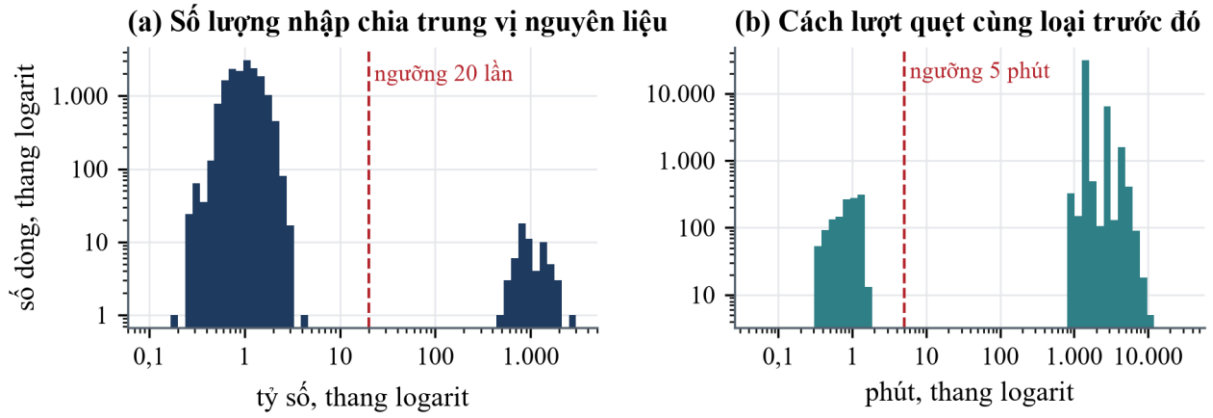
Nguồn: Kết quả thực nghiệm

Ba nhận xét từ hồ sơ quyết định cách xử lý. Thứ nhất, các nguồn có hạt khác nhau: hóa đơn POS là từng giao dịch, báo cáo sàn là tổng của một tuần, kiểm kê là tồn tại một thời điểm, hai tuần một lần. Các bảng này không nối trực tiếp được mà phải đưa về cùng

hạt, nên đối soát sàn được tính theo chi nhánh × tuần và hao hụt theo kỳ kiểm kê. Thứ hai, phần lớn giá trị trống là trống theo nghiệp vụ chứ không phải lỗi: người hủy chỉ có ở hóa đơn bị hủy, điểm đánh giá chỉ có khi khách chấm. Các trường này được giữ trống, vì điền giá trị sẽ tạo ra thông tin không có thật; chỉ trường trống do khác phiên bản, như tổng tiền của POS bản cũ, mới được lấy từ cột tương ứng. Thứ ba, các ràng buộc nghiệp vụ được kiểm tra trên dữ liệu và sau đó trở thành kiểm thử: tạm tính hóa đơn bằng tổng các dòng món, tiền thực nhận của sàn bằng doanh thu món trừ các khoản phí cộng điều chỉnh. Ràng buộc tồn đầu cộng nhập trừ tồn cuối bằng lượng tiêu hao không kiểm tra được ở từng dòng, nhưng là cơ sở để tính hao hụt ở Gold.

4.4.2. Phân phối làm căn cứ cho ngưỡng làm sạch

Hai quy tắc cách ly cần một ngưỡng: số lượng nhập kho lớn đến đâu thì bị coi là gõ nhầm gam vào cột kilôgam, và hai lượt quẹt cách nhau bao lâu thì bị coi là máy ghi trùng. Hai ngưỡng này được chọn từ phân phối của chính dữ liệu (Hình 4.4). Khi chia số lượng mỗi dòng nhập kho cho trung vị của cùng chi nhánh và nguyên liệu, 16.104 dòng nằm trong khoảng 0,2 đến 4 lần trung vị, 62 dòng từ 500 lần trở lên và không dòng nào ở giữa; ngưỡng 20 lần nằm trong khoảng trống nên kết quả cách ly không phụ thuộc vào giá trị chính xác của ngưỡng. Tương tự, khoảng cách từ một lượt quẹt tới lượt cùng loại trước đó của cùng nhân viên chia thành hai cụm: 1.290 lượt cách dưới 1,5 phút, các lượt còn lại cách ít nhất 934 phút, tức là lượt của ngày làm việc kế tiếp; ngưỡng 5 phút tách đúng hai cụm.



Nguồn: Kết quả thực nghiệm

Hình 4.4. Phân phối dùng làm căn cứ cho hai ngưỡng làm sạch, trên dữ liệu thô của tập phát triển

Khoảng trống rõ như vậy một phần là do dữ liệu được sinh từ bộ mô phỏng. Trên dữ liệu thật, hai cụm có thể chồng lấn, chẳng hạn một đợt nhập hàng cho dịp lễ lớn gấp nhiều lần bình thường; khi đó ngưỡng phải được chọn lại theo phân phối thực tế, và các dòng rơi vào vùng chồng lấn nên được cách ly để người kiểm tra thay vì tự động sửa.

4.5. Hiện thực tầng Silver

4.5.1. Tổ chức dự án dbt

Tầng Silver và Gold nằm trong một dự án dbt ở thư mục `dbt/`, chạy bằng `pipeline/run_dbt.py`; chương trình này chọn tệp kho của tập cần chạy và tách thư mục kết quả của từng tập, nên các tập được dựng độc lập bằng cùng mã nguồn. Dự án gồm 50 mô hình, 3 bảng hạt giống và 158 kiểm thử, tổng 211 bước trong một lần `dbt build`, chia theo ba lược đồ. `silver_work` chứa 10 mô hình trung gian và 3 bảng hạt giống (ánh xạ mã chi nhánh, biến thể tên nguyên liệu, ngày lễ 2024); mô hình trung gian gồm `parsed_` giải mã JSON theo chế độ tăng dần, `base_` ép kiểu và gắn mã lỗi, `checked_` áp quy tắc cần so với lịch sử, `map_` giải quyết định danh. `silver` chứa 20 bảng `stg_` đã sạch, bảng cách ly và bảng đối soát. `gold` chứa 13 bảng chiều, sự kiện và 5 bảng chỉ số. Mỗi nguồn đi qua cùng một khuôn: `base_` gắn cột `dq_issue` cho dòng vi phạm, `stg_` chỉ lấy dòng có `dq_issue` rỗng, bảng cách ly lấy phần còn lại, nên không dòng nào bị xóa im lặng.

4.5.2. Xử lý lỗi dữ liệu và giải quyết định danh

Các quy tắc ở Bảng 3.9 được hiện thực theo hai hướng: lỗi kỹ thuật bị tách khỏi dữ liệu, còn tín hiệu nghiệp vụ được giữ kèm cờ. Hai phiên bản POS được nhận diện theo từng hóa đơn rồi đưa về lược đồ chung; chẳng hạn hóa đơn bản 2.8 của CN7 ngày 12/4 ghi "2024-04-12T07:10:59" và chuỗi "89.000" ở `grand_total`, còn hóa đơn bản 3.2 của CN8 ghi "12/04/2024 07:11:22" và số 90000 ở `total_paid`. Hóa đơn hủy và hoàn được giữ lại, kèm số phút từ lúc thanh toán đến lúc hủy, vì đây là đầu vào của bộ phát hiện gian lận. Đơn App được đổi từ UTC sang giờ Việt Nam trước khi xác định ngày và ca; nếu không, mọi đơn ca tối sẽ rơi vào ca sáng. Ở sổ kho, số lượng lớn hơn 20 lần trung vị cùng nguyên liệu bị cách ly với mã `nghi_go_gam_vao_cot_kg` theo căn cứ ở mục 4.4.2, ví dụ cà chua 2.300 kg khi trung vị là 2,2 kg. Ở chấm công, lượt quẹt cùng loại lặp lại trong 5 phút bị cách ly với mã `quet_trung`, ca thiếu lượt ra được gắn

cờ mà không tự gán số giờ, ô kiểm kê trống giữ giá trị thiếu kèm cờ thay vì thay bằng 0. Số dòng chịu tác động của từng quy tắc trên hai tập được trình bày ở Bảng 5.1.

Về định danh, mã chi nhánh của sáu hệ thống được ánh xạ bằng bảng hạt giống `branch_code_map` lập từ khảo sát Bronze; mã `NV0012` của POS được chuẩn hóa về mã số của trụ sở bằng quy tắc; 28 món trên App đều khớp với danh mục trụ sở qua tên đã bỏ dấu. Tên nguyên liệu trong sổ kho đi qua ba tầng: khớp chính xác sau chuẩn hóa xử lý 38 cách viết, 84,3% số dòng; bảng biến thể 29 cách viết do người hiểu nghiệp vụ lập, chẳng hạn "gà tươi" và "thịt gà" đều là Thịt gà tươi, xử lý 35 cách viết, 15,7%; tầng khớp mờ Jaro–Winkler ngưỡng 0,9 chưa phải dùng lần nào. Thứ tự này có chủ đích: khớp mờ dễ nhầm giữa nguyên liệu tên gần nhau nên chỉ là lưới an toàn cuối cùng, và tên dưới ngưỡng được cách ly để người bổ sung vào bảng biến thể.

4.5.3. Bảo toàn số dòng

Bảng `silver_row_reconciliation` đối soát từng nguồn theo đẳng thức Bronze = Silver + cách ly + dòng cấu trúc, và kiểm thử `assert_silver_rows_conserved` thất bại nếu phần không giải thích được khác 0 (Bảng 4.8). Báo cáo GrabFood có 286 dòng ở cả hai tầng và được kiểm tra bằng hai kiểm thử riêng: mỗi chi nhánh × tuần đúng một dòng, và tiền thực nhận bằng doanh thu món trừ hoa hồng, quảng cáo, khuyến mãi cộng điều chỉnh.

Bảng 4.8. Đối soát số dòng giữa Bronze và Silver (tập phát triển, 183 ngày)

Nguồn	Bronze	Silver	Cách ly	Dòng cấu trúc	Không giải thích được
POS	341.674	341.674	0	0	0
Ứng dụng	97.207	97.207	0	0	0
ShopeeFood	286	286	0	0	0
Sổ nhập kho (hai mẫu)	18.652	16.104	62	2.486	0
Phiếu kiểm kê	3.146	3.146	0	0	0
Chấm công	42.594	41.304	1.290	0	0
Thời tiết	183	183	0	0	0

Nguồn: Kết quả thực nghiệm

4.6. Hiện thực tầng Gold

4.6.1. Bảng chiều, bảng sự kiện và bảng chỉ số

Bảng 4.9. Các bảng chiều và sự kiện của tầng Gold (tập phát triển, 183 ngày)

Bảng	Số dòng	Ghi chú hiện thực
`fact_order`	438.881	Hợp nhất 341.674 hóa đơn POS và 97.207 đơn App; trạng thái chuẩn hóa về COMPLETED, VOIDED, REFUNDED, CANCELLED_BY_STORE, CANCELLED_BY_CUSTOMER; doanh thu thuần chỉ tính COMPLETED
`fact_order_line`	851.601	Gắn phiên bản món có hiệu lực tại ngày bán để lấy giá vốn định mức
`fact_labor_shift`	21.170	1.036 ca thiếu lượt ra được nội suy số giờ bằng trung vị cùng ca, vai trò, cờ `is_hours_imputed`
`fact_marketplace_settlement`	572	Hai sàn × 11 chi nhánh × 26 tuần; tỷ lệ hợp đồng, chênh lệch, tiền thu thừa
`fact_inventory_receipt`	16.104	Dòng nhập kho hợp lệ, đơn vị chuẩn
`fact_stock_count`	3.146	Tồn đếm được, cờ ô trống
`dim_date`, `dim_branch`	183; 11	Ngày lễ từ bảng hạt giống, mưa; hạng, quận và mã chi nhánh ở mọi hệ thống
`dim_menu_item`	34	SCD kiểu 2: 28 món, 6 món có hai phiên bản do điều chỉnh giá 01/06
`dim_employee`	146	SCD kiểu 2: 145 nhân viên, 1 người lên quản lý ca từ 01/07
`dim_ingredient`, `dim_channel`, `dim_customer`	22; 4; 4.089	Nguyên liệu, kênh, khách hàng App

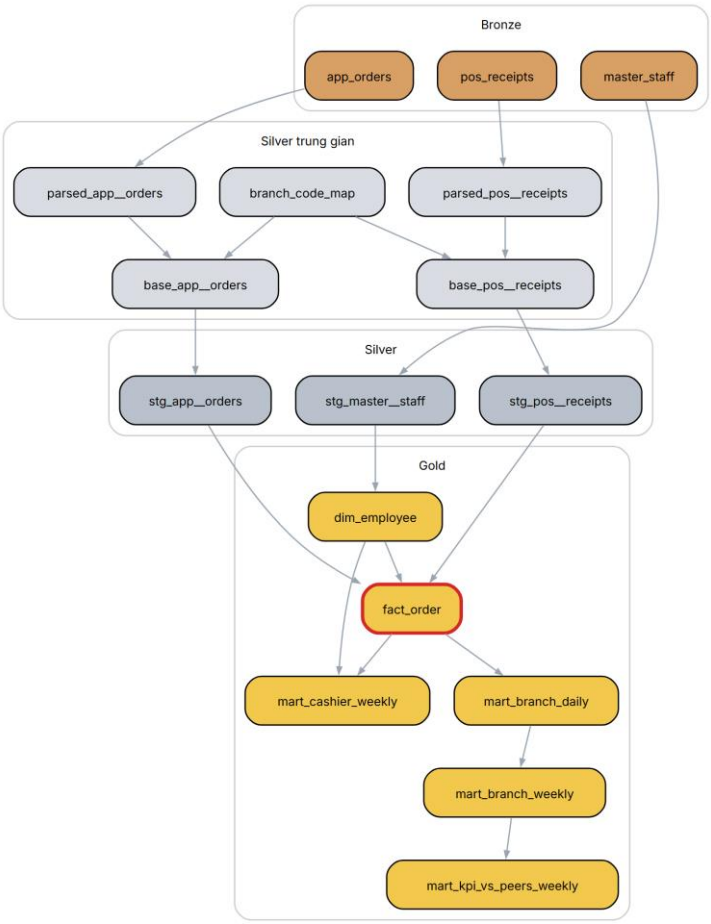
Nguồn: Kết quả thực nghiệm

Với chiều SCD kiểu 2, các ảnh chụp danh mục liên tiếp có cùng giá và giá vốn được gộp thành một phiên bản; khi giá đổi, phiên bản cũ đóng ở ngày liền trước ảnh chụp mới và phiên bản mới mở từ ngày đó. Ví dụ món Gà giòn miếng đơn có hai phiên bản: 35.000 đồng đến 31/05/2024 và 37.000 đồng từ 01/06/2024, nên giá vốn của một dòng món bán ngày 30/5 và ngày 2/6 được tính theo hai bảng giá khác nhau.

Năm bảng chỉ số ở mục 3.7.1 cũng viết bằng SQL trong dbt nên được kiểm thử và có phả hệ như mọi bảng Gold. `mart_branch_daily` có 52 cột cho mỗi chi nhánh × ngày; `mart_branch_weekly` nối với báo cáo sàn để tính độ phủ POS và chênh lệch hoa hồng; `mart_ingredient_avt` tính hao hụt theo kỳ kiểm kê, combo được tách thành món thành phần trước khi nhân công thức; `mart_cashier_weekly` tính tỷ lệ hủy, hoàn, giảm giá của

từng thu ngân và của các thu ngân còn lại. `mart_kpi_vs_peers_weekly` hiện thực công thức (3.6), (3.7) ở dạng dài, mỗi dòng là một chi nhánh × tuần × chỉ số với giá trị, trung vị nhóm, mức nền, độ dao động, z và mức kỳ vọng, gồm 10.582 dòng ở tập phát triển; trung vị và MAD cửa sổ tám tuần được tính bằng hàm cửa sổ của DuckDB.

Vì mọi biến đổi được khai báo trong dbt, phả hệ của từng bảng được sinh từ siêu dữ liệu của dự án. Hình 4.5 là phả hệ của `fact_order`: bảng được dựng từ hai bảng Bronze của POS và App qua các bước giải mã, gắn mã chi nhánh và làm sạch, lấy phiên bản nhân viên từ `dim_employee`, và là nguồn của các bảng chỉ số. Khi một con số ở Gold cần giải thích, phả hệ cho biết phải kiểm tra những bảng nào phía trước.



Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.5. Phả hệ dữ liệu của bảng fact_order, sinh từ siêu dữ liệu dbt

4.6.2. Kiểm thử

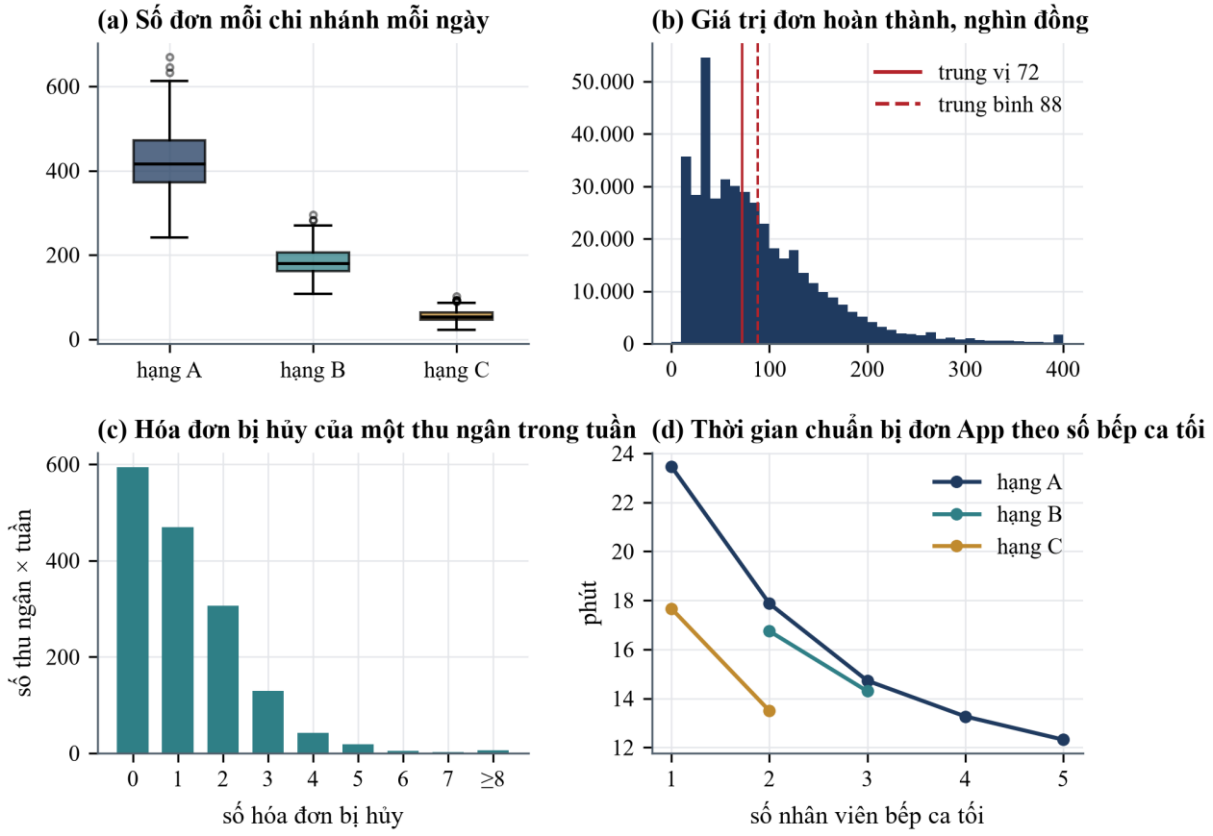
Dự án dbt có 158 kiểm thử theo các nhóm ở Bảng 3.12: 83 `not_null`, 36 `unique`, 18 `relationships` và 9 `accepted_values` khai báo trong tệp cấu hình mô hình; năm kiểm thử tổng quát `unique_combination` cho khóa ghép của năm bảng chỉ số; và bảy luật nghiệp vụ dạng câu SQL gồm bảo toàn số dòng, tạm tính POS bằng tổng dòng món,

thực nhận của hai sàn khớp công thức, một dòng GrabFood mỗi chi nhánh × tuần, SCD không chồng lấn và doanh thu Gold bằng Silver. Cả 158 kiểm thử đạt trên ba tập dữ liệu; chẳng hạn `assert_gold_net_sales_reconciles` cho thấy tổng doanh thu thuần 37.899.868.200 đồng của tập phát triển khớp tuyệt đối giữa Silver và Gold theo từng chi nhánh × ngày. Một lần `dbt build` đầy đủ mất 15 đến 25 giây, phần lớn ở hai mô hình giải mã JSON khi phải giải mã lại từ đầu.

Kiểm thử dbt kiểm tra dữ liệu nhưng không kiểm tra được mã Python của đường ống. Phần này có 89 kiểm thử pytest chạy trên dữ liệu nhỏ dựng riêng trong thư mục tạm: 12 cho bước nạp, như nạp lại không tạo dòng trùng hay tệp hỏng không làm hỏng cả lô; 10 cho hợp đồng dữ liệu; 10 cho bộ kết nối API, như thử lại khi lỗi tạm thời, lấy bổ sung hóa đơn đến trễ và làm tiếp đúng chỗ sau gián đoạn; 20 cho cửa chặn chất lượng; 4 cho bước kiểm tra tệp mới; cùng các kiểm thử cho phép thống kê của bộ phát hiện, đề xuất xử lý và ô truy vấn SQL chỉ đọc. Cả 89 kiểm thử đều đạt.

4.7. Khám phá dữ liệu đã làm sạch

Sau khi làm sạch, dữ liệu ở tầng Gold của tập phát triển được khám phá tiếp bằng phân tích đơn biến, hai biến và đa biến, với mục đích chọn cách so sánh, phép biến đổi và kiểm định cho lớp phân tích ở mục 4.8. Hình 4.6 trình bày bốn phân phối tiêu biểu và Bảng 4.10 tóm tắt các quan sát cùng quyết định rút ra.



Nguồn: Kết quả thực nghiệm

Hình 4.6. Một số phân phối của dữ liệu đã làm sạch (tập phát triển, 182 ngày)

Bảng 4.10. Từ khám phá dữ liệu đến lựa chọn phương pháp phân tích

Quan sát	Số liệu	Quyết định	Dùng ở
Ba hạng chi nhánh có quy mô tách biệt	Số đơn mỗi ngày có trung vị 417, 180 và 54 ở hạng A, B, C; khoảng từ phân vị 10 đến 90 của ba hạng không chồng lấn (Hình 4.6a)	So mỗi chi nhánh với nhóm cùng hạng, không dùng ngưỡng tuyệt đối chung	(3.6)
Biến động chung lớn	Doanh thu ngày cuối tuần gấp 1,26 lần ngày thường; ngày mưa đơn tại quầy giảm 27%, đơn App và đơn sàn tăng 19–21% (mục 5.6.2)	Lấy trung vị nhóm cùng tuần làm mốc để biến động chung tự triệt tiêu	(3.6)
Phân phối lệch phải, hiệu ứng mang tính nhân	Giá trị đơn trung bình 88.057 đ, trung vị 72.000 đ, hệ số bất đối xứng 1,99 (Hình 4.6b); hệ số ngày và mưa nhân vào số đơn	Biến đổi logarit: so ln(x/m) thay cho hiệu số, đưa hiệu ứng nhân về dạng cộng	(3.6)
Tuần bất thường kéo lệch thống kê thông thường	Độ lệch doanh thu tuần so với mức nền có độ lệch chuẩn 0,081 nhưng có tuần tới −0,22	Trung vị và MAD tám tuần thay cho trung bình và độ lệch chuẩn	(3.7)

Quan sát	Số liệu	Quyết định	Dùng ở
Số đếm nhỏ, nhiều số 0	Mỗi thu ngân × tuần có trung vị 136 hóa đơn và 1 hóa đơn bị hủy; 37,7% số tuần không có hóa đơn hủy nào (Hình 4.6c)	Kiểm định Poisson trên số đếm thay vì điểm z trên tỷ lệ; chỉ xét thu ngân từ 30 hóa đơn	P5, P1b
Giá trị rời rạc	Điểm đánh giá trên sàn chỉ có 7 giá trị từ 4,1 đến 4,7 do làm tròn 0,1	Sàn độ dao động 0,05 để MAD bằng 0 không làm z vô hạn	(3.7)
Chỉ số không đổi khi bình thường	Chênh lệch hoa hồng hiệu dụng so với hợp đồng bằng đúng 0 ở 569 trên 572 dòng	Luật dung sai 0,5 điểm % thay cho điểm z	P1a
Nhiễu kiểm kê lớn so với tín hiệu	Hao hụt so với định mức của hàng tươi có trung vị 4,3%, 80% số kỳ trong khoảng −5,3% đến 5,7%; tồn lúc kiểm kê chỉ bằng 0,6 ngày tiêu hao	So cắt ngang với chi nhánh khác cùng kỳ, tách hàng tươi và hàng giá trị cao, sàn 0,5 điểm %; P4 khó phát hiện	P2, P4
Quan hệ phi tuyến giữa nhân sự và vận hành	Ở hạng C, ca tối giảm từ hai xuống một nhân viên bếp làm thời gian chuẩn bị đơn App tăng từ 13,5 lên 17,7 phút và tỷ lệ cửa hàng hủy đơn App từ 0,9% lên 1,7% (Hình 4.6d)	Dấu hiệu P3 gộp số ca bếp tối, thời gian chuẩn bị và tỷ lệ hủy thay vì chỉ nhìn doanh thu	P3

Nguồn: Kết quả thực nghiệm

Từ các quan sát này, các phép biến đổi dữ liệu trong đường ống chia thành hai nhóm. Nhóm thứ nhất ở Silver đưa dữ liệu về dạng dùng được: ép kiểu chuỗi sang số và thời gian, đổi múi giờ, chuẩn hóa đơn vị và chuỗi ký tự, tách mảng món thành dòng, ánh xạ mã. Nhóm thứ hai ở Gold phục vụ phân tích: tổng hợp về các hạt chi nhánh × ngày, chi nhánh × tuần và kỳ kiểm kê, lấy logarit tỷ số với nhóm cùng hạng, rồi chuẩn hóa vững bằng trung vị và MAD thành điểm z.

Cần lưu ý rằng dữ liệu được sinh từ bộ mô phỏng, nên một số quan sát, như quan hệ giữa số nhân viên bếp và thời gian chuẩn bị, phản ánh lại chính giả định ở mục 3.3.2. Mục đích của bước khám phá ở đây không phải tìm quy luật kinh doanh mới mà là kiểm tra dữ liệu có những đặc điểm nào cần tính đến khi chọn phương pháp; trên dữ liệu thật, các bước này phải chạy lại và một số lựa chọn có thể thay đổi. Các tham số còn lại của bộ phát hiện, như độ dài cửa sổ mức nền, được chọn qua thử nghiệm trên tập phát triển như trình bày ở mục 4.8.

4.8. Hiện thực các bộ phát hiện và đề xuất xử lý

Các bộ phát hiện nằm trong `analytics/` và chỉ đọc tầng Gold. `config.py` khai báo bộ chỉ số giám sát, các ngưỡng và "dấu vân tay" của từng nguyên nhân, tức danh sách chỉ số cùng chiều bất thường đặc trưng cho nguyên nhân đó. `detect.py` có ba hàm chính: `scan_indicators` liệt kê chỉ số vượt ngưỡng, `score_all` chấm điểm mọi giả thuyết cho mọi chi nhánh × tuần, `alert_table` chọn giả thuyết mạnh nhất và xếp mức. Chương trình chỉ dùng thông tin có tại thời điểm đánh giá, không nhìn dữ liệu tương lai; quét 242 chi nhánh × tuần của một tập mất khoảng một giây. Bảng 4.11 ghi các tham số được chọn qua thử nghiệm trên tập phát triển; căn cứ dữ liệu của các lựa chọn còn lại đã nêu ở Bảng 4.10.

Bảng 4.11. Tham số của bộ phát hiện và lý do chọn (chỉ trên tập phát triển)

Tham số	Giá trị	Lý do
Mức nền	Trung vị 8 tuần trước	Bản đầu dùng trung bình 4 tuần; tuần 27/5 ở CN2, sau sự cố thiếu nhân sự, bị báo sai vì các tuần sự cố kéo mức nền xuống. Độ nhạy được đo ở mục 5.5.3
Độ dao động	1,4826 × MAD 8 tuần, sàn bằng trung vị các chi nhánh; điểm đánh giá sàn 0,05	Độ lệch chuẩn của 8 mẫu quá nhỏ ở vài chi nhánh gây báo sai; điểm đánh giá làm tròn 0,1 nên MAD có thể bằng 0
Lịch sử tối thiểu	4 tuần	Bốn tuần đầu của mỗi tập chỉ dùng làm mức nền
Nhóm giá trị cao (P4)	Giá chuẩn từ 80.000 đ/đơn vị	Tôm, thịt bò, phô mai, thịt gà: dễ bị lấy cắp, giá trị lớn
Thu ngân (P5)	Từ 30 hóa đơn/tuần; tỷ lệ kỳ vọng tối thiểu 0,5%	Tránh kết luận từ mẫu nhỏ; so với thu ngân khác cùng tuần vì khi gian lận kéo dài, lịch sử bị nhiễm làm điểm giảm dần
Ngưỡng z	Theo dõi 2, bất thường 3	Quy ước thông dụng, không tinh chỉnh
Ngưỡng điểm cảnh báo	3,5	F1 cao nhất khi quét 2,0–5,0 trên tập phát triển (mục 5.5.1), chốt trước khi chạy tập kiểm tra

Nguồn: Kết quả thực nghiệm

Một số quy tắc gộp bằng chứng được bổ sung khi phân tích cảnh báo sai trên tập phát triển. Ví dụ ở S2, nguyên liệu vẫn được dùng cho các đơn không vào sổ nên hao hụt hàng giá trị cao cũng tăng (z = 8,3), làm P4 hòa điểm với P1b; quy tắc giảm một nửa

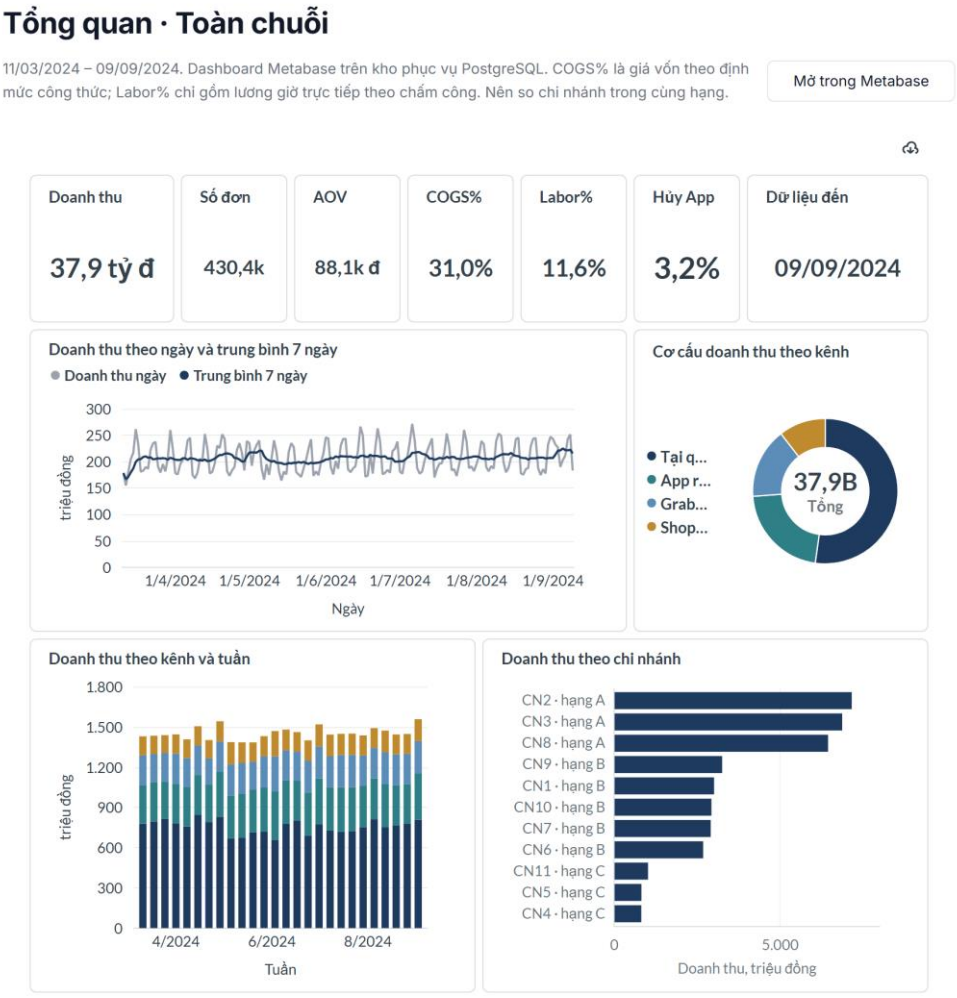
điểm P4 khi P1b đủ bằng chứng xuất phát từ quan sát này. Mọi quy tắc như vậy đều được chốt trước khi chạy tập kiểm tra.

Tệp `actions.py` lập đề xuất xử lý gồm việc xác minh, việc cần làm, việc theo dõi, người phụ trách, thời hạn và thiệt hại ước tính tính từ Gold. Với P1a đó là hoa hồng thu thừa lũy kế để kế toán đòi lại; P1b là số đơn thiếu trên POS vượt mức thường nhân giá trị đơn sàn bình quân; P2 và P4 là hao hụt vượt mức thường, với mức thường lấy theo tỷ lệ hao hụt trên định mức của các chi nhánh khác cùng kỳ; P3 là doanh thu thấp hơn kỳ vọng, đơn App bị hủy và chi phí bù ca bếp tối; P5 là giá trị hóa đơn bị hủy, hoàn, giảm giá của thu ngân nghi vấn, kèm ghi chú đây là giá trị liên quan chứ không phải số tiền đã xác định thất thoát, và không được kết luận gian lận chỉ từ thống kê. Con số này giúp xếp thứ tự xử lý: trên tập phát triển, cảnh báo hao hụt đúng ở CN7 ước tính vượt mức thường 6,83 triệu đồng, còn cảnh báo sai ở CN10 chỉ 66 nghìn đồng.

4.9. Kho phục vụ và báo cáo kinh doanh

Chương trình `pipeline/publish.py` đưa 22 bảng gồm toàn bộ Gold và bốn bảng vận hành từ DuckDB sang PostgreSQL qua phần mở rộng postgres của DuckDB; kiểu số nguyên 128 bit được đổi sang `BIGINT`. Sau khi nạp vào lược đồ tạm, chương trình so số dòng từng bảng với DuckDB, chỉ khi khớp hết mới đổi lược đồ trong một giao dịch, cấp quyền cho vai trò chỉ đọc `bi_reader`, tạo chỉ mục cho các cột hay lọc và ghi nhật ký. Mỗi lượt của môi trường vận hành đưa khoảng 1,5 triệu dòng trong 9 đến 15 giây.

Metabase được dựng hoàn toàn bằng mã trong `bi/metabase_setup.py` qua giao diện lập trình: kết nối ba cơ sở dữ liệu bằng tài khoản chỉ đọc, đặt định dạng số kiểu Việt Nam, tạo 15 câu hỏi SQL và một dashboard cho mỗi tập kèm bộ lọc khoảng ngày và chi nhánh, rồi tạo liên kết để nhúng; chạy lại cho cùng kết quả. Trang Tổng quan của ứng dụng (Hình 4.7) nhúng dashboard của tập đang chọn và truyền bộ lọc ở thanh bên qua địa chỉ, nên người dùng không phải chọn lại ở hai nơi.



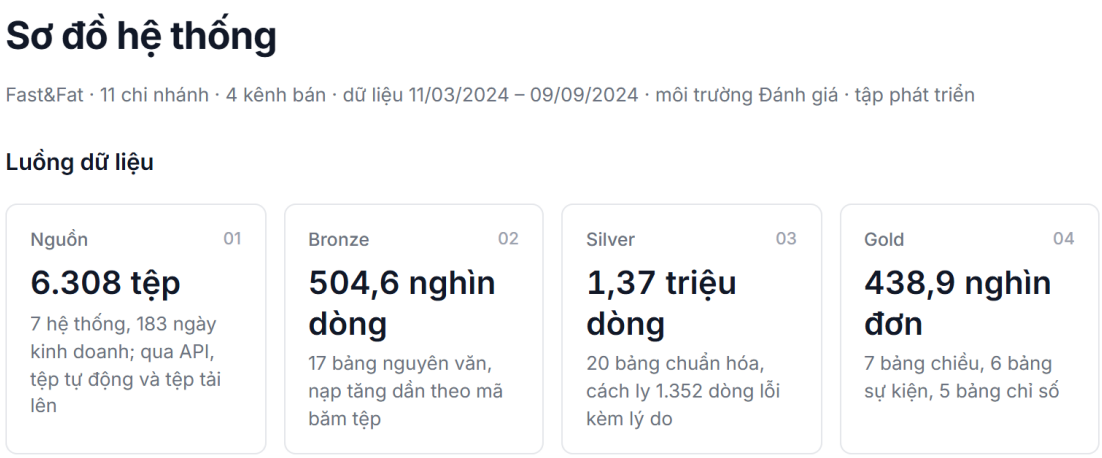
Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.7. Trang Tổng quan: dashboard Metabase trên kho phục vụ, nhúng vào ứng dụng (tập phát triển, toàn chuỗi)

4.10. Ứng dụng

4.10.1. Tổ chức ứng dụng

Ứng dụng Streamlit (`app/main.py`) có 14 trang xếp theo dòng dữ liệu như mục 3.8.1, mỗi trang một tệp trong `app/views/`. Ứng dụng chỉ mở DuckDB ở chế độ đọc, đóng ngay sau mỗi lần đọc để không giữ khóa tệp, và tự đọc lại khi đường ống vừa ghi dữ liệu mới. Trang chủ Sơ đồ hệ thống (Hình 4.8) tóm tắt các tầng, mỗi thẻ hiện số liệu hiện tại như số tệp nguồn, số dòng Bronze, số dòng bị cách ly và số đơn ở Gold.



Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.8. Trang chủ Sơ đồ hệ thống với số liệu của từng tầng (tập phát triển)

4.10.2. Các trang phân tích vận hành

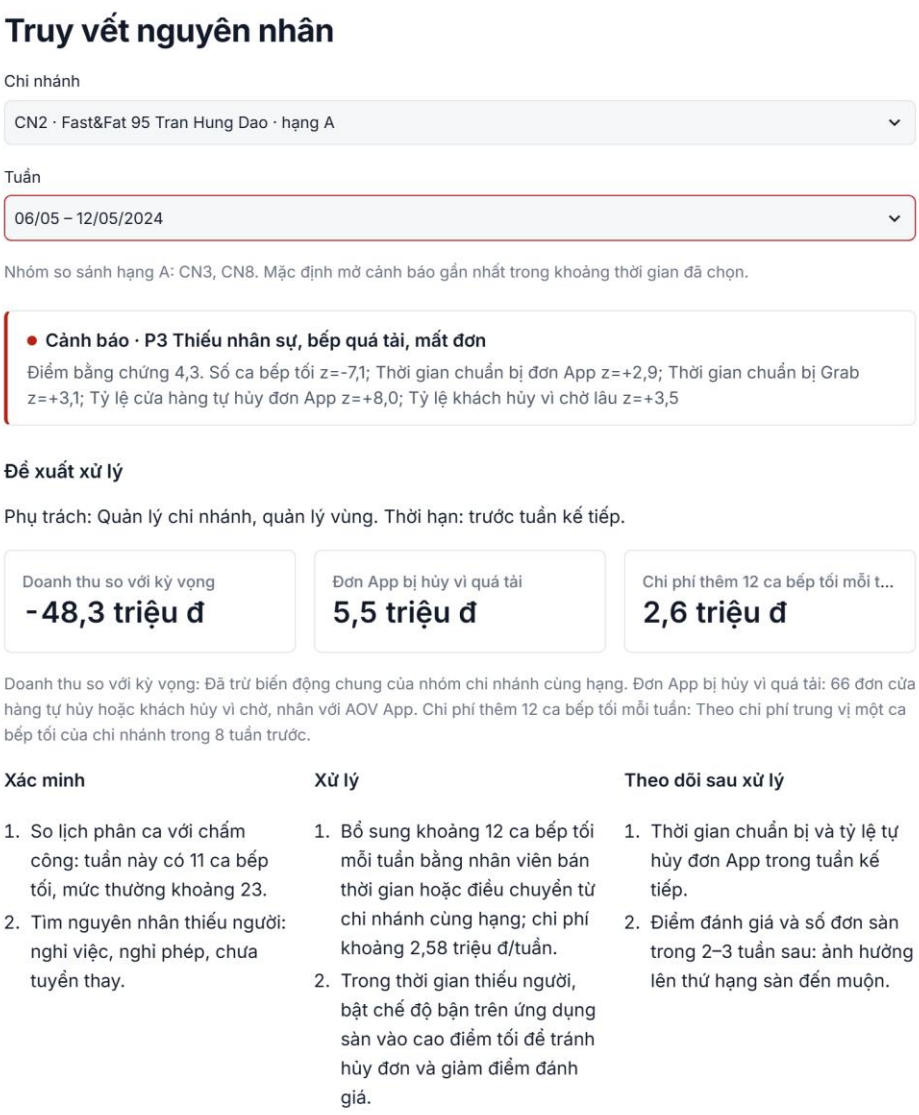
Trang Trung tâm cảnh báo (Hình 4.9) hiển thị bản đồ nhiệt mức cảnh báo theo chi nhánh × tuần và danh sách cảnh báo với nguyên nhân, điểm, bằng chứng, thiệt hại ước tính và người phụ trách, sắp theo thiệt hại; người dùng có thể thay ngưỡng điểm để xem đánh đổi giữa bỏ sót và báo động giả, và chọn một dòng để mở trang Truy vết của đúng chi nhánh, tuần đó.



Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.9. Trang Trung tâm cảnh báo (tập phát triển)

Trang Truy vết nguyên nhân mở đầu bằng kết luận và đề xuất xử lý (Hình 4.10), tiếp theo là doanh thu thực tế so với kỳ vọng qua các tuần, cây KPI theo kênh, số đơn và AOV, tín hiệu của từng giả thuyết và các yếu tố bình thường của tuần. Cuối trang là mục bằng chứng gốc, hiện thực FR8 và NFR3: trang liệt kê các bản ghi làm căn cứ cùng tên tệp và số dòng gốc mà Bronze đã lưu, và một nút mở thẳng tệp gốc ở trang Tệp nguồn với dòng đó được lọc sẵn. Ví dụ từ cảnh báo gian lận ở CN8 tuần 01/07/2024, người dùng đi tới hóa đơn POS-08-03-20240701-00065 do thu ngân NV0093 thu tiền mặt lúc 14:13 và hủy 14,8 phút sau, nằm trong tệp `pos/POS-08/pos_export_2024-07-01.json`.

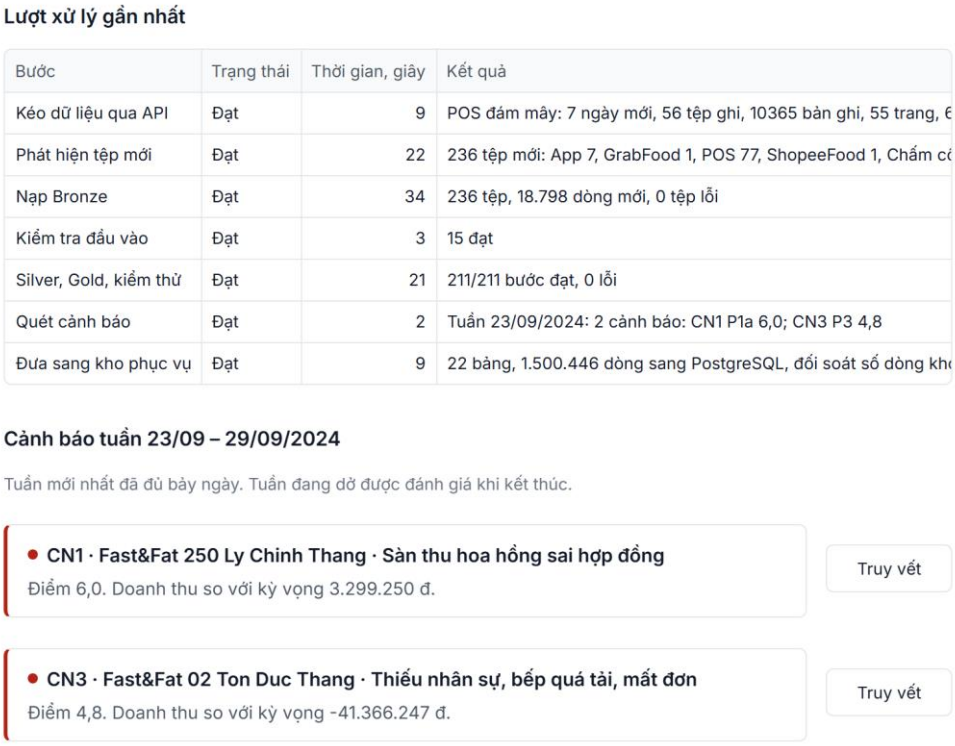


Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.10. Phần kết luận và đề xuất xử lý của trang Truy vết nguyên nhân: CN2, tuần 06/05/2024 (tập phát triển)

4.10.3. Các trang dữ liệu và kiểm chứng

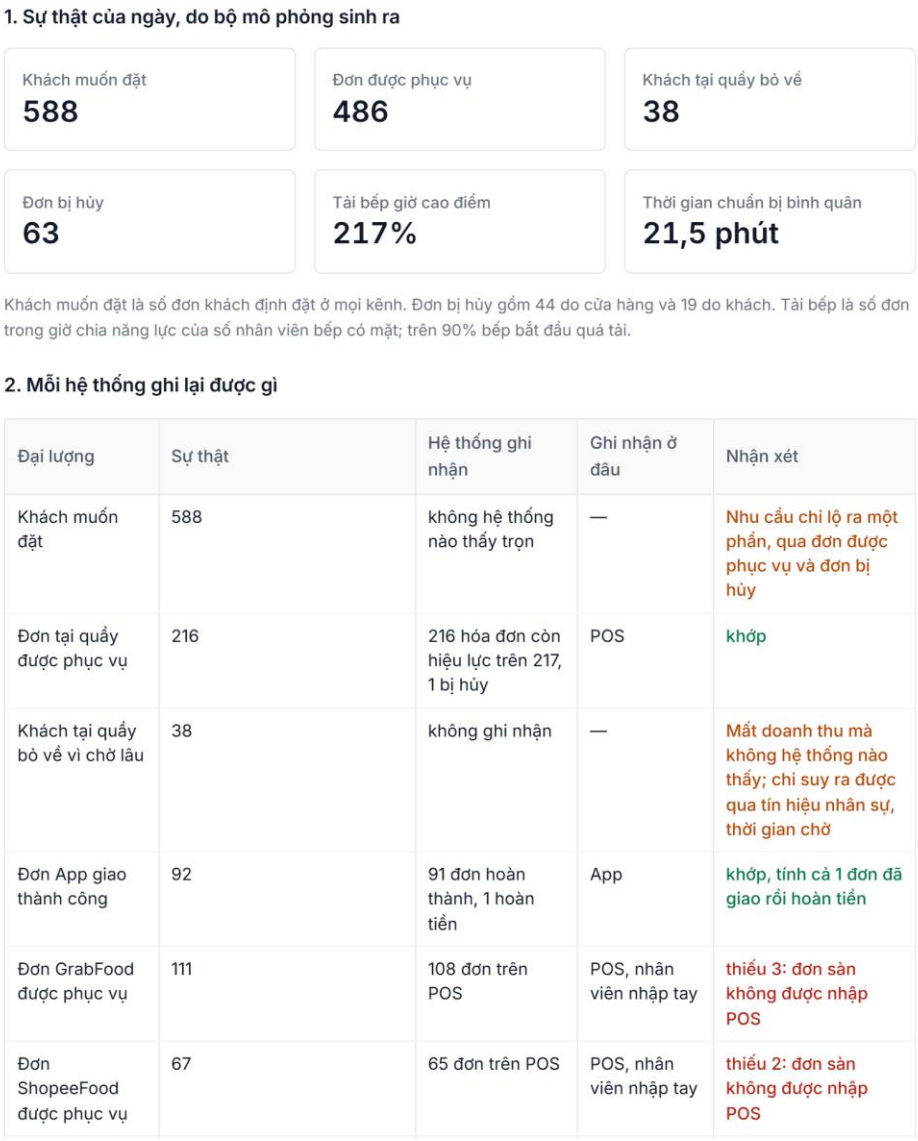
Trang Vận hành hằng ngày (Hình 4.11) cho phép đưa dữ liệu của một hoặc bảy ngày kinh doanh mới vào môi trường vận hành bằng cách kích hoạt DAG nguồn, rồi theo dõi từng bước: số bản ghi kéo qua API, tệp mới, số dòng nạp, cửa chặn chất lượng, kiểm thử dbt, cảnh báo mới và lượt đưa sang kho phục vụ; bước gặp sự cố nhưng không chặn các bước sau, như API không phản hồi, hiện ở mức cảnh báo, tách khỏi mức lỗi. Trang Chất lượng dữ liệu tổng hợp kết quả cửa chặn, kiểm thử dbt, đối soát số dòng, bảng cách ly và độ mới từng nguồn; trang Mô hình và phả hệ vẽ phả hệ và lược đồ hình sao từ siêu dữ liệu dbt nên luôn khớp với mã nguồn.



Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.11. Trang Vận hành hằng ngày sau khi đưa vào bảy ngày kinh doanh mới (môi trường vận hành)

Trang Bộ mô phỏng (Hình 4.12), thuộc nhóm Kiểm chứng, đặt con số sự thật của một ngày cạnh những gì từng hệ thống ghi lại, lấy từ kho đúng như đường ống nhìn thấy. Ở ngày 11/05/2024 của CN2, giữa kịch bản thiếu nhân sự, 216 đơn tại quầy khớp với số hóa đơn POS còn hiệu lực và 92 đơn App khớp với App, nhưng 38 khách bỏ về không được hệ thống nào ghi nhận, và 5 đơn sàn không được nhập POS lộ ra đúng bằng phần thiếu ở hai dòng GrabFood, ShopeeFood. Trang này đọc đáp án nên chỉ dùng để trình bày và kiểm chứng. Ngoài ra, ứng dụng có một trang trợ lý phân tích thử nghiệm dùng mô hình ngôn ngữ lớn gọi các hàm truy vấn có sẵn; phần này chưa được đánh giá nên không thuộc kết quả của khóa luận.



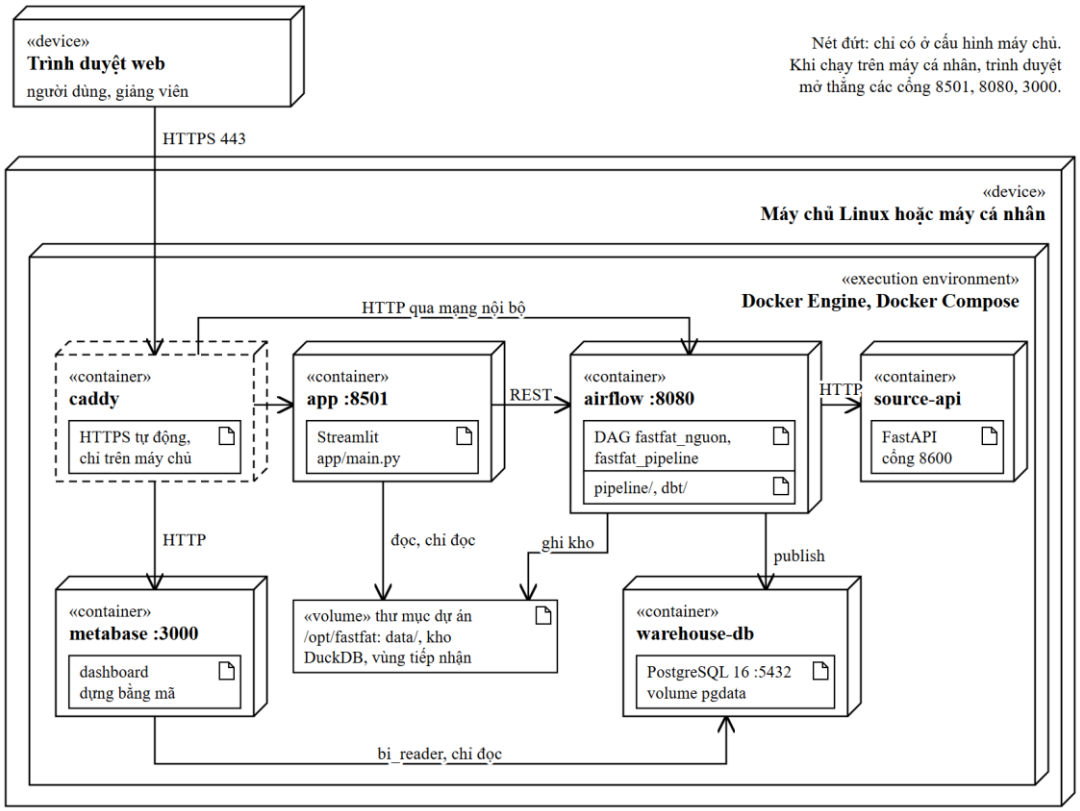
Nguồn: Ảnh chụp giao diện hệ thống

Hình 4.12. Trang Bộ mô phỏng: sự thật của một ngày đặt cạnh những gì các hệ thống nguồn ghi lại (CN2, 11/05/2024, tập phát triển)

4.11. Điều phối và vận hành tăng dần

4.11.1. Đóng gói và triển khai

Tệp `docker-compose.yml` dựng năm dịch vụ là Airflow, PostgreSQL, Metabase, ứng dụng và API giả lập phía nguồn; toàn bộ hệ thống bật bằng một lệnh `docker compose up -d`. Hình 4.13 là sơ đồ triển khai: mọi thành phần chạy trong container trên cùng một máy, giao tiếp qua mạng nội bộ của Docker; kho DuckDB nằm trong thư mục dự án, gắn vào container airflow để ghi và vào container app để đọc. Cấu hình cho máy chủ trong `deploy/` thêm một container Caddy đứng trước để cấp HTTPS và chuyển tiếp tới ba giao diện web; các cổng khác, kể cả PostgreSQL và API giả lập, không mở ra ngoài.



Nguồn: Đề xuất của nghiên cứu

Hình 4.13. Sơ đồ triển khai của nền tảng trên Docker Compose

4.11.2. Hai DAG và cơ chế kích hoạt theo dữ liệu

Tệp `airflow/dags/fastfat_pipeline.py` khai báo hai DAG như Hình 3.7. Bước ghi dữ liệu của DAG nguồn khai báo đầu ra là một Dataset, và trang Tải tệp lên cũng báo cập nhật Dataset này; DAG đường ống dùng lịch `DatasetOrTimeSchedule` nên chạy khi Dataset cập nhật hoặc vào đầu mỗi giờ. Bước `extract` gọi bộ kết nối API, và nếu API không phản hồi thì kết thúc ở trạng thái cảnh báo để các bước sau vẫn xử lý nguồn tệp. Bước `check` so các tệp với nhật ký nạp theo đường dẫn, kích thước và thời điểm sửa; không có tệp mới thì thoát với mã 99 và Airflow đánh dấu các bước sau là bỏ qua thay vì lỗi; tệp vừa được ghi trong 5 giây thì chờ thêm vì nguồn có thể còn đang ghi. Mỗi bước gọi `pipeline/run_daily.py --step <tên bước>`, nên cùng chương trình chạy được cả ngoài Airflow. Một lượt từng thất bại vì đúng lúc ghi nhật ký, ứng dụng đang mở kho để đọc; từ đó mọi chỗ đường ống mở kho đều chờ và thử lại tối đa 120 giây khi gặp lỗi khóa tệp.

4.11.3. Một lượt chạy với dữ liệu ngày mới

Môi trường vận hành, tức tập `live`, là bản sao của tập phát triển dùng riêng cho vận hành hằng ngày để hai tập đánh giá không bị thay đổi. Để minh họa luồng từ dữ liệu mới đến cảnh báo, môi trường này có hai sự cố từ ngày 23/09/2024 chỉ phục vụ trình diễn: thiếu nhân sự ca tối ở CN3 và ShopeeFood tính hoa hồng 27% ở CN1. Bảng 4.12 là nhật ký một lượt thật trong Docker: người dùng bấm gửi bảy ngày kinh doanh 23–29/09/2024 ở trang Vận hành hằng ngày, rồi Airflow tự kích hoạt đường ống mà không cần thao tác nào khác.

Bảng 4.12. Một lượt đường ống kích hoạt theo dữ liệu mới (môi trường vận hành, bảy ngày, nhật ký `ops.pipeline_runs`)

Bước	Thời gian	Kết quả ghi nhận
extract	8,6 giây	POS đám mây: 7 ngày, 10.365 hóa đơn, 55 trang, 6 lần thử lại; App: 7 ngày, 3.880 đơn, 24 trang, 1 lần thử lại
check	22,5 giây	236 tệp mới: 77 POS, 7 App, 77 chấm công, 66 nhập kho, 7 thời tiết, 1 GrabFood, 1 ShopeeFood
ingest	33,8 giây	236 tệp, 18.798 dòng mới, 0 tệp lỗi
quality	3,4 giây	15/15 mục đạt
dbt	21,0 giây	211/211 bước đạt
detect	2,5 giây	Tuần 23/09/2024: 2 cảnh báo, CN1 P1a điểm 6,0; CN3 P3 điểm 4,8
publish	8,6 giây	22 bảng, 1.500.446 dòng sang PostgreSQL, đối soát số dòng khớp

Nguồn: Kết quả thực nghiệm

Từ lúc bấm nút đến khi dữ liệu lên kho phục vụ mất 146 giây, các lượt khác từ 152 đến 199 giây, phần lớn là thời gian đọc tệp qua thư mục gắn từ Windows vào Docker. Hai cảnh báo trùng đúng hai sự cố đã cài; riêng CN1 bị thu thừa 528.250 đồng.

4.12. Tiểu kết chương

Các thành phần thiết kế ở Chương 3 đều đã được hiện thực và chạy được trên một máy tính cá nhân. Bộ mô phỏng tạo đúng tác động của mười hai kịch bản; tầng thu thập nhận dữ liệu qua ba kênh và từ chối tệp sai hợp đồng; khám phá dữ liệu cho căn cứ của các ngưỡng làm sạch và của phương pháp phân tích; từ Bronze tới Gold không dòng nào bị loại im lặng, 158 kiểm thử dbt và 89 kiểm thử mã nguồn đều đạt; một lượt bảy ngày đi từ dữ liệu nguồn đến cảnh báo trên kho phục vụ mà không cần thao tác tay. Chương 5 đánh giá định lượng các kết quả này.

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương này trả lời ba câu hỏi nghiên cứu ở mục 1.3. Sau phần thiết lập thực nghiệm (mục 5.1), mục 5.2 đánh giá đường ống và chất lượng dữ liệu (RQ1), mục 5.3 đánh giá năm bộ phát hiện (RQ2), mục 5.4 đánh giá khả năng truy vết nguyên nhân (RQ3), mục 5.5 phân tích độ nhạy và so sánh với phương án cơ sở. Mục 5.6 trình bày các phát hiện kinh doanh rút ra từ kho dữ liệu, mục 5.7 thảo luận kết quả và tính hợp lệ.

5.1. Thiết lập thực nghiệm

5.1.1. Dữ liệu và quy trình đánh giá

Thực nghiệm dùng hai tập dữ liệu do bộ mô phỏng sinh ra (mục 3.3.4), đã kiểm chứng ở Bảng 4.3. Hai tập có cùng cấu trúc, 11 chi nhánh, 26 tuần từ 11/03/2024 đến 08/09/2024, nhưng khác hạt giống ngẫu nhiên và kịch bản sự cố. Đường ống và bộ phát hiện chạy giống hệt nhau trên hai tập, mỗi tập một kho riêng. Bốn tuần đầu chỉ dùng làm mức nền, nên mỗi tập có 22 tuần đánh giá được, tức 242 chi nhánh × tuần.

Quy trình được thiết kế để kết quả trên tập kiểm tra phản ánh đúng năng lực của hệ thống khi gặp dữ liệu mới. Mọi tham số, gồm cửa sổ thời gian, ngưỡng và quy tắc gộp bằng chứng, chỉ được chọn trên tập phát triển. Ngưỡng điểm cảnh báo được chọn theo quy tắc khai báo trước: quét từ 2,0 đến 5,0, lấy ngưỡng có F1 cao nhất trên tập phát triển, hòa thì lấy ngưỡng thấp hơn; kết quả là 3,5. Cấu hình cuối được ghi vào `analytics/config.py` và lưu ở commit `60d28bb` ngày 11/10/2026, rồi chạy trên tập kiểm tra đúng một lần, không chỉnh sửa gì sau khi xem kết quả. Chương trình `analytics/evaluate.py` đọc danh sách cảnh báo và đáp án để tính các độ đo; bộ phát hiện không đọc đáp án. Mọi phân tích lỗi thực hiện sau khi biết đáp án chỉ để giải thích và không làm thay đổi kết quả đã báo cáo.

5.1.2. Quy tắc đối chiếu và độ đo

Đơn vị đánh giá là chi nhánh × tuần. Cửa sổ của một sự cố gồm các tuần giao với khoảng từ ngày bắt đầu đến 14 ngày sau ngày kết thúc, vì một số hậu quả đến muộn, như thứ hạng sàn giảm sau vài tuần hay hao hụt chỉ lộ ra ở lần kiểm kê kế tiếp. Cảnh báo cùng chi nhánh và nằm trong cửa sổ là cảnh báo đúng, còn lại là báo động giả; cách đánh giá theo khoảng phù hợp với bất thường kéo dài (Tatbul et al., 2018). Việc chỉ

đúng nguyên nhân được đánh giá riêng, để tách hai năng lực là phát hiện có vấn đề và chỉ ra đó là vấn đề gì.

Sáu độ đo được dùng: số sự cố bắt được, tức có ít nhất một cảnh báo đúng; số sự cố đúng nguyên nhân hạng một ở cảnh báo đầu tiên; độ trễ phát hiện, tính từ ngày bắt đầu đến ngày cuối của tuần có cảnh báo đúng đầu tiên, nhỏ nhất thường là 6 ngày vì hệ thống đánh giá theo tuần; precision theo công thức (2.11); recall theo tuần, tức tỷ lệ chi nhánh × tuần đang có sự cố mà được cảnh báo; và F1 theo công thức (2.12). Mỗi tập chỉ có sáu kịch bản nên mỗi kịch bản ứng với khoảng 17 điểm phần trăm; vì vậy kết quả được báo cáo chi tiết theo từng kịch bản và từng báo động giả.

5.2. Đánh giá đường ống và chất lượng dữ liệu (RQ1)

5.2.1. Phát hiện và xử lý lỗi dữ liệu

Bảng 5.1 so sánh các lỗi mà tầng Silver phát hiện trên hai tập. Tỷ lệ gần như giống nhau, phù hợp với việc bộ mô phỏng sinh lỗi theo cùng xác suất; quan trọng hơn, các quy tắc làm sạch xây dựng trên tập phát triển hoạt động không cần sửa trên tập kiểm tra.

Bảng 5.1. Lỗi dữ liệu được phát hiện và xử lý ở tầng Silver

Loại lỗi	Tập phát triển (183 ngày)	Tập kiểm tra (182 ngày)	Cách xử lý
Lượt quẹt thẻ trùng	1.290 (3,03%)	1.285 (3,03%)	Cách ly
Ca thiếu lượt ra	1.036 ca (4,89%)	1.023 ca (4,85%)	Gắn cờ; Gold nội suy số giờ, có cờ
Nghi gõ gam vào cột kg	62 dòng (0,38%)	63 dòng (0,40%)	Cách ly
Dòng tổng cộng, chữ ký trong sổ kho	2.486	2.474	Tách thành dòng cấu trúc
Tên nguyên liệu khớp chính xác	13.576 dòng (84,3%)	13.336 dòng (84,5%)	Ánh xạ trực tiếp
Tên nguyên liệu qua bảng biến thể	2.528 dòng (15,7%)	2.453 dòng (15,5%)	Ánh xạ; khớp mờ không phải dùng
Ô kiểm kê trống	77 (2,4%)	76 (2,4%)	Giữ giá trị thiếu, gắn cờ
Hóa đơn POS phiên bản cũ	59.979	59.131	Chuẩn hóa về lược đồ chung
Hóa đơn hủy / hoàn tiền	1.896 / 2.278	1.669 / 2.050	Giữ lại, gắn cờ, tính phút đến lúc hủy
Đơn App lưu giờ UTC	97.207	85.931	Đổi sang giờ Việt Nam rồi xác định ngày, ca

Loại lỗi	Tập phát triển (183 ngày)	Tập kiểm tra (182 ngày)	Cách xử lý
Số lượng dính đơn vị (sổ mẫu B)	4.536	4.470	Tách số và đơn vị, chuẩn hóa

Nguồn: Kết quả thực nghiệm

Lỗi kỹ thuật như quẹt trùng, gõ nhầm đơn vị được tách khỏi dữ liệu, còn tín hiệu nghiệp vụ như hóa đơn hủy, quên quẹt ra, ô kiểm kê trống được giữ lại kèm cờ, đúng nguyên tắc ở mục 2.4.2. Hạn chế cần ghi nhận là tầng khớp mờ tên nguyên liệu chưa được kiểm chứng, vì mọi biến thể tên do bộ mô phỏng tạo ra đều nằm trong bảng biến thể.

5.2.2. Đối soát giữa các tầng và hiệu năng

Đối soát Bronze–Silver ở Bảng 4.8 cho phần không giải thích được bằng 0 ở cả bảy nguồn trên cả hai tập. Doanh thu thuần ở Gold khớp tuyệt đối với tổng tính từ Silver theo từng chi nhánh × ngày, với 37.899.868.200 đồng ở tập phát triển và 33.302.131.300 đồng ở tập kiểm tra. Ở bước đưa sang kho phục vụ, số dòng của cả 22 bảng được so giữa DuckDB và PostgreSQL trước khi đổi lược đồ, và mọi lượt trong nhật ký đều khớp (Bảng 5.2).

Bảng 5.2. Kết quả kiểm thử và kiểm tra chất lượng

Nội dung	Tập phát triển	Tập kiểm tra	Môi trường vận hành
Kiểm thử dbt đạt	158/158	158/158	158/158
Bước dbt thành công (mô hình, hạt giống, kiểm thử)	211/211	211/211	211/211
Nguồn có chênh lệch số dòng không giải thích được	0/7	0/7	0/7
Mục cửa chặn chất lượng đạt mỗi lượt	—	—	15/15 ở lượt dữ liệu bình thường

Nguồn: Kết quả thực nghiệm

Bảng 5.3. Thời gian chạy của từng bước

Bước	Dựng toàn bộ một tập (182 ngày, trên máy)	Một ngày mới (trong Docker, qua Airflow)
Sinh dữ liệu nguồn	khoảng 3,5 phút	khoảng 2 giây
Kéo qua API (POS đám mây, App)	—	0,8 giây, 1.343 hóa đơn và 419 đơn

Bước	Dựng toàn bộ một tập (182 ngày, trên máy)	Một ngày mới (trong Docker, qua Airflow)
Kiểm tra tệp mới	—	23,9 giây
Nạp Bronze	80 giây, 6.273 tệp	20,2 giây, 35 tệp
Cửa chặn chất lượng	—	5,6 giây
dbt build (211 bước)	15–25 giây	17,4 giây
Bộ phát hiện	khoảng 1 giây	2,0 giây
Đưa sang kho phục vụ	khoảng 38 giây, lần đầu	8,9 giây

Nguồn: Kết quả thực nghiệm

Xử lý một ngày mới qua bảy bước mất khoảng 80 giây (Bảng 5.3), đáp ứng NFR7; phần chậm nhất là liệt kê và đọc tệp qua thư mục gắn vào Docker, đã phân tích ở mục 4.11.3.

5.2.3. Độ bền trước dữ liệu bất thường và sự cố nguồn

Để kiểm tra NFR8, chương trình `tools/thu_tinh_huong.py` dựng một "ngày xấu" trên môi trường vận hành: hệ thống nguồn ghi bảy ngày 23–29/09/2024, 11 tình huống dữ liệu bất thường được cài cùng lúc, rồi đường ống chạy hai lượt không có thao tác tay ở giữa, lượt đầu khi API của POS đám mây và App không phản hồi, lượt sau khi API hoạt động lại. Cả 11 tình huống cho đúng kết quả mong đợi đã ghi trước khi chạy và không tệp nào bị bỏ qua im lặng (Bảng 5.4).

Bảng 5.4. Kết quả xử lý 11 tình huống dữ liệu bất thường cài cùng lúc (môi trường vận hành, 17/10/2026)

Tình huống	Kết quả đo được
Tệp POS bị cắt ngang khi ghi (CN5, 23/09)	Không đọc được, không nạp, ghi lỗi; các tệp khác vẫn nạp; cửa chặn báo CN5 thiếu POS ngày 23/09
Tệp POS rỗng (CN10, 23/09)	Nạp 0 dòng; cửa chặn coi như thiếu; bộ phát hiện để CN10 ở mức theo dõi, ghi chưa kết luận
Tệp chấm công thiếu cột `event_type` (CN4)	Sai hợp đồng, không nạp, lý do nêu đúng cột thiếu; cửa chặn báo thiếu chấm công CN4
Tệp chấm công xuất bằng bảng mã UTF-16 (CN2)	Đọc được, nạp 24 dòng
Báo cáo GrabFood lưu thành Excel	Không nhận dạng, không nạp, kèm gợi ý gửi đúng tệp CSV gốc
Bảng lương gửi nhầm vào vùng tiếp nhận	Không nhận dạng, không nạp
Tệp POS CN7 ngày 23/09 chép thành tên ngày 30/09	Sai hợp đồng vì tên không khớp nội dung, không nạp, tránh đếm hai lần

Tình huống	Kết quả đo được
Tệp của máy POS-12 chưa khai báo	Bronze nạp 3 dòng; Silver cách ly 3 dòng vì không gắn được chi nhánh
Phiếu kiểm kê CN3 ngày 22/09 đếm lại	Nạp lại, thay toàn bộ bản cũ (22 dòng)
Phiếu nhập CN1 ngày 22/09 gửi muộn	Nạp 4 dòng; Silver và Gold tính lại kỳ đó
API POS đám mây trả thêm trường `loyalty_tier`	Kéo về, nạp bình thường; cửa chặn cảnh báo trường mới

Nguồn: Kết quả thực nghiệm

Với sự cố API, lượt thứ nhất kết thúc sau 105 giây: bộ kết nối thử sáu lần rồi ghi cảnh báo, 174 tệp của các nguồn tệp vẫn được nạp, nhưng cửa chặn chất lượng dừng đường ống trước Silver vì dữ liệu App chậm 7 ngày và mỗi ngày có 8 đến 10 trong 11 chi nhánh thiếu POS. Gold và kho phục vụ giữ nguyên dữ liệu đến 22/09, nên không có cảnh báo hay báo cáo nào từ dữ liệu thiếu. Lượt thứ hai tự lấy đủ bảy ngày, chạy hết đường ống trong 66 giây và đưa ra đúng hai cảnh báo của hai sự cố đã cài.

Hai quy tắc không kết luận trên dữ liệu thiếu (mục 3.7.3) được bổ sung sau khi đã chốt đánh giá, xuất phát từ thử nghiệm tệp xấu và từ lỗi thật của bộ kết nối nêu ở mục 4.3.2: khi tám chi nhánh thiếu POS sáu ngày, ba chi nhánh đủ dữ liệu từng bị cảnh báo "chưa xác định nguyên nhân" vì trung vị nhóm cùng hạng sụt theo các chi nhánh thiếu. Trên hai tập đánh giá, không chi nhánh × tuần nào chịu tác động của hai quy tắc và mã băm của bảng điểm, bảng cảnh báo trùng khớp trước và sau khi bổ sung, nên kết quả ở mục 5.3 không thay đổi. Giới hạn của thử nghiệm là các tình huống dựa trên lỗi thường gặp, và API là dịch vụ giả lập.

5.3. Đánh giá các bộ phát hiện (RQ2)

5.3.1. Kết quả tổng hợp

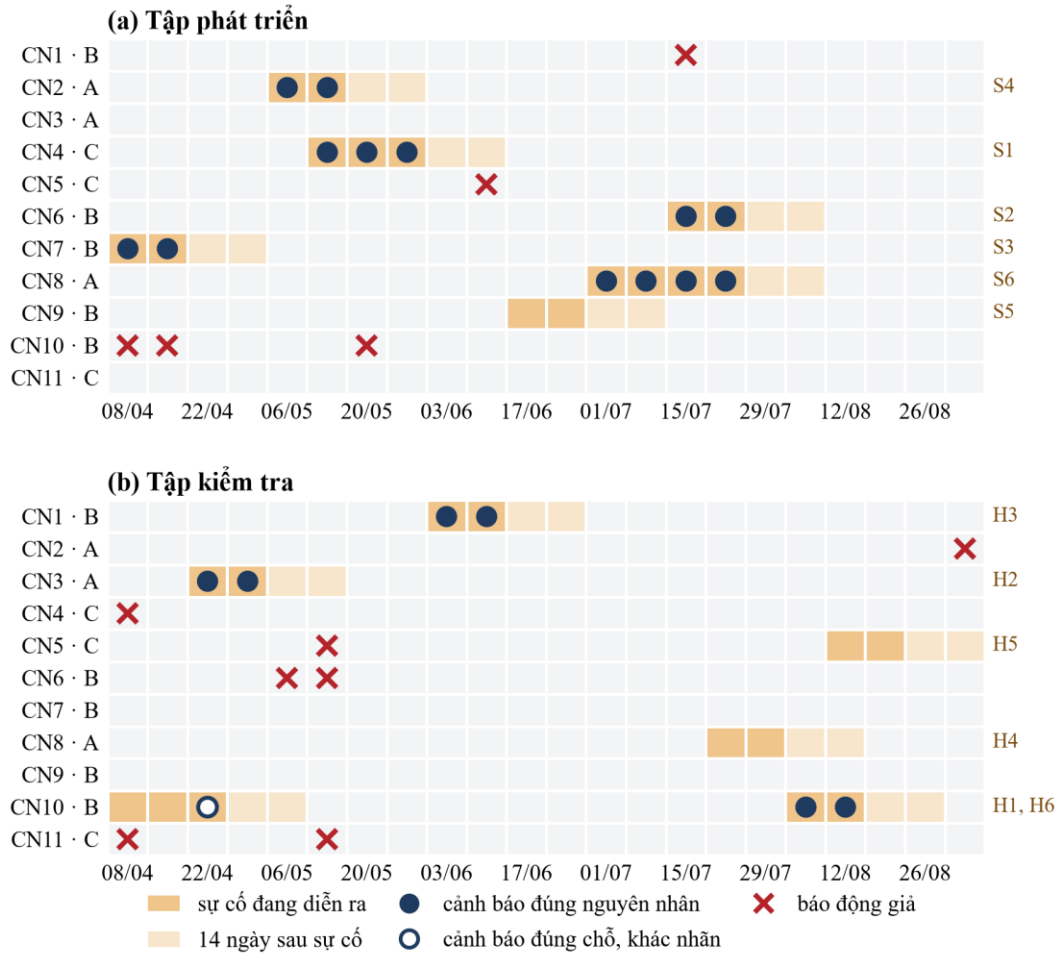
Bảng 5.5. Kết quả của phương pháp đề xuất trên hai tập (ngưỡng điểm 3,5)

Độ đo	Tập phát triển	Tập kiểm tra
Sự cố bắt được	5/6	4/6
Đúng nguyên nhân hạng 1	5/5	3/4
Độ trễ trung vị	6 ngày	6 ngày
Số cảnh báo (chi nhánh × tuần)	18	14
Cảnh báo đúng / báo động giả	13 / 5	7 / 7
Precision	0,72	0,50

Độ đo	Tập phát triển	Tập kiểm tra
Recall theo tuần	0,87	0,54
F1	0,79	0,52
Báo động giả trên số tuần bình thường	2,3%	3,2%

Nguồn: Kết quả thực nghiệm

Trên tập kiểm tra, hệ thống bắt được bốn trên sáu sự cố; ba sự cố được chỉ đúng nguyên nhân ngay ở cảnh báo đầu tiên, sau đúng một tuần (Bảng 5.5). F1 giảm từ 0,79 xuống 0,52 khi chuyển sang tập kiểm tra, cho thấy phương pháp có phần khớp với tập phát triển; đó là lý do phải tách tập kiểm tra, vì nếu chỉ báo cáo trên tập phát triển, kết quả sẽ lạc quan hơn thực tế đáng kể. Hình 5.1 đặt từng cảnh báo cạnh thời gian các sự cố: cảnh báo đúng tập trung trong vùng sự cố, báo động giả rải rác ở các chi nhánh hạng C và ở CN10, CN6, còn H4 và H5 bị bỏ sót.



Nguồn: Kết quả thực nghiệm

Hình 5.1. Cảnh báo của bộ phát hiện đặt cạnh thời gian các sự cố, theo chi nhánh × tuần (ngưỡng điểm 3,5)

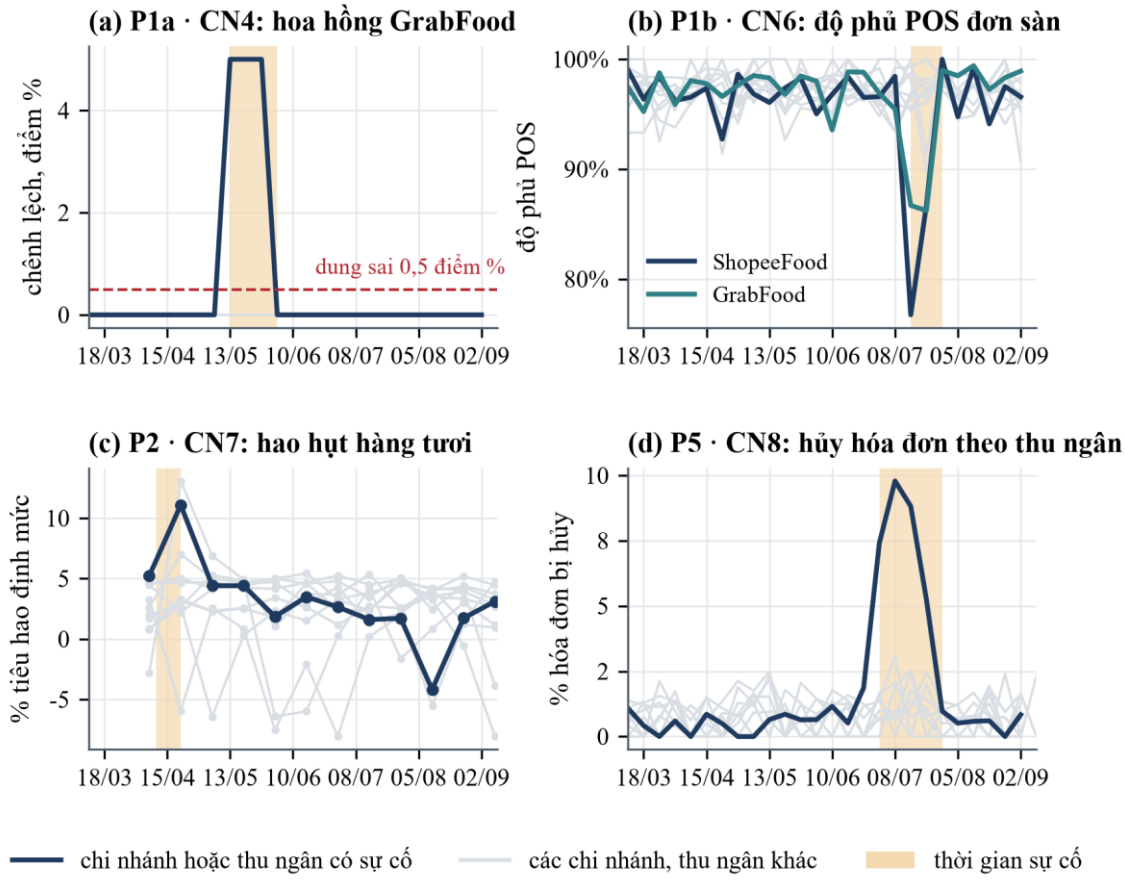
5.3.2. Kết quả theo từng bộ phát hiện

Bảng 5.6. Kết quả theo từng loại sự cố

Bộ phát hiện	Phát triển: sự cố	Phát triển: cảnh báo đúng / tổng	Phát triển: trễ (ngày)	Kiểm tra: sự cố	Kiểm tra: cảnh báo đúng / tổng	Kiểm tra: trễ (ngày)
P1a. Hoa hồng sai hợp đồng	S1 bắt được	3/3	6	H1 bắt được	2/2	6
P1b. Đơn sàn không vào POS	S2 bắt được	2/3	6	H2 bắt được	2/2	6
P2. Hao hụt vượt định mức	S3 bắt được	2/4	4	H3 bắt được	2/4	6
P3. Thiếu nhân sự	S4 bắt được	2/2	6	H4 bỏ sót	0/0	—
P4. Thất thoát kho	S5 bỏ sót	0/0	—	H5 bỏ sót	0/0	—
P5. Gian lận tại quầy	S6 bắt được	4/4	6	H6 bắt được, sai nhãn	0/1	27
Chưa xác định nguyên nhân	—	0/2	—	—	1/5	—

Nguồn: Kết quả thực nghiệm

Cột "cảnh báo đúng / tổng" tính theo nguyên nhân mà hệ thống gán. Hai bộ phát hiện đối soát sàn P1a, P1b ổn định nhất: bắt cả bốn sự cố sau một tuần, không có báo động giả trên tập kiểm tra, phù hợp với bản chất bài toán vì đối soát dựa trên con số so được trực tiếp giữa hai nguồn nên ít phụ thuộc mô hình kỳ vọng. P2 bắt cả hai sự cố hao hụt nhưng có báo động giả ở cả hai tập. Hình 5.2 cho thấy vì sao bốn bộ phát hiện bắt được sự cố trên tập phát triển: tín hiệu của chi nhánh hoặc thu ngân có sự cố tách hẳn khỏi dải của các đối tượng khác đúng trong thời gian sự cố, còn tín hiệu hao hụt lộ ra ở lần kiểm kê ngay sau sự cố.



Nguồn: Kết quả thực nghiệm

Hình 5.2. Tín hiệu của bốn bộ phát hiện quanh sự cố trên tập phát triển

5.3.3. Phân tích lỗi

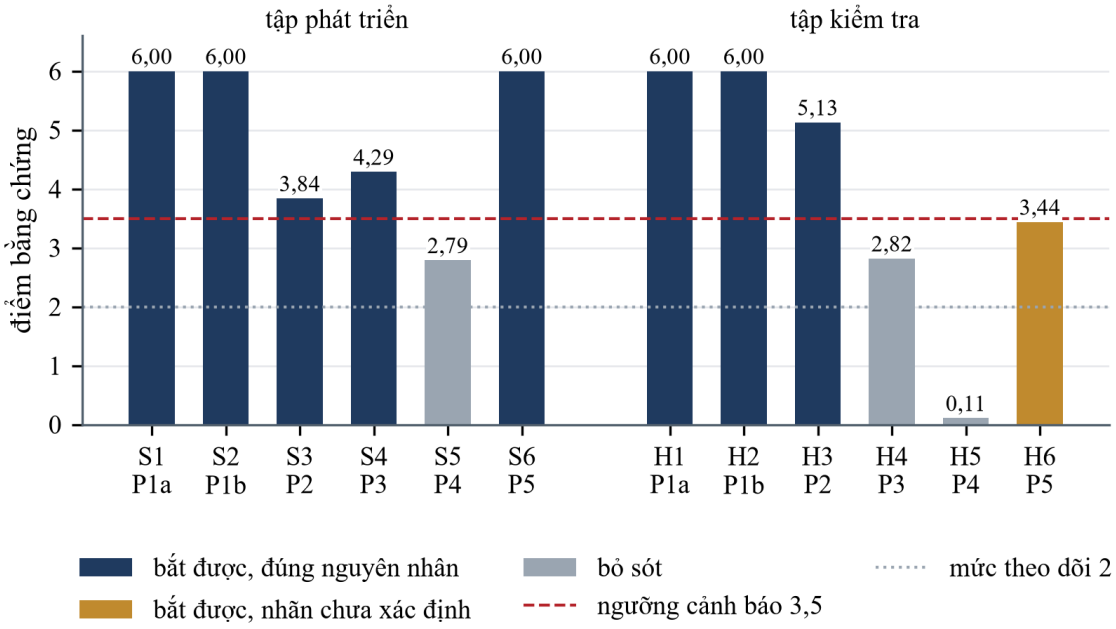
Phần này thực hiện sau khi biết đáp án, chỉ để giải thích kết quả (Bảng 5.7, Hình 5.3).

Bảng 5.7. Các sự cố bị bỏ sót hoặc gán sai nguyên nhân

Sự cố	Điểm cao nhất của nguyên nhân đúng	Hạng	Giải thích
S5 thất thoát kho CN9	2,8	1	Ở mức theo dõi, dưới ngưỡng 3,5. Tồn kho mỗi nguyên liệu chỉ đủ 2–4 ngày, nên mất 1,5% lượng tồn mỗi ngày chỉ làm hao hụt nhóm giá trị cao tăng 1–2 điểm %
H4 thiếu nhân sự CN8	2,82	1	Số ca bếp tối giảm rõ ($z = -5,6$) nhưng sự cố chỉ 10 ngày, hậu quả vừa phải; điểm P3 là trung bình năm tín hiệu nên bị các tín hiệu yếu kéo xuống
H5 thất thoát kho CN5	gần 0	—	Không có tín hiệu: chi nhánh nhỏ, mất 1,2% lượng tồn mỗi ngày, kiểm kê hai tuần một lần

Sự cố	Điểm cao nhất của nguyên nhân đúng	Hạng	Giải thích
H6 gian lận thu ngân CN10	3,44	1	Thiếu ngưỡng 0,06. Gian lận nhẹ hơn S6 (5–8 so với 14–20 hóa đơn mỗi tuần); chỉ được cảnh báo ở tuần thứ tư khi doanh thu lệch đủ lớn, với nhãn chưa xác định

Nguồn: Kết quả thực nghiệm



Nguồn: Kết quả thực nghiệm

Hình 5.3. Điểm cao nhất của nguyên nhân đúng trong cửa sổ từng sự cố, so với ngưỡng cảnh báo và mức theo dõi

Ở cả năm sự cố có tín hiệu trên tập kiểm tra, nguyên nhân đúng đều xếp hạng một trong cửa sổ sự cố, kể cả hai trường hợp chưa vượt ngưỡng. Mười một trên mười hai sự cố có điểm từ mức theo dõi trở lên; ba sự cố S5, H4, H6 nằm giữa mức theo dõi và ngưỡng, tức một ngưỡng thấp hơn sẽ bắt được nhưng phải trả giá bằng nhiều báo động giả hơn (mục 5.5.1). Điểm yếu chính vì vậy nằm ở ngưỡng và độ nhạy với sự cố nhẹ, ngắn, không nằm ở khả năng chỉ đúng nguyên nhân khi đã có tín hiệu. Thất thoát kho là loại khó nhất: với kiểm kê hai tuần một lần và tồn kho chỉ vài ngày, lượng mất nhỏ chìm trong sai số đếm; đây là giới hạn của dữ liệu đầu vào, không chỉ của phương pháp.

Bảy báo động giả trên tập kiểm tra gồm bốn tuần ở chi nhánh hạng C có doanh thu lệch kỳ vọng mà không nguyên nhân nào đủ điểm, vì nhóm chỉ có ba chi nhánh nên trung vị dao động mạnh; hai tuần P2 ở CN6 có hao hụt hàng tươi cao hơn các chi nhánh

cùng kỳ; và một tuần P5 ở CN2 có một thu ngân hủy hóa đơn nhiều hơn đồng nghiệp. Năm báo động giả trên tập phát triển gồm hai tuần doanh thu lệch không rõ nguyên nhân, hai tuần P2 và một tuần P1b ở CN10. Các báo động giả này có thiệt hại ước tính nhỏ, như P2 ở CN10 chỉ 66 nghìn đồng và ở CN6 chỉ 29 nghìn đồng so với 6,83 triệu đồng của sự cố hao hụt thật ở CN7, nên khi danh sách sắp theo thiệt hại, chúng nằm cuối và chi phí xử lý thấp.

5.4. Đánh giá khả năng truy vết nguyên nhân (RQ3)

5.4.1. Ví dụ truy vết: thiếu nhân sự ở CN2

Sự cố S4 làm CN2 thiếu nhân viên bếp ca tối từ 06/05 đến 19/05. Bảng 5.8 trình bày cây KPI và tín hiệu vận hành của CN2 trong tuần đầu sự cố, đúng như trang Truy vết ở Hình 4.10 hiển thị.

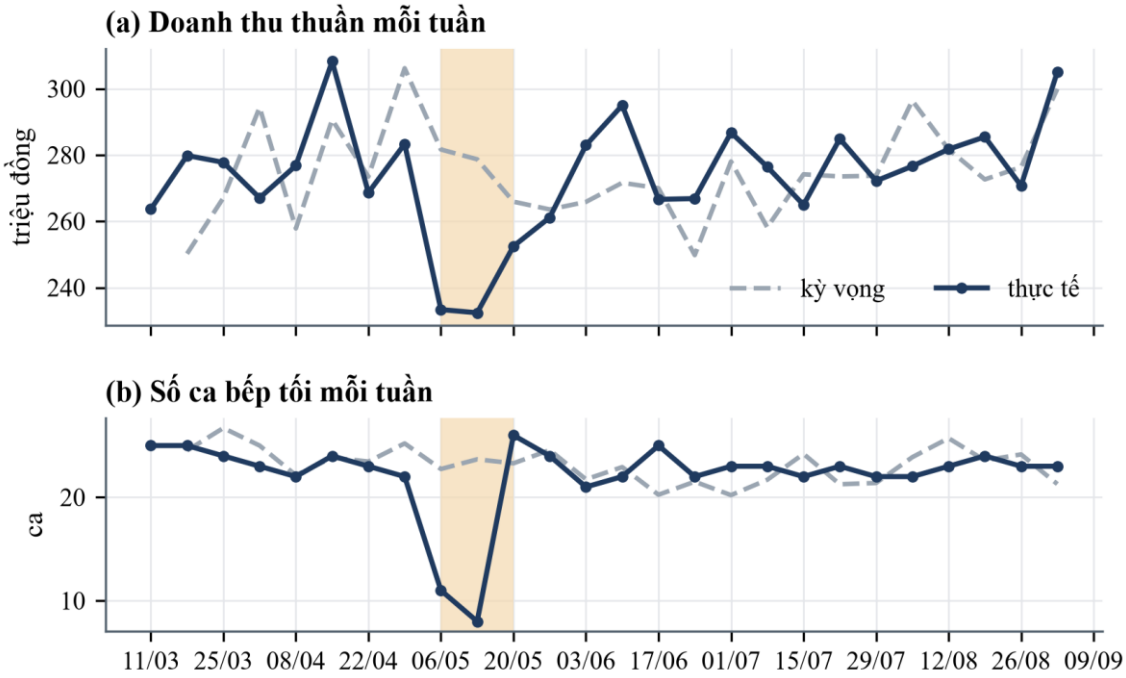
Bảng 5.8. Truy vết CN2, tuần 06/05–12/05/2024 (tập phát triển)

Nút của cây KPI hoặc tín hiệu	Thực tế	Kỳ vọng	Chênh lệch	z
Doanh thu thuần	233,4 triệu đ	281,7 triệu đ	−17,2%	−2,8
· Tại quầy	112,6 triệu đ	131,8 triệu đ	−14,6%	−1,6
· App	50,6 triệu đ	67,5 triệu đ	−25,0%	−3,0
· GrabFood (ghi trên POS)	41,6 triệu đ	46,5 triệu đ	−10,5%	−0,9
· ShopeeFood (ghi trên POS)	28,5 triệu đ	31,6 triệu đ	−9,7%	−0,7
Số đơn App	611	742	−17,7%	−2,0
Số ca bếp tối	11	22,7	−51,6%	−7,1
Thời gian chuẩn bị đơn App	20,9 phút	14,2 phút	+47,1%	+2,9
Tỷ lệ cửa hàng tự hủy đơn App	6,2%	1,1%	+5,1 điểm %	+8,0
Tỷ lệ khách hủy vì chờ lâu	3,3%	0,5%	+2,8 điểm %	+3,5
Điểm đánh giá GrabFood	4,3	4,5	−0,2	−4,0

Nguồn: Kết quả thực nghiệm

Cây KPI cho thấy chênh lệch nằm chủ yếu ở số đơn chứ không ở giá trị đơn, và nặng nhất ở kênh App, kênh mà cửa hàng tự hủy đơn khi quá tải. Các tín hiệu vận hành cùng chỉ một hướng: số ca bếp tối giảm một nửa, thời gian chuẩn bị tăng gần 50%, cửa hàng tự hủy đơn App tăng gấp năm; bộ phát hiện xếp P3 hạng một với điểm 4,3. Chỉ nhìn doanh thu thì tuần này chưa đủ để cảnh báo, vì $z = -2,8$ còn dưới 3; chính các tín hiệu vận hành đã đẩy tuần này lên mức cảnh báo. Hậu quả kéo dài cũng được ghi nhận:

ở tuần 20/05, khi nhân sự đã trở lại với 26 ca bếp tối và thời gian chuẩn bị 13,3 phút, doanh thu GrabFood của CN2 vẫn thấp hơn kỳ vọng 22,1% với điểm đánh giá 4,3 so với 4,5, và hệ thống xếp tuần này ở mức theo dõi. Đây đúng là chuỗi nhân quả trễ qua thứ hạng sàn ở mục 3.3.2, như Hình 5.4 cho thấy.



Nguồn: Kết quả thực nghiệm

Hình 5.4. Doanh thu thuần và số ca bếp tối của CN2 so với mức kỳ vọng; vùng tô là thời gian sự cố S4

5.4.2. Chỉ đúng nguyên nhân và phân biệt với biến động bình thường

Trên tập phát triển, cả năm sự cố bắt được đều được chỉ đúng nguyên nhân ngay ở cảnh báo đầu tiên; trên tập kiểm tra, ba trên bốn, còn H6 được cảnh báo với nhãn "chưa xác định nguyên nhân" chứ không bị gán nhầm sang nguyên nhân khác. Trong toàn bộ 32 cảnh báo của hai tập, không cảnh báo nào nằm trong cửa sổ một sự cố mà lại chỉ sai sang một nguyên nhân vận hành khác. Bảng 5.9 xét các tuần có biến động chung lớn trên toàn chuỗi.

Bảng 5.9. Cảnh báo trong các tuần có biến động bình thường lớn

Tuần (tập)	Biến động chung	Doanh thu chuỗi so với tuần trước	Cảnh báo trong tuần
29/04 (phát triển), lễ 30/4–1/5	Hai ngày lễ	+10,0%	0
02/09 (phát triển), lễ 2/9	Hai ngày lễ	+7,6%	0

Tuần (tập)	Biến động chung	Doanh thu chuỗi so với tuần trước	Cảnh báo trong tuần
15/04 (phát triển), Giỗ Tổ	Một ngày lễ	+7,0%	2, đều thuộc kho (CN7 sự cố thật; CN10 báo động giả P2)
03/06 (phát triển), sau điều chỉnh giá, 6 ngày mưa	AOV +3,3%, mưa nhiều nhất	+2,7%	0
29/04 (kiểm tra), lễ 30/4–1/5	Hai ngày lễ	+7,9%	1, sự cố thật H2
02/09 (kiểm tra), lễ 2/9	Hai ngày lễ	+5,5%	1, báo động giả P5 ở một thu ngân

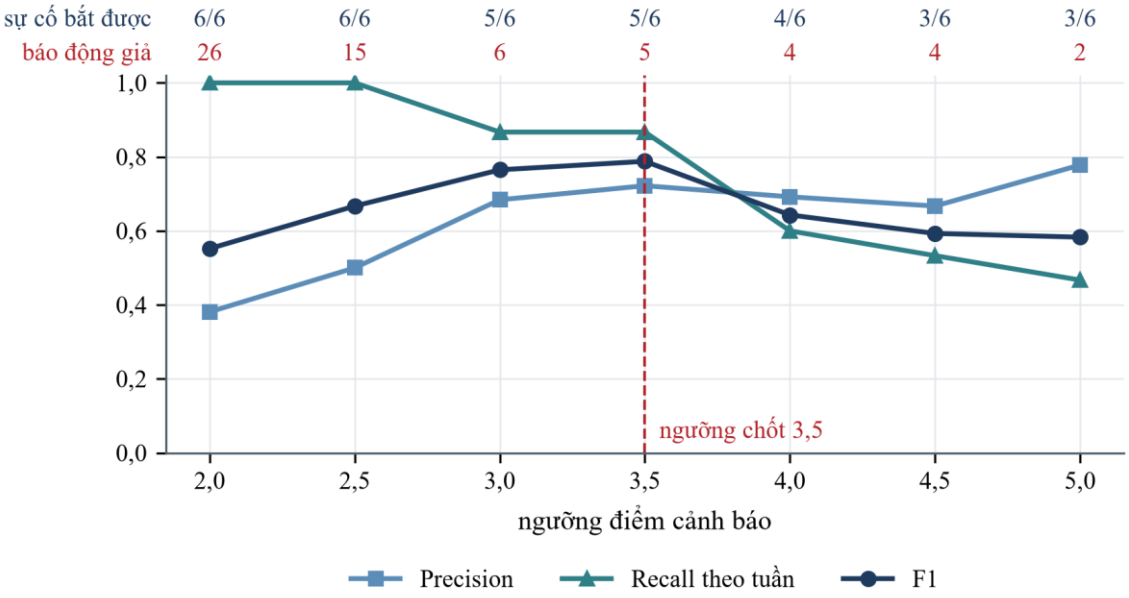
Nguồn: Kết quả thực nghiệm

Không cảnh báo nào trong các tuần này được gán cho biến động doanh thu chung; các cảnh báo xuất hiện đều đến từ bằng chứng riêng của chi nhánh về kho, thu ngân hoặc đối soát sàn. Lý do là mức kỳ vọng tính theo nhóm cùng hạng trong cùng tuần nên tác động của lễ, mưa và điều chỉnh giá lên cả nhóm tự triệt tiêu, trong khi doanh thu ngày lễ cao hơn ngày thường 21–23% (Bảng 4.4), lớn hơn tác động doanh thu của phần lớn sự cố. Điểm yếu lộ ra ở hạng C: nhóm chỉ có ba chi nhánh, mỗi chi nhánh so với trung vị của hai chi nhánh còn lại, nên biến động riêng của một chi nhánh làm lệch kỳ vọng của các chi nhánh khác; bốn trên bảy báo động giả trên tập kiểm tra rơi vào hạng C.

5.5. Phân tích độ nhạy và so sánh với phương án cơ sở

5.5.1. Độ nhạy theo ngưỡng điểm cảnh báo

Ngưỡng điểm điều chỉnh đánh đổi giữa bỏ sót và báo động giả (Hình 5.5). Ở ngưỡng 2,0 hệ thống bắt cả sáu sự cố nhưng có 26 báo động giả; ở 2,5 vẫn bắt đủ sáu với 15 báo động giả, bằng số cảnh báo đúng. Ngưỡng 3,5 cho F1 cao nhất 0,79 với 5 báo động giả nên được chốt; từ 4,0 trở lên recall giảm nhanh. Ở mọi ngưỡng, sự cố đã bắt được đều có nguyên nhân hạng một đúng. Trên thực tế, ngưỡng nên do người quản lý chọn theo khả năng xử lý cảnh báo của bộ phận mình, nên ứng dụng cho thay đổi ngưỡng trên trang Trung tâm cảnh báo, còn kết quả chính thức luôn báo cáo ở ngưỡng đã chốt.



Nguồn: Kết quả thực nghiệm

Hình 5.5. Precision, recall theo tuần và F1 trên tập phát triển theo ngưỡng điểm cảnh báo; hai dòng phía trên là số sự cố bắt được và số báo động giả

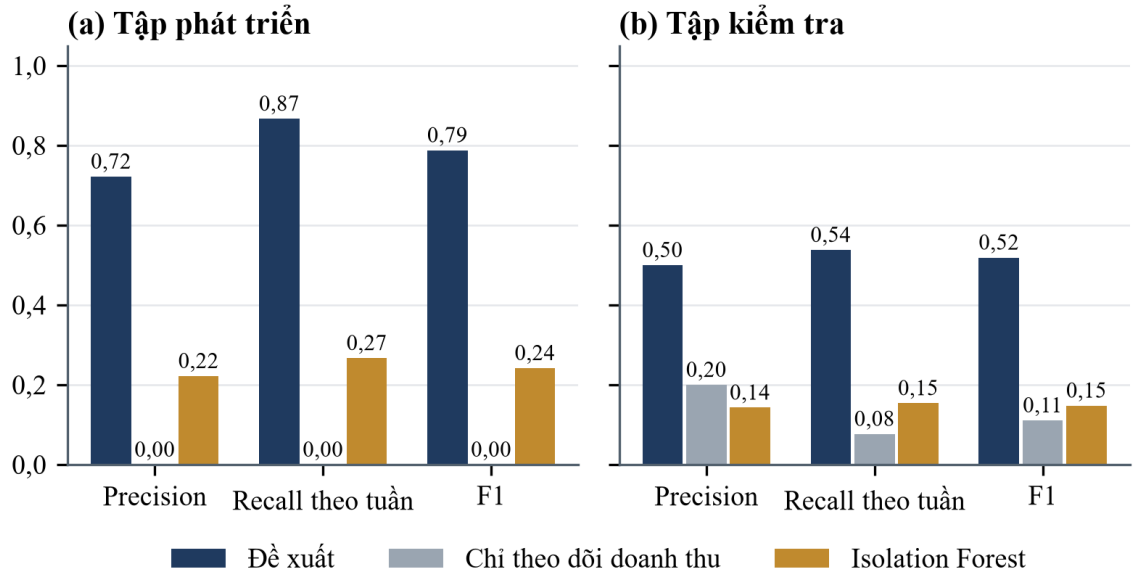
5.5.2. So sánh với phương án cơ sở

Hai phương án cơ sở chạy trên cùng dữ liệu Gold. Phương án thứ nhất chỉ theo dõi doanh thu, cảnh báo khi |z| doanh thu thuần từ 3, tức cách làm phổ biến khi chỉ có báo cáo doanh thu. Phương án thứ hai là Isolation Forest (Liu et al., 2008) cài bằng scikit-learn (Pedregosa et al., 2011), phát hiện bất thường không giám sát trên vector z của cả 24 chỉ số, được đưa ra đúng số cảnh báo như phương pháp đề xuất để so sánh công bằng (Bảng 5.10, Hình 5.6).

Bảng 5.10. So sánh với các phương án cơ sở

Phương pháp	Tập	Sự cố bắt được	Precision	Recall theo tuần	F1
Đề xuất: bộ chỉ số giám sát và dấu vân tay nguyên nhân	Phát triển	5/6	0,72	0,87	0,79
	Kiểm tra	4/6	0,50	0,54	0,52
Chỉ theo dõi doanh thu, lệch từ 3 đơn vị z	Phát triển	0/6	0,00	0,00	0,00
	Kiểm tra	1/6	0,20	0,08	0,11
Isolation Forest, cùng số cảnh báo	Phát triển	3/6	0,22	0,27	0,24
	Kiểm tra	2/6	0,14	0,15	0,15

Nguồn: Kết quả thực nghiệm



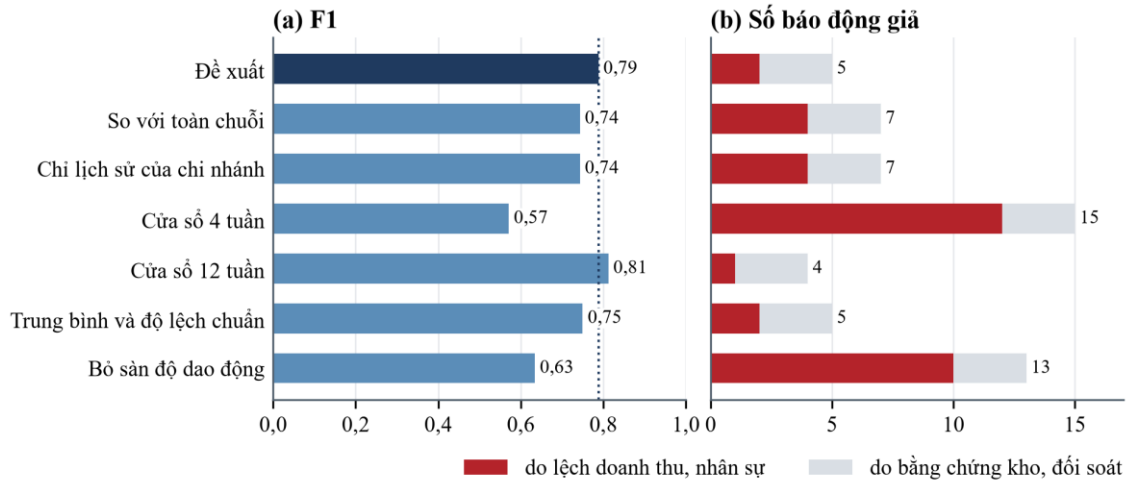
Nguồn: Kết quả thực nghiệm

Hình 5.6. Precision, recall theo tuần và F1 của phương pháp đề xuất và hai phương án cơ sở

Theo dõi doanh thu gần như không phát hiện được sự cố nào, vì phần lớn sự cố không làm doanh thu lệch đủ xa: hoa hồng sai và hao hụt làm tăng chi phí chứ không giảm doanh thu, gian lận chỉ vài triệu đồng mỗi tuần, và ngay cả S4 cũng chỉ làm doanh thu lệch $z = -2{,}8$. Đây là bằng chứng định lượng cho nhận định ở mục 1.1 rằng nhìn con số tổng hợp không đủ để phát hiện sự cố vận hành. Isolation Forest dùng đúng các chỉ số như phương pháp đề xuất nhưng chỉ tìm điểm "lạ" chung chung, không biết chiều nào là xấu và chỉ số nào đi cùng nhau, nên phần lớn cảnh báo rơi vào các tuần lạ mà vô hại, và cũng không cho biết nguyên nhân.

5.5.3. Độ nhạy theo cách tính mức kỳ vọng

Mục này kiểm tra từng lựa chọn của cách tính mức kỳ vọng ở mục 3.7.2: mỗi lần chỉ thay một lựa chọn, giữ nguyên phần khác và ngưỡng 3,5, rồi chấm lại trên tập phát triển. Chương trình `analytics/sensitivity.py` tính lại bảng mức kỳ vọng bằng Python và trước khi thay đổi gì đã được đối chiếu khớp tuyệt đối với bảng do dbt sinh ra trên 8.954 dòng. Tập kiểm tra không được dùng vì đã được đánh giá một lần với cấu hình đã chốt.



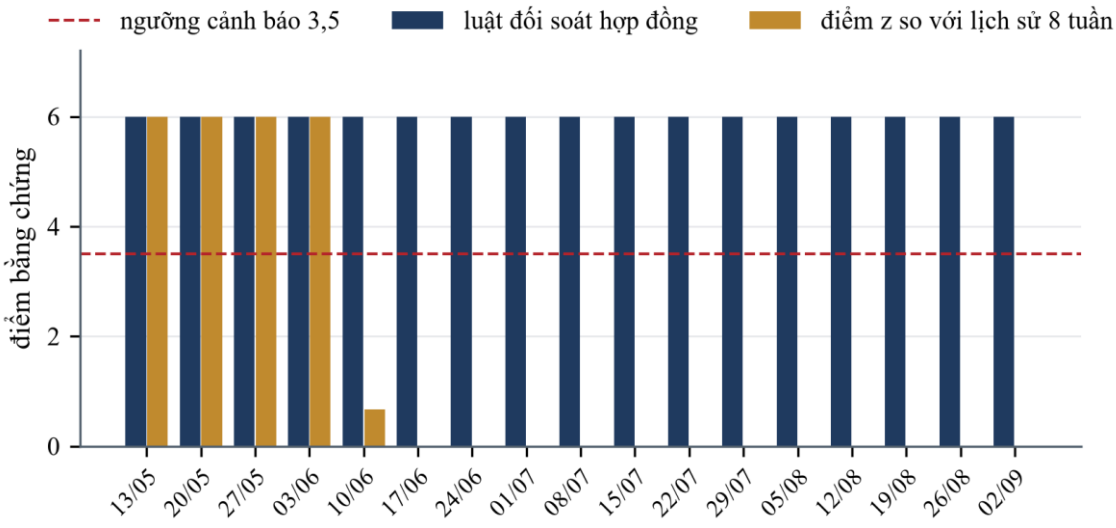
Nguồn: Kết quả thực nghiệm

Hình 5.7. F1 và số báo động giả theo cách tính mức kỳ vọng (tập phát triển, ngưỡng điểm 3,5)

Hình 5.7 cho thấy mọi phương án đều bắt 5/6 sự cố, nhưng khác nhau ở số báo động giả; phần màu đỏ là báo động giả do lệch doanh thu hoặc nhân sự, tức loại chịu ảnh hưởng của mức kỳ vọng, còn ba báo động giả về kho và đối soát ở CN10 thì giống nhau ở mọi phương án. Sàn độ dao động và độ dài cửa sổ ảnh hưởng lớn nhất: bỏ sàn làm báo động giả tăng từ 5 lên 13 và F1 giảm còn 0,63, vì có chi nhánh mà tám tuần trước tình cờ rất đều làm z bị thổi phồng; cửa sổ 4 tuần làm báo động giả tăng lên 15, F1 0,57, đồng thời S4 chỉ còn được cảnh báo một tuần vì tuần sự cố đầu đã chiếm một phần tư mức nền của tuần sau. Trung bình và độ lệch chuẩn cho cùng số báo động giả nhưng bỏ sót tuần thứ hai của S4 (F1 0,75), vì tuần sự cố đầu làm độ lệch chuẩn phình ra, đúng lý do chọn trung vị và MAD. So với toàn chuỗi, hoặc chỉ dùng lịch sử của chính chi nhánh, đều thêm hai báo động giả (F1 0,74), trong đó các tuần lễ 29/4 và 2/9 ở CN1 bị cảnh báo và tuần 29/4 còn bị gán nhầm là thiếu nhân sự; so với nhóm cùng hạng loại được đúng loại lỗi này.

Cửa sổ 12 tuần cho kết quả tốt hơn nhẹ cửa sổ 8 tuần đang dùng, ít hơn một báo động giả và F1 0,81. Khi phát triển, cửa sổ 8 tuần được chọn khi so với 4 tuần, cửa sổ dài hơn chưa được thử trước khi chốt. Khóa luận không đổi cấu hình, vì kết quả trên tập kiểm tra chỉ có giá trị với cấu hình đã chốt trước khi xem nó; chênh lệch chỉ là một cảnh báo trên chính tập phát triển, và cửa sổ dài phản ứng chậm hơn với các thay đổi bền vững như đổi cơ cấu kênh. Thử cửa sổ dài hơn trên một tập kiểm tra mới được ghi vào hướng phát triển.

Cuối cùng, lập luận dùng luật thay vì điểm z cho P1a (mục 3.7.3) cũng được kiểm tra bằng cách sửa chuỗi chênh lệch hoa hồng GrabFood của CN4 theo giả định sàn tính thừa 5 điểm % từ tuần 13/5 đến hết kỳ, tức 17 tuần. Luật đối soát cảnh báo cả 17 tuần, còn điểm z chỉ vượt 3 ở bốn tuần đầu và bằng 0 từ tuần thứ sáu, vì mức nền trung vị tám tuần đã gồm phần lớn các tuần bị tính sai (Hình 5.8). Với phương pháp dựa trên lịch sử, một sai lệch kéo dài dần trở thành "bình thường"; với bài toán tuân thủ hợp đồng, luật so trực tiếp với tỷ lệ cam kết mới là công cụ đúng.



Nguồn: Kết quả thực nghiệm

Hình 5.8. Điểm bằng chứng P1a theo luật đối soát và theo điểm z khi sai lệch hoa hồng kéo dài 17 tuần (giả định trên dữ liệu CN4)

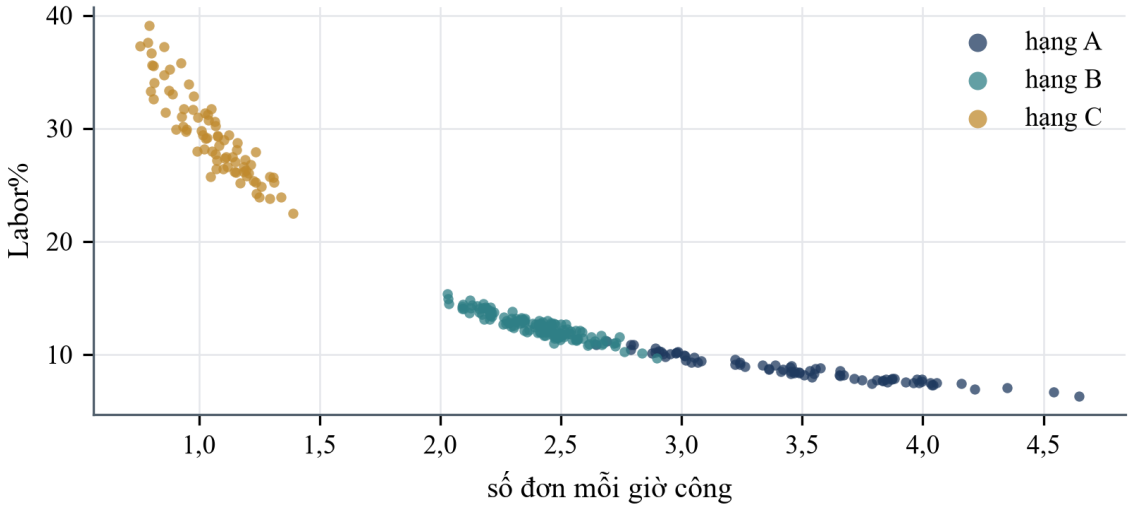
5.6. Các phát hiện kinh doanh

Các số liệu trong mục này được tính hoàn toàn từ kho dữ liệu 182 ngày của tập phát triển, không lấy từ đáp án. Vì dữ liệu là mô phỏng, các phát hiện minh họa loại câu hỏi mà nền tảng trả lời được, không phải kết luận về một doanh nghiệp thật.

5.6.1. Cơ cấu chi phí theo hạng chi nhánh

Doanh thu bình quân mỗi chi nhánh mỗi tuần là 261,2 triệu đồng ở hạng A, 113,1 triệu ở hạng B và 33,8 triệu ở hạng C. COGS% định mức như nhau ở cả ba hạng, đều 31,0%, nhưng Labor% của hạng C là 29,1%, gấp khoảng 3,4 lần mức 8,6% của hạng A; hạng B ở giữa với 12,4%. Đây là phát hiện về cấu trúc chứ không phải sự cố: chi nhánh phải có số người tối thiểu cho mỗi ca dù ít đơn, nên năng suất ở hạng C chỉ 1,04 đơn mỗi giờ công so với 3,44 ở hạng A; Hình 5.9 cho thấy ba hạng tạo thành ba cụm tách biệt trên cùng một đường cong. Hệ quả cho việc giám sát là không thể dùng một ngưỡng

Labor% chung cho mọi chi nhánh mà phải so theo nhóm cùng hạng. Labor% ở đây chỉ gồm lương giờ trực tiếp theo chấm công, chưa gồm lương cố định của quản lý và bảo hiểm, nên thấp hơn mức thường gặp trong thực tiễn.



Nguồn: Kết quả thực nghiệm

Hình 5.9. Labor% và số đơn mỗi giờ công của từng chi nhánh × tuần, theo hạng chi nhánh (tập phát triển)

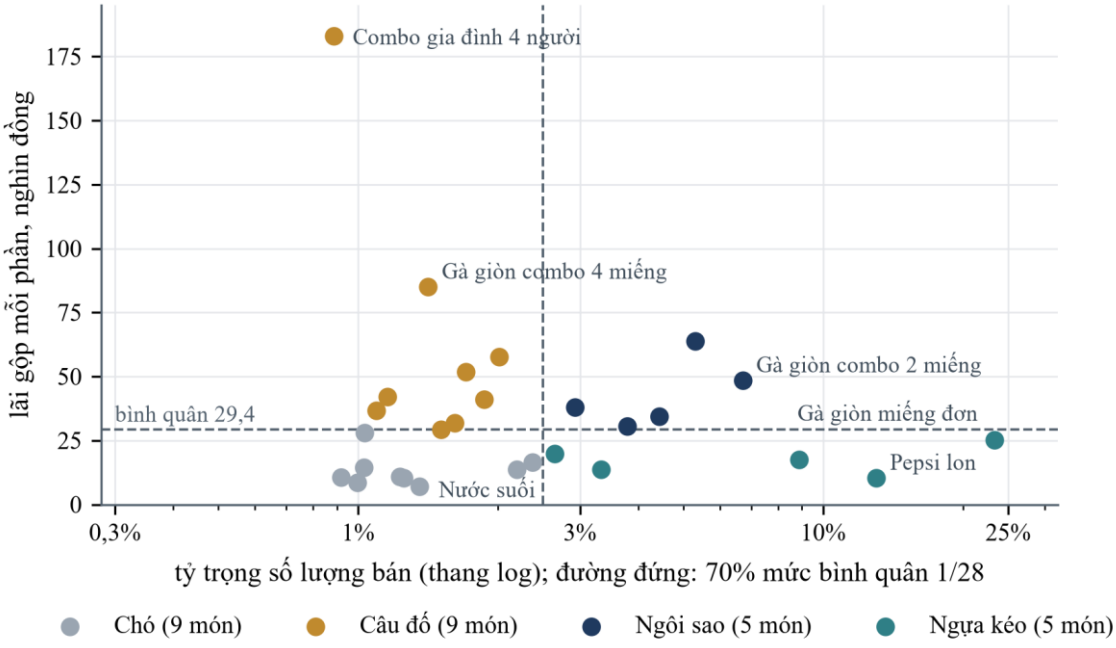
5.6.2. Hiệu quả theo kênh, ảnh hưởng của mưa và điều chỉnh giá

Tại quầy chiếm 52% doanh thu thuần, ứng dụng riêng 22%, GrabFood 16%, ShopeeFood 10%. Theo báo cáo đối soát, tổng phí sàn giữ lại, gồm hoa hồng, quảng cáo và khuyến mãi do cửa hàng tài trợ, bằng 27,7% doanh thu món trên GrabFood và 24,7% trên ShopeeFood. Cộng với giá vốn định mức khoảng 31%, mỗi 100 đồng bán qua GrabFood chỉ còn khoảng 41 đồng trước chi phí nhân công và mặt bằng, so với khoảng 69 đồng tại quầy; điều này giải thích vì sao một sai lệch nhỏ của tỷ lệ hoa hồng như P1a đáng được kiểm soát hằng tuần.

Không tính ngày lễ, so với 118 ngày khô, vào 59 ngày mưa mỗi chi nhánh có ít hơn 27% đơn tại quầy, nhiều hơn 19% đơn App và 21% đơn sàn; tỷ trọng đơn giao hàng tăng từ 43,6% lên 56,0%, còn doanh thu mỗi ngày giảm 5,3%. Vì đơn sàn chịu phí khoảng một phần tư, ngày mưa làm biên lợi nhuận giảm nhiều hơn doanh thu, gợi ý dịch chuyển nhân sự từ quầy sang khu đóng gói vào ngày dự báo mưa và ưu tiên kéo khách sang ứng dụng riêng. Sau điều chỉnh giá sáu món ngày 01/06, AOV hai tuần sau tăng 3,4% và COGS% định mức giảm từ 31,6% xuống 30,6%; số đơn không giảm, nhưng điều này chỉ phản ánh giả định của bộ mô phỏng vốn chưa mô hình hóa độ co giãn của cầu theo giá (mục 3.3.5).

5.6.3. Ma trận thực đơn

Theo phương pháp menu engineering (Kasavana & Smith, 1982), mỗi món được xếp theo mức phổ biến, so tỷ trọng số lượng bán với 70% mức bình quân 1/28, và lãi gộp mỗi phần, so với bình quân có trọng số 29.357 đồng (Hình 5.10). Nhóm ngôi sao có 5 món, chiếm 23,2% số lượng và 35,6% lãi gộp, tiêu biểu là gà giòn combo 2 miếng và burger gà giòn phô mai. Nhóm ngựa kéo có 5 món, chiếm 51,2% số lượng nhưng chỉ 33,3% lãi gộp, gồm gà giòn miếng đơn với 23,3% số lượng. Nhóm câu đố có 9 món với 13,3% số lượng và 25,5% lãi gộp, nổi bật là combo gia đình 4 người lãi 182.920 đồng mỗi phần. Nhóm chó có 9 món với 12,4% số lượng và 5,7% lãi gộp, như trà sữa, nước suối, súp ngô và salad. Hành động gợi ý là đẩy khách từ miếng đơn sang các combo nhóm ngôi sao bằng gợi ý bán kèm, quảng bá nhóm câu đố và xem xét rút gọn nhóm chó; phân tích này dùng giá vốn định mức, chưa tính hao hụt thực tế theo món.



Nguồn: Kết quả thực nghiệm

Hình 5.10. Ma trận thực đơn: tỷ trọng số lượng bán và lãi gộp mỗi phần của 28 món (tập phát triển)

5.6.4. Thiệt hại ước tính của các sự cố được phát hiện

Bảng 5.11. Thiệt hại ước tính từ kho dữ liệu cho các sự cố được phát hiện (tập phát triển)

Sự cố	Cách ước tính (mục 4.8)	Ước tính	Đối chiếu sau với tác động đo bởi bộ mô phỏng (Bảng 4.3)
S1 hoa hồng GrabFood CN4	Hoa hồng thu thừa lũy kế 3 tuần	0,72 triệu đ	Khớp: sàn tính 30% thay vì 25%

Sự cố	Cách ước tính (mục 4.8)	Ước tính	Đối chiếu sau với tác động đo bởi bộ mô phỏng (Bảng 4.3)
S2 đơn sàn không vào POS CN6	Đơn thiếu vượt mức thường × giá trị đơn sàn, 2 tuần	7,12 triệu đ	8,52 triệu đ
S3 hao hụt CN7	Hao hụt vượt mức thường của kỳ kiểm kê	6,83 triệu đ	khoảng 7,5 triệu đ (682 nghìn đ/ngày × 11 ngày)
S4 thiếu nhân sự CN2	Doanh thu thấp hơn kỳ vọng, 2 tuần	94,6 triệu đ	Doanh thu thấp hơn nhóm cùng hạng 16,9% trong kỳ
S6 gian lận thu ngân CN8	Giá trị hóa đơn bị hủy, hoàn, giảm giá của thu ngân nghi vấn, 4 tuần	5,74 triệu đ (giá trị liên quan)	5,31 triệu đ hóa đơn bị hủy sau khi thu tiền

Nguồn: Kết quả thực nghiệm

Các ước tính được tính hoàn toàn từ kho dữ liệu; cột cuối chỉ dùng để kiểm tra độ hợp lý sau khi đã tính. Ước tính cùng bậc độ lớn với tác động thật, đủ để xếp thứ tự ưu tiên. Thiếu nhân sự là sự cố đắt nhất, gấp hơn mười lần các sự cố còn lại, dù về dữ liệu nó chỉ là vài ca làm việc bị thiếu; ngược lại, gian lận và thất thoát kho nhỏ về tiền nhưng là vấn đề kiểm soát nội bộ nên vẫn cần được xử lý.

5.7. Thảo luận

5.7.1. Trả lời các câu hỏi nghiên cứu

Với RQ1, câu trả lời là có. Đường ống tích hợp được bảy nhóm hệ thống nguồn với ba định dạng tệp, hai phiên bản lược đồ POS, sáu hệ mã chi nhánh và tên nguyên liệu tự do vào một lược đồ hình sao, kiểm chứng bằng ba lớp: 158/158 kiểm thử dbt đạt trên cả ba tập, đối soát số dòng không có chênh lệch không giải thích được, doanh thu thuần Gold khớp tuyệt đối với Silver. Đường ống chạy tăng dần, lũy đẳng, xử lý một ngày mới trong khoảng 80 giây và chịu được 11 tình huống dữ liệu bất thường. Giới hạn là các lỗi do bộ mô phỏng sinh ra, chưa bao phủ hết lỗi của dữ liệu thật.

Với RQ2, trên tập kiểm tra chưa từng dùng để chọn ngưỡng, hệ thống bắt được bốn trên sáu sự cố với precision 0,50, recall theo tuần 0,54, F1 0,52 và độ trễ trung vị 6 ngày, vượt rõ hai phương án cơ sở là chỉ theo dõi doanh thu (1/6, F1 0,11) và Isolation Forest (2/6, F1 0,15). Mức độ chính xác khác nhau theo loại sự cố: đối soát sàn đáng tin

cậy nhất; hao hụt bắt được nhưng có báo động giả; thiếu nhân sự nhẹ và gian lận nhẹ nằm sát dưới ngưỡng; thất thoát kho không phát hiện được với nhịp kiểm kê hai tuần.

Với RQ3, câu trả lời là phần lớn có thể. Khi sự cố đã có tín hiệu, nguyên nhân đúng luôn xếp hạng một, ở cả 5/5 sự cố có tín hiệu trên tập kiểm tra, và không cảnh báo nào trong cửa sổ sự cố bị chỉ sang nguyên nhân sai. Mức kỳ vọng theo nhóm cùng hạng loại được biến động của ngày lễ, mưa, điều chỉnh giá; bỏ so nhóm thì tuần lễ bị cảnh báo và có tuần bị gán nhầm là thiếu nhân sự. Giới hạn chính là nhóm hạng C quá nhỏ, gây bốn trên bảy báo động giả trên tập kiểm tra.

5.7.2. So sánh với các nghiên cứu liên quan

Kết quả không so sánh trực tiếp bằng con số được với các nghiên cứu ở Bảng 2.4 vì dữ liệu, loại sự cố và cách đánh giá khác nhau, nhưng so được về cách tiếp cận. Malashin et al. (2024) dùng Isolation Forest và bộ mã hóa tự động trên hóa đơn nhà hàng và phát hiện 25 trên 100 bất thường đã biết; trong khóa luận, Isolation Forest trên 24 chỉ số cũng chỉ phát hiện 2 trên 6 sự cố ở tập kiểm tra. Hai kết quả cùng cho thấy phương pháp không giám sát tổng quát chỉ ra chỗ bất thường nhưng khó chỉ ra nguyên nhân; gắn mỗi nguyên nhân với một dấu vân tay chỉ số trên nhiều nguồn cho phép vừa phát hiện vừa gán nguyên nhân, đổi lại chỉ nhận ra những nguyên nhân đã định nghĩa trước. So với Begen et al. (2023) dùng mô hình phân loại có giám sát trên nhật ký POS, P5 không cần dữ liệu gắn nhãn nên áp dụng được ngay cho doanh nghiệp chưa có lịch sử gian lận được xác minh, nhưng bỏ lỡ gian lận nhẹ như H6; khi đã tích lũy được trường hợp xác minh, hai cách có thể bổ trợ nhau.

Các phương pháp định vị nguyên nhân như Adtributor (Bhagwan et al., 2014) hay HotSpot (Sun et al., 2018) tìm chiều và giá trị gây biến động trên một chỉ số. Cây KPI làm việc tương tự ở bước đầu, nhưng đi thêm một bước là đối chiếu với dữ liệu nhân sự, kho và đối soát; ví dụ CN2 cho thấy bước này là cần thiết, vì phân rã doanh thu chỉ cho biết đơn App giảm, còn dữ liệu chấm công mới cho biết vì sao. Cuối cùng, việc không phát hiện được thất thoát kho với kiểm kê hai tuần phù hợp với nghiên cứu về sai lệch tồn kho: tần suất kiểm kê là yếu tố làm giảm sai lệch (DeHoratius & Raman, 2008), và thất thoát nhỏ chỉ lộ ra khi đã tích lũy (Kang & Gershwin, 2005).

5.7.3. Các yếu tố ảnh hưởng đến tính hợp lệ

Về tính hợp lệ nội tại, tham số được chọn trên tập phát triển nên kết quả trên tập này lạc quan, như khoảng cách F1 từ 0,79 xuống 0,52 xác nhận; tập kiểm tra độc lập với hạt giống, chi nhánh, thời điểm và mức độ sự cố khác giảm rủi ro này. Tuy vậy hai tập được sinh bởi cùng một bộ mô phỏng, nên tập kiểm tra kiểm tra được khả năng khái quát sang sự cố mới chứ chưa sang một doanh nghiệp khác; bộ mô phỏng và bộ phát hiện lại được xây dựng trong cùng một nghiên cứu, nên có nguy cơ vô thức thiết kế phương pháp hợp với cách dữ liệu được sinh. Về tính hợp lệ cấu trúc, mỗi kịch bản có một nguyên nhân chính, cường độ ổn định và hầu như không chồng lấn, trong khi ngoài thực tế nhiều vấn đề có thể xảy ra đồng thời và tăng dần. Về tính hợp lệ bên ngoài, dữ liệu mô phỏng một chuỗi giả định; một số quy luật mua hàng đã được hiệu chỉnh từ dữ liệu thật của một tiệm bánh ở Vương quốc Anh, còn các tham số vận hành khác là giả định (mục 3.3.5), nên kết quả định lượng chưa thể khẳng định cho một doanh nghiệp cụ thể. Điều khóa luận chứng minh được là tính khả thi và đúng đắn của phương pháp trong điều kiện có kiểm soát, cùng một đường ống áp dụng được cho dữ liệu thật mà không phải đổi kiến trúc. Về tính hợp lệ thống kê, sáu kịch bản mỗi tập chỉ cho tỷ lệ mang tính chỉ báo, nên kết quả được báo cáo chi tiết từng kịch bản và từng báo động giả.

5.8. Tiểu kết chương

Kết quả thực nghiệm trả lời được cả ba câu hỏi nghiên cứu như tóm tắt ở mục 5.7.1: đường ống tích hợp đủ bảy nguồn mà không thất lạc dữ liệu, bộ phát hiện vượt rõ hai phương án cơ sở trên tập kiểm tra độc lập, và nguyên nhân đúng luôn đứng hạng một khi sự cố đã để lại tín hiệu. Điểm yếu tập trung ở sự cố nhẹ, ngắn, ở thất thoát kho khi kiểm kê thưa và ở nhóm hạng C quá nhỏ. Chương 6 tổng kết theo mục tiêu đề tài và đề xuất hướng phát triển.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chương này tổng kết kết quả theo các mục tiêu đã đặt ra, rút ra hàm ý quản trị cho các chuỗi F&B, nêu những điều chỉnh so với đề cương, các hạn chế và hướng phát triển.

6.1. Kết quả đạt được

Đối chiếu với các mục tiêu cụ thể ở mục 1.4.2, khóa luận đã đạt được các kết quả sau.

- Bộ dữ liệu mô phỏng theo nguyên lý "một thế giới, nhiều góc nhìn" sinh dữ liệu nhất quán về nhân quả cho bảy hệ thống vận hành cùng danh mục và thời tiết, có đủ lỗi dữ liệu đặc trưng, thành hai tập độc lập 26 tuần với 385 đến 435 nghìn đơn mỗi tập; cả mười hai kịch bản sự cố tạo tác động đúng thiết kế (Bảng 4.3).
- Đường ống nhận dữ liệu qua ba kênh như thực tế và kiểm tra theo hợp đồng dữ liệu; Bronze nạp tăng dần và lũy đẳng; Silver hợp nhất hai phiên bản POS, giải quyết định danh giữa sáu hệ mã và cách ly 1.352 dòng lỗi kèm lý do, với chênh lệch số dòng không giải thích được bằng 0 ở cả bảy nguồn; đường ống xử lý đúng 11 tình huống dữ liệu bất thường cùng lúc và một lần API nguồn không phản hồi.
- Kho dữ liệu dạng lược đồ hình sao gồm sáu bảng sự kiện, bảy bảng chiều, trong đó hai chiều thay đổi chậm kiểu 2; 158 kiểm thử dbt đạt trên cả ba tập và doanh thu thuần Gold khớp tuyệt đối với Silver.
- Bộ 24 chỉ số giám sát được so với mức kỳ vọng theo nhóm cùng hạng và lịch sử của chính chi nhánh; cây KPI chỉ đúng nhánh bị ảnh hưởng, và không tuần lễ, tuần mưa hay tuần đổi giá nào bị gán nguyên nhân do biến động chung.
- Trên tập kiểm tra chạy một lần với ngưỡng đã chốt, bộ phát hiện bắt bốn trên sáu sự cố với F1 0,52, độ trễ trung vị 6 ngày, so với 5/6 và F1 0,79 trên tập phát triển; ở mọi sự cố có tín hiệu, nguyên nhân đúng xếp hạng một, và phương pháp vượt rõ hai phương án cơ sở.
- Ứng dụng 14 trang, kho phục vụ PostgreSQL với dashboard Metabase và hai DAG Airflow đưa bảy ngày dữ liệu mới từ hệ thống nguồn đến cảnh báo trong khoảng 150 đến 200 giây; toàn bộ hệ thống chạy bằng một lệnh Docker Compose.

Về học thuật, khóa luận đóng góp một cách đánh giá có kiểm soát cho bài toán phát hiện sự cố vận hành trên dữ liệu đa nguồn, trong đó dữ liệu mô phỏng nhất quán nhân quả và tập kiểm tra độc lập cho phép đo lường định lượng thay vì chỉ minh họa. Về thực tiễn, nền tảng cho thấy một chuỗi F&B quy mô vừa có thể xây dựng hệ thống dữ liệu theo các nguyên tắc kỹ thuật dữ liệu chuẩn mực bằng công cụ mã nguồn mở trên một máy tính, và rằng nhìn doanh thu tổng hợp gần như không phát hiện được sự cố vận hành nào, trong khi đối chiếu chéo các nguồn thì có.

6.2. Hàm ý quản trị

Các kết quả được rút ra từ dữ liệu mô phỏng, nên những hàm ý dưới đây là định hướng cho chuỗi F&B quy mô vừa có cơ cấu vận hành tương tự và cần được kiểm chứng lại trên dữ liệu của chính doanh nghiệp.

Thứ nhất, không nên chỉ theo dõi doanh thu tổng hợp. Phương án chỉ giám sát doanh thu không phát hiện được sự cố nào trên tập phát triển và chỉ một trên sáu sự cố trên tập kiểm tra, vì nhiều sự cố gây thiệt hại thật mà doanh thu gần như không đổi. Báo cáo vận hành hằng tuần nên đặt doanh thu cạnh các chỉ số đối chiếu giữa hệ thống: đơn sàn so với đơn trên POS, hoa hồng thực tế so với hợp đồng, hao hụt so với định mức theo nguyên liệu, số ca làm so với lượng đơn, và tỷ lệ hủy, hoàn theo thu ngân.

Thứ hai, đối soát với sàn nên được làm hằng tuần theo điều khoản hợp đồng thay vì chỉ khi thực nhận giảm bất thường. Phí sàn chiếm khoảng một phần tư doanh thu món, nên sai lệch vài điểm phần trăm có thể kéo dài nhiều tháng; thí nghiệm ở mục 5.5.3 cho thấy luật so thẳng với hợp đồng phát hiện được sai lệch suốt thời gian nó tồn tại, còn so với lịch sử chỉ nhận ra trong vài tuần đầu.

Thứ ba, cần bảo vệ định biên nhân sự tối thiểu của từng ca kể cả khi muốn giảm chi phí nhân công. Thiếu nhân sự bếp ca tối là sự cố gây thiệt hại lớn nhất, ước tính 94,6 triệu đồng doanh thu trong hai tuần, và còn ảnh hưởng sau khi nhân sự đã trở lại; thời gian chuẩn bị và tỷ lệ đơn bị cửa hàng hủy là hai chỉ báo sớm nên theo dõi cùng số ca làm. Labor% của chi nhánh nhỏ cần so với chi nhánh cùng hạng, vì hạng C có Labor% gấp khoảng 3,4 lần hạng A chỉ do phải duy trì số người tối thiểu.

Thứ tư, kiểm soát nội bộ dựa trên dữ liệu nhưng không kết luận chỉ từ thống kê. Tỷ lệ hủy, hoàn và giảm giá theo thu ngân là căn cứ để chọn ca cần xem lại hóa đơn và

camera, chưa đủ để kết luận gian lận. Với hàng tồn kho, nhịp kiểm kê hai tuần không đủ để phát hiện thất thoát ở nguyên liệu tồn chỉ vài ngày, nên cần kiểm kê hằng tuần hoặc đột xuất cho nhóm giá trị cao như thịt bò, thịt gà và phô mai.

Thứ năm, chiến lược kênh và thực đơn nên tính theo biên đóng góp chứ không theo doanh thu. Sau phí sàn và giá vốn, mỗi 100 đồng bán qua GrabFood chỉ còn khoảng 41 đồng so với 69 đồng tại quầy, nên kéo khách giao hàng sang ứng dụng riêng mang lại lợi ích rõ, nhất là ngày mưa; món bán chạy nhất có lãi mỗi phần dưới bình quân, nên gợi ý bán kèm sang combo lãi cao hiệu quả hơn tăng giá.

Cuối cùng, doanh nghiệp cần coi dữ liệu vận hành là tài sản được quản lý: thống nhất mã chi nhánh, mã nhân viên, tên nguyên liệu giữa các hệ thống; yêu cầu đối tác và nhà cung cấp phần mềm xuất dữ liệu theo khuôn dạng cố định; lưu lại toàn bộ dữ liệu gốc để mọi con số truy ngược được về chứng từ ban đầu; và xử lý cảnh báo theo thiệt hại ước tính để nguồn lực kiểm tra tập trung vào nơi mất mát nhiều nhất.

6.3. Điều chỉnh so với đề cương

Mục tiêu tổng quát, câu hỏi nghiên cứu và phạm vi giữ nguyên như đề cương; riêng mục tiêu cụ thể thứ sáu được bổ sung lớp báo cáo kinh doanh. Các nội dung đề cương đã xếp ngoài phạm vi vẫn nằm ngoài phạm vi, gồm dữ liệu thật của doanh nghiệp, gửi cảnh báo qua kênh nhắn tin, triển khai trên đám mây và dự báo nhu cầu. Phần bổ sung gồm kho phục vụ PostgreSQL và Metabase để tách máy tính toán khỏi nơi phục vụ người đọc; cơ chế kích hoạt đường ống theo dữ liệu mới bên cạnh chạy theo lịch; tầng thu thập với ba kênh, hợp đồng dữ liệu và API giả lập phía nguồn để đường đi của dữ liệu giống thực tế; đề xuất xử lý và thiệt hại ước tính cho từng cảnh báo; và một trợ lý phân tích thử nghiệm chưa được đánh giá. Nguyên tắc của các điều chỉnh là ưu tiên chất lượng của đường ống và của đánh giá, chỉ thêm thành phần khi nó giải quyết một nhu cầu cụ thể, không thêm công nghệ chỉ để có mặt.

6.4. Hạn chế

Hạn chế lớn nhất là dữ liệu mô phỏng: nền tảng chưa được kiểm chứng trên dữ liệu vận hành thật. Một số quy luật mua hàng đã được hiệu chỉnh từ dữ liệu giao dịch thật công khai nhưng thuộc loại hình và bối cảnh khác; các tham số vận hành còn lại là giả định, và một số kết luận như số đơn không giảm sau điều chỉnh giá phản ánh giả

định hơn là hành vi khách hàng. Nhu cầu theo giờ dạng bậc thang, hai ca cố định và khách hàng chọn ngẫu nhiên khiến chưa phân tích được phân ca theo giờ và giữ chân khách (mục 3.3.5). Các kịch bản đơn giản hơn thực tế, mỗi tập chỉ sáu kịch bản nên tỷ lệ phát hiện chỉ mang tính chỉ báo, và bộ mô phỏng cùng bộ phát hiện được xây dựng trong cùng một nghiên cứu.

Về phương pháp, thất thoát kho ở S5 và H5 không phát hiện được với nhịp kiểm kê hai tuần; sự cố nhẹ và ngắn nằm sát dưới ngưỡng, như H4 điểm 2,82 và H6 điểm 3,44; nhóm hạng C chỉ ba chi nhánh nên mức kỳ vọng nhiễu, gây bốn trên bảy báo động giả ở tập kiểm tra. Phân tích độ nhạy cho thấy cửa sổ 12 tuần tốt hơn nhẹ 8 tuần trên tập phát triển nhưng chưa được kiểm chứng trên dữ liệu mới; tầng khớp mờ tên nguyên liệu chưa phải dùng tới lần nào. Định nghĩa Labor% chỉ gồm lương giờ trực tiếp, và giá vốn món dùng định mức, chưa phân bổ hao hụt thực tế theo món.

Về kỹ thuật, tầng thu thập mới được kiểm chứng với API giả lập, trong khi API thật có thể khác về xác thực, cách lấy tăng dần và giới hạn tần suất; mã xác thực đang để trong biến môi trường. Kiểm thử dbt kiểm tra kết quả sau khi dựng, chưa có kiểm thử đơn vị cho logic của từng mô hình SQL với đầu vào và kết quả mong đợi viết sẵn, nên một lỗi logic chỉ lộ ra nếu nó vi phạm một luật đã khai báo. Silver và Gold được dựng lại toàn bộ mỗi lượt, phù hợp với quy mô hiện tại nhưng cần chuyển sang cập nhật tăng dần khi dữ liệu lớn hơn nhiều lần (mục 3.5.3). DuckDB chỉ cho một tiến trình ghi nên mỗi lúc chỉ một lượt đường ống; ứng dụng chưa có đăng nhập, phân quyền và dashboard được nhúng bằng liên kết công khai, chỉ phù hợp trong mạng nội bộ.

6.5. Hướng phát triển

Hướng đầu tiên và nên ưu tiên là áp dụng trên dữ liệu thật của một doanh nghiệp đối tác sau khi có thỏa thuận về quyền truy cập và bảo mật: viết bộ kết nối cho API của nhà cung cấp POS cụ thể theo khuôn hiện có, chuyển nguồn tệp sang thư mục dùng chung hoặc hộp thư nhận báo cáo, bổ sung hợp đồng dữ liệu cho mẫu tệp thật, rồi hiệu chỉnh lại tham số bộ phát hiện trên dữ liệu đó. Mọi cải tiến khác đều cần được hiệu chỉnh lại trên dữ liệu này.

Về bộ phát hiện, các hướng cụ thể gồm gộp bằng chứng P3 theo trọng số, ưu tiên tín hiệu gốc là số ca bếp; cộng dồn bằng chứng thu ngân qua nhiều tuần bằng tổng tích lũy CUSUM (Page, 1954) để gian lận nhẹ kéo dài được phát hiện sớm; thay trung vị

nhóm hạng C bằng mô hình kỳ vọng có biến quy mô; thử cửa sổ mức nền dài hơn. Các cải tiến này cần được đánh giá trên một tập kiểm tra mới, vì tập kiểm tra hiện tại đã được xem kết quả. Về phân tích, khi có dữ liệu ca làm và lịch sử khách hàng thật, có thể dự báo nhu cầu theo chi nhánh, kênh và khung giờ để đề xuất lượng đặt hàng và lịch phân ca, tính biên lợi nhuận theo món có hao hụt thực tế, và phân khúc khách hàng ứng dụng kèm hành động cụ thể. Hệ thống cũng có thể gửi cảnh báo chủ động qua email hoặc kênh nhắn tin cho người phụ trách, và tổ chức cấu hình nguồn, bảng ánh xạ, tham số theo từng doanh nghiệp để phục vụ nhiều chuỗi mà không sửa mã lõi.

Cuối cùng, kiến trúc hiện tại đã tách các vai trò lưu tệp thô, điều phối, tính toán, kho phục vụ và trình bày, nên có thể chuyển lên đám mây mà không đổi logic. Trên Amazon Web Services chẳng hạn, vùng tiếp nhận tương ứng với Amazon S3 kèm thông báo sự kiện thay cho Dataset của Airflow; Airflow chuyển sang dịch vụ Airflow được quản lý và giữ nguyên hai DAG; DuckDB cùng dbt chạy trong container đọc ghi tệp Parquet trên S3, và chỉ khi dữ liệu lớn hơn nhiều bậc mới cần chuyển sang kho phân tán với bộ chuyển dbt tương ứng; kho phục vụ chuyển sang PostgreSQL được quản lý; ứng dụng và Metabase chạy sau bộ cân bằng tải có đăng nhập. Việc chuyển này chỉ thực sự cần khi nền tảng phục vụ nhiều người dùng hoặc nhiều chuỗi cùng lúc.

TÀI LIỆU THAM KHẢO

Abedjan, Z., Golab, L., & Naumann, F. (2015). Profiling relational data: A survey. *The VLDB Journal, 24*(4), 557–581. https://doi.org/10.1007/s00778-015-0389-y

Agresti, A. (2013). *Categorical data analysis* (3rd ed.). Wiley.

Apache Software Foundation. (n.d.). *Apache Airflow documentation*. https://airflow.apache.org/docs/

Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. In *Proceedings of the 11th Conference on Innovative Data Systems Research (CIDR 2021)*.

Batini, C., & Scannapieco, M. (2016). *Data and information quality: Dimensions, principles and techniques*. Springer.

Begen, E., Sayan, İ. U., Bayrak, A. T., & Yıldız, O. T. (2023). Point of sale fraud detection methods via machine learning. In *2023 International Conference on Innovations in Intelligent Systems and Applications (INISTA)* (pp. 1–5). IEEE. https://doi.org/10.1109/INISTA59065.2023.10310515

Bhagwan, R., Kumar, R., Ramjee, R., Varghese, G., Mohapatra, S., Manoharan, H., & Shah, P. (2014). Adtributor: Revenue debugging in advertising systems. In *Proceedings of the 11th USENIX Symposium on Networked Systems Design and Implementation (NSDI 14)* (pp. 43–55). USENIX Association.

Bolton, R. J., & Hand, D. J. (2002). Statistical fraud detection: A review. *Statistical Science, 17*(3), 235–255. https://doi.org/10.1214/ss/1042727940

Breck, E., Polyzotis, N., Roy, S., Whang, S. E., & Zinkevich, M. (2019). Data validation for machine learning. In *Proceedings of the 2nd SysML Conference*.

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107.

Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys, 41*(3), Article 15. https://doi.org/10.1145/1541880.1541882

Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record, 26*(1), 65–74. https://doi.org/10.1145/248603.248616

Christen, P. (2012). *Data matching: Concepts and techniques for record linkage, entity resolution, and duplicate detection*. Springer.

Databricks. (n.d.). *What is a medallion architecture?* https://www.databricks.com/glossary/medallion-architecture

dbt Labs. (n.d.). *dbt documentation*. https://docs.getdbt.com/

DeHoratius, N., & Raman, A. (2008). Inventory record inaccuracy: An empirical analysis. *Management Science, 54*(4), 627–641. https://doi.org/10.1287/mnsc.1070.0789

Docker Inc. (n.d.). *Docker Compose documentation*. https://docs.docker.com/compose/

Dopson, L. R., & Hayes, D. K. (2019). *Food and beverage cost control* (7th ed.). Wiley.

Dunn, O. J. (1961). Multiple comparisons among means. *Journal of the American Statistical Association, 56*(293), 52–64. https://doi.org/10.1080/01621459.1961.10482090

Elmagarmid, A. K., Ipeirotis, P. G., & Verykios, V. S. (2007). Duplicate record detection: A survey. *IEEE Transactions on Knowledge and Data Engineering, 19*(1), 1–16. https://doi.org/10.1109/TKDE.2007.250581

Emmott, A. F., Das, S., Dietterich, T., Fern, A., & Wong, W.-K. (2013). Systematic construction of anomaly detection benchmarks from real data. In *Proceedings of the ACM SIGKDD Workshop on Outlier Detection and Description (ODD '13)* (pp. 16–21). ACM. https://doi.org/10.1145/2500853.2500858

FastAPI. (n.d.). *FastAPI documentation*. https://fastapi.tiangolo.com/

Feldman, P., Frazelle, A. E., & Swinney, R. (2023). Managing relationships between restaurants and food delivery platforms: Conflict, contracts, and coordination. *Management Science, 69*(2), 812–823. https://doi.org/10.1287/mnsc.2022.4390

Fellegi, I. P., & Sunter, A. B. (1969). A theory for record linkage. *Journal of the American Statistical Association, 64*(328), 1183–1210. https://doi.org/10.1080/01621459.1969.10501049

Fielding, R. T. (2000). *Architectural styles and the design of network-based software architectures* [Doctoral dissertation, University of California, Irvine].

Golfarelli, M., & Rizzi, S. (2009). *Data warehouse design: Modern principles and methodologies*. McGraw-Hill.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., Fernández del Río, J., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with

NumPy. *Nature, 585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly, 28*(1), 75–105. https://doi.org/10.2307/25148625

Hodge, V. J., & Austin, J. (2004). A survey of outlier detection methodologies. *Artificial Intelligence Review, 22*(2), 85–126. https://doi.org/10.1023/B:AIRE.0000045502.10941.a9

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. https://otexts.com/fpp3/

Iglewicz, B., & Hoaglin, D. C. (1993). *How to detect and handle outliers*. ASQC Quality Press.

Inmon, W. H. (2005). *Building the data warehouse* (4th ed.). Wiley.

iPOS.vn. (2025). *Báo cáo thị trường kinh doanh ẩm thực tại Việt Nam năm 2024* [Báo cáo thực hiện cùng Nestlé Professional]. Công ty Cổ phần iPOS.vn.

Jaro, M. A. (1989). Advances in record-linkage methodology as applied to matching the 1985 census of Tampa, Florida. *Journal of the American Statistical Association, 84*(406), 414–420. https://doi.org/10.1080/01621459.1989.10478785

Jordon, J., Szpruch, L., Houssiau, F., Bottarelli, M., Cherubin, G., Maple, C., Cohen, S. N., & Weller, A. (2022). *Synthetic data – what, why and how?* (arXiv:2205.03257). arXiv. https://doi.org/10.48550/arXiv.2205.03257

Kang, Y., & Gershwin, S. B. (2005). Information inaccuracy in inventory systems: Stock loss and stockout. *IIE Transactions, 37*(9), 843–859. https://doi.org/10.1080/07408170590969861

Kasavana, M. L., & Smith, D. I. (1982). *Menu engineering: A practical guide to menu analysis*. Hospitality Publications.

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), Article 15. https://doi.org/10.1145/2382577.2382579

Kimball, R., & Caserta, J. (2004). *The data warehouse ETL toolkit*. Wiley.

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Wiley.

Kimes, S. E. (1999). Implementing restaurant revenue management: A five-step approach. *Cornell Hotel and Restaurant Administration Quarterly, 40*(3), 16–21. https://doi.org/10.1177/001088049904000315

Kleinrock, L. (1975). *Queueing systems, Volume 1: Theory*. Wiley.

Kleppmann, M. (2017). *Designing data-intensive applications*. O'Reilly Media.

Laptev, N., Amizadeh, S., & Flint, I. (2015). Generic and scalable framework for automated time-series anomaly detection. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 1939–1947). ACM. https://doi.org/10.1145/2783258.2788611

Law, A. M. (2015). *Simulation modeling and analysis* (5th ed.). McGraw-Hill Education.

Leys, C., Ley, C., Klein, O., Bernard, P., & Licata, L. (2013). Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology, 49*(4), 764–766. https://doi.org/10.1016/j.jesp.2013.03.013

Li, C., Mirosa, M., & Bremer, P. (2020). Review of online food delivery platforms and their impacts on sustainability. *Sustainability, 12*(14), 5528. https://doi.org/10.3390/su12145528

Lin, Q., Lou, J.-G., Zhang, H., & Zhang, D. (2016). iDice: Problem identification for emerging issues. In *Proceedings of the 38th International Conference on Software Engineering (ICSE '16)* (pp. 214–224). ACM. https://doi.org/10.1145/2884781.2884795

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining* (pp. 413–422). IEEE. https://doi.org/10.1109/ICDM.2008.17

Lopez-Rojas, E. A., Elmir, A., & Axelsson, S. (2016). PaySim: A financial mobile money simulator for fraud detection. In *Proceedings of the 28th European Modeling and Simulation Symposium (EMSS 2016)* (pp. 249–255).

Malashin, I. P., Masich, I. S., Tynchenko, V. S., Gantimurov, A. P., Nelyub, V. A., Borodulin, A. S., Tokarev, S. I., & Vasilev, D. I. (2024). Anomaly detection in restaurant receipts data. *IEEE Access, 12*, 145590–145607. https://doi.org/10.1109/ACCESS.2024.3471081

Mariani, M., Baggio, R., Fuchs, M., & Höepken, W. (2018). Business intelligence and big data in hospitality and tourism: A systematic literature review. *International*

Journal of Contemporary Hospitality Management, 30(12), 3514–3554. https://doi.org/10.1108/IJCHM-07-2017-0461

McKinney, W. (2010). Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Merkel, D. (2014). Docker: Lightweight Linux containers for consistent development and deployment. *Linux Journal, 2014*(239), Article 2.

Metabase. (n.d.). *Metabase documentation*. https://www.metabase.com/docs/

Momentum Works. (2025). *Food delivery platforms in Southeast Asia* (5th ed.). Momentum Works.

Montgomery, D. C. (2019). *Introduction to statistical quality control* (8th ed.). Wiley.

Object Management Group. (2017). *OMG Unified Modeling Language (OMG UML), Version 2.5.1*. https://www.omg.org/spec/UML/2.5.1/

OpenAPI Initiative. (2021). *OpenAPI Specification, Version 3.1.0*. https://spec.openapis.org/oas/v3.1.0

OpenML. (2022). *The-Bread-Basket* (Dataset ID 43422) [Data set]. https://www.openml.org/d/43422

Page, E. S. (1954). Continuous inspection schemes. *Biometrika, 41*(1–2), 100–115. https://doi.org/10.1093/biomet/41.1-2.100

Papargyropoulou, E., Wright, N., Lozano, R., Steinberger, J., Padfield, R., & Ujang, Z. (2016). Conceptual framework for the study of food waste generation and prevention in the hospitality sector. *Waste Management, 49*, 326–336. https://doi.org/10.1016/j.wasman.2016.01.017

Patki, N., Wedge, R., & Veeramachaneni, K. (2016). The synthetic data vault. In *2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)* (pp. 399–410). IEEE. https://doi.org/10.1109/DSAA.2016.49

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems, 24*(3), 45–77. https://doi.org/10.2753/MIS0742-1222240302

Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data quality assessment. *Communications of the ACM, 45*(4), 211–218. https://doi.org/10.1145/505248.506010

PostgreSQL Global Development Group. (n.d.). *PostgreSQL documentation*. https://www.postgresql.org/docs/

Raasveldt, M., & Mühleisen, H. (2019). DuckDB: An embeddable analytical database. In *Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)* (pp. 1981–1984). ACM. https://doi.org/10.1145/3299869.3320212

Rahm, E., & Do, H. H. (2000). Data cleaning: Problems and current approaches. *IEEE Data Engineering Bulletin, 23*(4), 3–13.

Reis, J., & Housley, M. (2022). *Fundamentals of data engineering*. O'Reilly Media.

Rousseeuw, P. J., & Croux, C. (1993). Alternatives to the median absolute deviation. *Journal of the American Statistical Association, 88*(424), 1273–1283. https://doi.org/10.1080/01621459.1993.10476408

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Schelter, S., Lange, D., Schmidt, P., Celikel, M., Biessmann, F., & Grafberger, A. (2018). Automating large-scale data quality verification. *Proceedings of the VLDB Endowment, 11*(12), 1781–1794. https://doi.org/10.14778/3229863.3229867

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems 28* (pp. 2503–2511).

Simmhan, Y. L., Plale, B., & Gannon, D. (2005). A survey of data provenance in e-science. *ACM SIGMOD Record, 34*(3), 31–36. https://doi.org/10.1145/1084805.1084812

Streamlit. (n.d.). *Streamlit documentation*. https://docs.streamlit.io/

Sun, Y., Zhao, Y., Su, Y., Liu, D., Nie, X., Meng, Y., Cheng, S., Pei, D., Zhang, S., Qu, X., & Guo, X. (2018). HotSpot: Anomaly localization for additive KPIs with multi-dimensional attributes. *IEEE Access, 6*, 10909–10923. https://doi.org/10.1109/ACCESS.2018.2804764

Tatbul, N., Lee, T. J., Zdonik, S., Alam, M., & Gottschlich, J. (2018). Precision and recall for time series. In *Advances in Neural Information Processing Systems 31* (pp. 1920–1930).

Thompson, G. M. (1998). Labor scheduling, part 1: Forecasting demand. *Cornell Hotel and Restaurant Administration Quarterly, 39*(5), 22–31. https://doi.org/10.1177/001088049803900507

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Vanschoren, J., van Rijn, J. N., Bischl, B., & Torgo, L. (2013). OpenML: Networked science in machine learning. *ACM SIGKDD Explorations Newsletter, 15*(2), 49–60. https://doi.org/10.1145/2641190.2641198

Vassiliadis, P. (2009). A survey of extract–transform–load technology. *International Journal of Data Warehousing and Mining, 5*(3), 1–27. https://doi.org/10.4018/jdwm.2009070101

Vu, T. D., Nguyen, H. V., Vu, P. T., Tran, T. H. H., & Vu, V. H. (2023). Gen Z customers' continuance intention in using food delivery application in an emerging market: Empirical evidence from Vietnam. *Sustainability, 15*(20), 14776. https://doi.org/10.3390/su152014776

Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems, 12*(4), 5–33. https://doi.org/10.1080/07421222.1996.11518099

Winkler, W. E. (1990). String comparator metrics and enhanced decision rules in the Fellegi–Sunter model of record linkage. In *Proceedings of the Section on Survey Research Methods* (pp. 354–359). American Statistical Association.

PHỤ LỤC

Phụ lục A. Mã nguồn và tài liệu của hệ thống

Toàn bộ mã nguồn của bộ mô phỏng, đường ống dữ liệu, dự án dbt, bộ phát hiện, ứng dụng và cấu hình Docker Compose, Airflow được lưu tại kho mã nguồn dưới đây. Tệp README.md ở thư mục gốc hướng dẫn cài đặt, sinh dữ liệu, chạy đường ống và tái lập các kết quả đánh giá của Chương 5.

Bảng A.1. Đường dẫn tới mã nguồn và tài liệu của hệ thống

Nội dung	Đường dẫn
Kho mã nguồn	https://github.com/phuclc17/final_proj
Hướng dẫn cài đặt và chạy	https://github.com/phuclc17/final_proj/blob/main/README.md

Nguồn: Kho mã nguồn của khóa luận